

ベイズ統計

概要: 事象は原因と関連している。ある事象が興った時、その原因をベイズ統計は教えてくれる。

キーワード: ベイズの定理; 条件付き確率; ベイズ更新; 事前確率; 事後確率

1. 序

ベイズ統計は条件付き確率と関連する。条件付き確率は通常の統計でよく扱われている。したがって、その意味ではベイズ統計は通常の統計と何ら変わるところがない。

通常の統計では、我々はデータを取得し、そのデータに基づいて次に起こることを予想する。ベイズ統計は逆向きの議論をする。すなわち、あることが起こった場合、その起こった原因は何かを議論する。原因の同定があまりはっきりできなくても、次々にデータを取得していけば、その予測精度は良くなっていく。最近では、我々は大きなデータを比較的容易に取得できるようになっている。そのため、このベイズ統計は注目されている。

2. 医療検査のベイズ理論

図 1 に示す医療検査を考えよう。

病気に罹っている人を検視した場合、陽性になるのが 98%としよう。検査結果が陽性である場合を E とする。そして、対応する確率を以下のように表す。


$$P(E) = 0.98 \quad (1)$$

ここで、我々は罹患している人のみを扱っていることに注意しよう。高い陽性比率は検査の観点から言えばいいことである。しかし、それだけでは罹患のチェックとしては不備である。病気に罹っていない人への検査結果が大事である。

病気に罹っていない人の検査で陽性になる確率を求める。それは、以下のように低いものであったとする。検査結果が陰性であることを $\bar{E}$ であらわす。すると

$$P(\bar{E}) = 0.05 \quad (2)$$

となる。



1

図 1 病気にかかっている人といない人の検査結果

検査して陽性である人を同じ確率の式 $P(E)$ で表していた。しかし、この二つの $P(E)$ は違うものである。つまり、本当にその病気に罹っている場合と本当はその病気に罹っていない場合である。

実際に病気に罹っている人を A 、罹っていない人を B とする。式(1)の 98 % は病気に罹っている人が陽性と判断される確率である。したがって、その確率を以下のように変形して表す。

$$P(E|A) = 0.98 \quad (3)$$

これは、実際に病気に罹っていて、検査結果が陽性である確率を表している。

実際は病気に罹っていない人が、検査結果で陽性になる確率を $P(E|B)$ で表そう。したがって、それは以下で表せる。

$$P(E|B) = 0.05 \quad (4)$$

検査では $P(E|A)$ が高く、 $P(E|B)$ が低いことが要請される。

我々はさらに情報が必要である。つまり、この病気にかかる人の割合 $P(A)$ である。これを 5 %

とあるとする。したがって、

$$P(A) = 0.05 \quad (5)$$

となる。つまり、実際は病気になっていない人の割合は以下になる。

$$P(B) = 1 - P(A) = 0.95 \quad (6)$$

厳密に言えば、確率 $P(A)$ は全ての事象の中で、事象 A が起こる確率である。すべての事象は A と $\bar{A}$ の和である。このすべて事象を Ω とする。したがって、 $P(A)$ は以下のように表記される。

$$P(A) \rightarrow P(A|\Omega) \quad (7)$$

我々はしばしば Ω を無視する。

検査を受けて陽性である確率は以下となる。

$$\begin{aligned} P(E) &= P(E|A)P(A) + P(E|B)P(B) \\ &= 0.98 \times 0.05 + 0.05 \times 0.95 \\ &= 0.0965 \end{aligned} \quad (8)$$

したがって、陽性である確率は 0.0965、約 10 % 程度である。これは、実際に病気である人の割合が 0.1 であることに起因する。

検査結果が陽性である場合、自分が本当にその病気に罹っているか、が問題になる。

集合の中から一人のメンバーを選ぶ。そして、その人に検査をする。その結果として陽性が出た。この人が本当に病気に罹患している確率はいくらか？を知りたい。つまり、 $P(A|E)$ を知りたい。

この状況を図 2 に示す。ここでは、検査結果が陰性の人には、興味がない。検査結果が陽性の中で、真に病気に罹患している人の割合を知りたいのである。

実際に罹患していて、つまり A であり、検査結果が陽性である比率は

$$P(E|A)P(A) \quad (9)$$

である。

検査結果が陽性であるが、実際は罹患していない人 B である人の比率は

$$P(E|B)P(B) \quad (10)$$

したがって、 $P(A|E)$ は以下になる。

$$\begin{aligned}
 P(A|E) &= \frac{P(E|A)P(A)}{P(E|A)P(A) + P(E|B)P(B)} \\
 &= \frac{0.98 \times 0.05}{0.98 \times 0.05 + 0.05 \times 0.95} \\
 &= 0.51
 \end{aligned}
 \tag{11}$$

これは、ベイズ確率と呼ばれる。この確率は $P(E|A) = 0.98$ より著しく低い。

検査結果が陽性である人のすべては図 2 で茶色にハッチしている人々である。実際に罹患している人の割合はこの中で A に属している人である。実際に罹患していない人が検査結果で陽性になる確率は低い、その絶対数はそれほど低いわけではない。したがって、 $P(A|E)$ は思ったほど大きい値にはならない。




図 2 検査結果が陽性であった場合の罹患率を求める模式図

上の結果は容易に一般化できる。

実際の結果をここでは、陽性、陰性の 2 種類とした仮定していなかったが、 m 種類に拡張する。したがって、 $A_i (i=1,2,\dots,m)$ となる。したがって結果 E を得た場合の確率は以下の関係になる。

$$\begin{aligned}
P(A_i|E) &= \frac{P(E|A_i)P(A_i)}{P(E)} \\
&= \frac{P(E|A_i)P(A_i)}{P(E|A_1)P(A_1) + P(E|A_2)P(A_2) + \cdots + P(E|A_m)P(A_m)} \\
&= \frac{P(E|A_i)P(A_i)}{\sum_{j=1}^m P(E|A_j)P(A_j)}
\end{aligned} \tag{12}$$

これをベイズ統計の理論という。

3. 2 回の医療検査

先にのべたように、一回目の検査で陽性になった人が本当に罹患している場合は約 50%であった。では、この人にさらに検査を加えてその確率を増すことを考えよう。

2 回目の検査では

$$P(A|E) \rightarrow P(A) \tag{13}$$

$$P(B|E) \rightarrow P(B) \tag{14}$$

とする。

病気に罹患している人が検査で陽性になる場合に、実際に罹患している場合の確率は

$$\begin{aligned}
P(A|E) &= \frac{P(E|A)P(A)}{P(E|A)P(A) + P(E|B)P(B)} \\
&= \frac{0.98 \times 0.51}{0.98 \times 0.51 + 0.05 \times 0.49} \\
&= 0.95
\end{aligned} \tag{15}$$

であった。

病気に罹患していない人が検査で陽性になる場合に、実際には罹患していない場合の確率は

$$\begin{aligned}
P(B|E) &= \frac{P(E|B)P(B)}{P(E|A)P(A) + P(E|B)P(B)} \\
&= \frac{0.05 \times 0.49}{0.98 \times 0.51 + 0.05 \times 0.49} \\
&= 0.05
\end{aligned} \tag{16}$$

である。したがって、検査が独立であれば、検査を 2 回することに意味がある。しかし、実際は同じ検査をすると、同じ傾向にあるから、検査で陽性が出た人は、同じ検査で陽性になる場合が多いと考えられる。したがって、2 種類の検査をしていくことになる。

4. 2種類の医療検査

ここでは二種類の検査をする場合を考えよう。それに対するデータは、以下である。

検査1での実際に罹患している場合の陽性率、罹患していない場合の陽性率。

検査2での実際に罹患している場合の陽性率、罹患していない場合の陽性率。

実際に罹患している場合の確率。

それぞれ、 $P_1(E|A)=0.8$ および $P_1(E|B)=0.1$ とする。 $P_2(E|A)=0.98$ および

$P_2(E|B)=0.03$ とする。また $P(A)=0.05$ および $P(B)=0.95$ とする。




図 3 2種類の検査をする場合

最初に検査1を行う。

検査1で陰性だった場合 $\bar{E}$ を考える。

$$\begin{aligned}
P_1(A|\bar{E}) &= \frac{P_1(\bar{E}|A)P(A)}{P_1(\bar{E}|A)P(A) + P_1(\bar{E}|B)P(B)} \\
&= \frac{0.2 \times 0.05}{0.2 \times 0.05 + 0.90 \times 0.95} \\
&= 0.01
\end{aligned} \tag{17}$$

$$\begin{aligned}
P_1(B|\bar{E}) &= \frac{P_1(\bar{E}|B)P(B)}{P_1(\bar{E}|A)P(A) + P_1(\bar{E}|B)P(B)} \\
&= \frac{0.90 \times 0.95}{0.2 \times 0.05 + 0.90 \times 0.95} \\
&= 0.99
\end{aligned} \tag{18}$$

この場合は圧倒的に罹患していないと判断できるため検査は打ち切りとなる。患者が罹患していないと判断できる。

検査 1 で陽性が出た場合を考えよう。その場合、実際に罹患している確率は

$$\begin{aligned}
P_1(A|E) &= \frac{P_1(E|A)P(A)}{P_1(E|A)P(A) + P_1(E|B)P(B)} \\
&= \frac{0.80 \times 0.05}{0.80 \times 0.05 + 0.10 \times 0.95} \\
&= 0.30
\end{aligned} \tag{19}$$

となる。検査 1 で陽性が出ても罹患していない確率は

$$\begin{aligned}
P_1(B|E) &= \frac{P_1(E|B)P(B)}{P_1(E|A)P(A) + P_1(E|B)P(B)} \\
&= \frac{0.10 \times 0.95}{0.80 \times 0.05 + 0.10 \times 0.95} \\
&= 0.70
\end{aligned} \tag{20}$$

である。

検査 1 で陽性が出ても実際に罹患していない確率の方が大きいことがわかる。

そこで、検査 2 を加える。ここで、2 回目の検査では、罹患している割合は

$$P(A|E) \rightarrow P(A) \tag{21}$$

$$P(B|E) \rightarrow P(B) \tag{22}$$

とする。




図 4 検査 1 によって更新されたベジアン確率

検査でも陽性が出た場合、実査に罹患している確率は

$$\begin{aligned}
 P_2(A|E) &= \frac{P_2(E|A)P(A)}{P_2(E|A)P(A) + P_2(E|B)P(B)} \\
 &= \frac{0.98 \times 0.30}{0.98 \times 0.30 + 0.03 \times 0.70} \\
 &= 0.93
 \end{aligned} \tag{23}$$

となる。検査 2 で陽性が出ても罹患していない確率は

$$\begin{aligned}
 P_2(B|E) &= \frac{P_2(E|B)P(B)}{P_2(E|A)P(A) + P_2(E|B)P(B)} \\
 &= \frac{0.03 \times 0.70}{0.98 \times 0.30 + 0.03 \times 0.70} \\
 &= 0.07
 \end{aligned} \tag{24}$$

である。したがって、おそらく患者は病気に罹患している。

もし、2 回目の検査で陽性がでなかったら、それを $\bar{E}$ であらわし、実際は罹患している確率は

$$\begin{aligned}
 P_2(A|\bar{E}) &= \frac{P_2(\bar{E}|A)P(A)}{P_2(\bar{E}|A)P(A) + P_2(\bar{E}|B)P(B)} \\
 &= \frac{0.02 \times 0.30}{0.02 \times 0.30 + 0.97 \times 0.70} \\
 &= 0.01
 \end{aligned} \tag{25}$$

である。実際は罹患していない確率は

$$\begin{aligned}
P_2(B|\bar{E}) &= \frac{P_2(\bar{E}|B)P(B)}{P_2(\bar{E}|A)P(A) + P_2(\bar{E}|B)P(B)} \\
&= \frac{0.97 \times 0.70}{0.02 \times 0.30 + 0.97 \times 0.70} \\
&= 0.99
\end{aligned} \tag{26}$$

となる。したがって、患者は病気に罹患していないと判断できる。

5. 時間厳守人間か？(曖昧なものを定量的に定義する)

ベイズ理論を利用して、われわれは、あいまいなことを決定づけることができる。

時間厳守人間かどうかを判断しよう。時間厳守人間は、時間通りに約束を果たすというイメージがある。時間厳守人間とそうでない人間は、完全ではない。すなわち時間厳守人間は常に時間を守るわけではない。

ここで、時間厳守人間とそうでない人間を定義しよう。時間厳守人間は、約束時間に 5 回中 4 回は守ると定義しよう。時間厳守でない人間は 4 回中 3 回は時間を守れないとしよう。つまり、以下のように定義する。

Punctual: On time probability = $\frac{4}{5}$; Off time probability = $\frac{1}{5}$

Not punctual: On time probability = $\frac{1}{4}$; Off time probability = $\frac{3}{4}$

つまり、時間非厳守人間と時間厳守人間を表 1 のように定義する。

表 1 時間厳守、時間非厳守の定義

Character	Off time(D_1)	On time(D_2)
Not Punctual(H_1)	$\frac{3}{4}$	$\frac{1}{4}$
Punctual(H_2)	$\frac{1}{5}$	$\frac{4}{5}$

メンバー S が時間厳守か非時間厳守人間かを以下のように判断する。

もし人 S が時間非厳守だったら H_1 ，時間厳守だったら H_2 とする。

時間に遅れたら D_1 送れなかったら D_2 とする。

S の実績は D_2, D_2, D_1, D_1, D_1 であったとする。

Step 0

ここで、初期条件を決めなければならない。すなわち、世の中には時間非厳守人間と、時間厳守人間の比率はいくらか、ということである。ここでは、時間非厳守人間は 0.6 としよう。すると、以下

になる。

$$P(H_1) = 0.6 \quad (27)$$

$$P(H_2) = 0.4 \quad (28)$$

Step 1

ここでメンバー S がどちらに属するか判断しよう。メンバーS のデータは D_2, D_2, D_1, D_1, D_1 であった。この最初の D_2 を取りあげる。

最初の会合で時間に間に合った D_2 であるから、S が時間非厳守である確率は

$$\begin{aligned} P(H_1|D_2) &= \frac{P(D_2|H_1)P(H_1)}{P(D_2|H_1)P(H_1) + P(D_2|H_2)P(H_2)} \\ &= \frac{\frac{1}{4} \times 0.6}{\frac{1}{4} \times 0.6 + \frac{4}{5} \times 0.4} \\ &= 0.319 \end{aligned} \quad (29)$$

である。時間厳守である確率は

$$\begin{aligned} P(H_2|D_2) &= \frac{P(D_2|H_2)P(H_2)}{P(D_2|H_1)P(H_1) + P(D_2|H_2)P(H_2)} \\ &= \frac{\frac{4}{5} \times 0.4}{\frac{1}{4} \times 0.6 + \frac{4}{5} \times 0.4} \\ &= 0.681 \end{aligned} \quad (30)$$

である。

ここで、 $P(H_1)$ と $P(H_2)$ をアップデートする。つまり

$$P(H_1|D_2) \rightarrow P(H_1) = 0.319 \quad (31)$$

$$P(H_2|D_2) \rightarrow P(H_2) = 0.681 \quad (32)$$

とする。

Step 2

メンバーS は、 D_2, D_2, D_1, D_1, D_1 であった。この次の D_2 を取りあげる。

2番目の会合で時間に間に合ったのであるから、メンバーS が時間非厳守である確率は

$$\begin{aligned}
P(H_1|D_2) &= \frac{P(D_2|H_1)P(H_1)}{P(D_2|H_1)P(H_1) + P(D_2|H_2)P(H_2)} \\
&= \frac{\frac{1}{4} \times 0.310}{\frac{1}{4} \times 0.310 + \frac{4}{5} \times 0.681} \\
&= 0.125
\end{aligned} \tag{33}$$

である。メンバーS が時間厳守である確率は

$$\begin{aligned}
P(H_2|D_2) &= \frac{P(D_2|H_2)P(H_2)}{P(D_2|H_1)P(H_1) + P(D_2|H_2)P(H_2)} \\
&= \frac{\frac{4}{5} \times 0.681}{\frac{1}{4} \times 0.310 + \frac{4}{5} \times 0.681} \\
&= 0.875
\end{aligned} \tag{34}$$

である。

ここで、 $P(H_1)$ と $P(H_2)$ をアップデートする。つまり

$$P(H_1|D_2) \rightarrow P(H_1) = 0.125 \tag{35}$$

$$P(H_2|D_2) \rightarrow P(H_2) = 0.875 \tag{36}$$

とする。

Step 3

メンバーS は、 D_2, D_2, D_1, D_1, D_1 であった。3 番目の D_1 を取りあげる。

3 番目の会合で時間に間に合わなかったのであるから、メンバーS が時間非厳守である確率は

$$\begin{aligned}
P(H_1|D_1) &= \frac{P(D_1|H_1)P(H_1)}{P(D_1|H_1)P(H_1) + P(D_1|H_2)P(H_2)} \\
&= \frac{\frac{3}{4} \times 0.125}{\frac{3}{4} \times 0.125 + \frac{1}{5} \times 0.875} \\
&= 0.349
\end{aligned} \tag{37}$$

である。メンバーS が時間厳守である凝る確率は

$$\begin{aligned}
P(H_2|D_1) &= \frac{P(D_1|H_2)P(H_2)}{P(D_1|H_1)P(H_1) + P(D_1|H_2)P(H_2)} \\
&= \frac{\frac{1}{5} \times 0.875}{\frac{3}{4} \times 0.125 + \frac{1}{5} \times 0.875} \\
&= 0.651
\end{aligned} \tag{38}$$

である。

ここで、 $P(H_1)$ と $P(H_2)$ をアップデートする。つまり

$$P(H_1|D_1) \rightarrow P(H_1) = 0.349 \tag{39}$$

$$P(H_2|D_1) \rightarrow P(H_2) = 0.651 \tag{40}$$

となる。

Step 4

メンバーS は、 D_2, D_2, D_1, D_1, D_1 であった。4 番目の D_1 を取りあげる。

4 番目の会合で時間に間に合わなかったのであるから、メンバーS が時間非厳守である確率は

$$\begin{aligned}
P(H_1|D_1) &= \frac{P(D_1|H_1)P(H_1)}{P(D_1|H_1)P(H_1) + P(D_1|H_2)P(H_2)} \\
&= \frac{\frac{3}{4} \times 0.349}{\frac{3}{4} \times 0.349 + \frac{1}{5} \times 0.651} \\
&= 0.668
\end{aligned} \tag{41}$$

となる。メンバーS が時間厳守である確率は

$$\begin{aligned}
P(H_2|D_1) &= \frac{P(D_1|H_2)P(H_2)}{P(D_1|H_1)P(H_1) + P(D_1|H_2)P(H_2)} \\
&= \frac{\frac{1}{5} \times 0.651}{\frac{3}{4} \times 0.349 + \frac{1}{5} \times 0.651} \\
&= 0.332
\end{aligned} \tag{42}$$

となる。

ここで、 $P(H_1)$ と $P(H_2)$ をアップデートする。つまり

$$P(H_1|D_1) \rightarrow P(H_1) = 0.668 \quad (43)$$

$$P(H_2|D_1) \rightarrow P(H_2) = 0.332 \quad (44)$$

となる。

Step 5

メンバーSは、 D_2, D_2, D_1, D_1, D_1 であった。5番目の D_1 を取りあげる。

5番目の会合で時間に間に合わなかったのであるから、メンバーSが時間非厳守である確率は

$$\begin{aligned} P(H_1|D_1) &= \frac{P(D_1|H_1)P(H_1)}{P(D_1|H_1)P(H_1) + P(D_1|H_2)P(H_2)} \\ &= \frac{\frac{3}{4} \times 0.668}{\frac{3}{4} \times 0.668 + \frac{1}{5} \times 0.332} \\ &= 0.883 \end{aligned} \quad (45)$$

である。メンバーSが時間厳守である確率は

$$\begin{aligned} P(H_2|D_1) &= \frac{P(D_1|H_2)P(H_2)}{P(D_1|H_1)P(H_1) + P(D_1|H_2)P(H_2)} \\ &= \frac{\frac{1}{5} \times 0.332}{\frac{3}{4} \times 0.668 + \frac{1}{5} \times 0.332} \\ &= 0.117 \end{aligned} \quad (46)$$

となる。

ここで、 $P(H_1)$ と $P(H_2)$ をアップデートする。つまり

$$P(H_1|D_1) \rightarrow P(H_1) = 0.883 \quad (47)$$

$$P(H_2|D_1) \rightarrow P(H_2) = 0.117 \quad (48)$$

となる。したがって、メンバーSは時間非厳守人間である確率が高いと言える。

ここで、時間厳守とか時間非厳守とかはあいまいでどうとも定義できることに注目しよう。しかし、いったん時間厳守、時間非厳守がどういうものかを決めてしまえば、決めてしまったことに応じて、上の方式でそのどちらに属するのかを計算できる。これは、あくまでそうすることができることを示したままで、それが正しいかどうかを保証するものではない。役に立てば使えばいいし、役に立たな

いと思ったら使わなければいい。

6. スпамメール問題

われわれは日々たくさんのメールを受け取る。その中にスパムメールがある。そのスパムメールを取り除きたいという要望がある。それをベイズ統計で行う。

われわれは連日膨大な量のメールを受け取る。その中で、スパムメールとそうでないものがある。それがスパムメールである比率 r_{s0} はわかっているものとする。

スパムメールとスパムメールではないメールで **word1** が含まれているメール数を n_{s1}, n_{ns1} とする。これから

$$r_{s1} = \frac{n_{s1}}{n_{s1} + n_{ns1}} \quad (49)$$

$$r_{ns1} = \frac{n_{ns1}}{n_{s1} + n_{ns1}} \quad (50)$$

とする。他の **wod** でも同じような操作をして表 2 のような表を構成する。表では、**Word3** までしか表示していない。

表 2 スпамメールを同定するための表

Word	Spam	Non-spam
W01	r_{s1}	r_{ns1}
W02	r_{s2}	r_{ns2}
W03	r_{s3}	r_{ns3}

ここで、

$$r_{si} + r_{nsi} = 1 \quad (51)$$

である。

われわれはスパムメールを S で、非スパムメールを $\bar{S}$ で表す。われわれは、メールで **word1,2,3** を発見したとする。

まず **word1** から考える。

われわれは **word 1** を発見したのであるから、それがスパムメールである確率は

$$\begin{aligned}
 P(S|W01) &= \frac{P(W01|S)P(S)}{P(W01|S)P(S) + P(W01|\bar{S})P(\bar{S})} \\
 &= \frac{r_{s1}r_{s0}}{r_{s1}r_{s0} + r_{ns1}(1-r_{s0})} \rightarrow P(S)
 \end{aligned} \quad (52)$$

となる。それが、非スパムメールである確率は

$$\begin{aligned}
P(\bar{S}|W01) &= \frac{P(W01|\bar{S})P(\bar{S})}{P(W01|S)P(S) + P(W01|\bar{S})P(\bar{S})} \\
&= \frac{r_{ns1}(1-r_{s0})}{r_{s1}r_{s0} + r_{ns1}(1-r_{s0})} \rightarrow P(\bar{S})
\end{aligned} \tag{53}$$

となる。

われわれは word 2 を発見したのであるから、それがスパムメールである確率は

$$\begin{aligned}
P(S|W02) &= \frac{P(W02|S)P(S)}{P(W02|S)P(S) + P(W02|\bar{S})P(\bar{S})} \\
&= \frac{r_{s2} \frac{r_{s1}r_{s0}}{r_{s1}r_{s0} + r_{ns1}(1-r_{s0})}}{r_{s2} \frac{r_{s1}r_{s0}}{r_{s1}r_{s0} + r_{ns1}(1-r_{s0})} + r_{ns2} \frac{r_{ns1}(1-r_{s0})}{r_{s1}r_{s0} + r_{ns1}(1-r_{s0})}} \\
&= \frac{r_{s2}r_{s1}r_{s0}}{r_{s2}r_{s1}r_{s0} + r_{ns2}r_{ns1}(1-r_{s0})} \rightarrow P(S)
\end{aligned} \tag{54}$$

となる。それが、非スパムメールをある確率は

$$\begin{aligned}
P(\bar{S}|W02) &= \frac{P(W02|\bar{S})P(\bar{S})}{P(W02|S)P(S) + P(W02|\bar{S})P(\bar{S})} \\
&= \frac{r_{ns2} \frac{r_{ns1}(1-r_{s0})}{r_{s1}r_{s0} + r_{ns1}(1-r_{s0})}}{r_{s2} \frac{r_{s1}r_{s0}}{r_{s1}r_{s0} + r_{ns1}(1-r_{s0})} + r_{ns2} \frac{r_{ns1}(1-r_{s0})}{r_{s1}r_{s0} + r_{ns1}(1-r_{s0})}} \\
&= \frac{r_{ns2}r_{ns1}(1-r_{s0})}{r_{s2}r_{s1}r_{s0} + r_{ns2}r_{ns1}(1-r_{s0})} \rightarrow P(\bar{S})
\end{aligned} \tag{55}$$

となる。

われわれは word3 を発見したのであるから、それがスパムメールである確率は

$$\begin{aligned}
P(S|W03) &= \frac{P(W03|S)P(S)}{P(W03|S)P(S) + P(W03|\bar{S})P(\bar{S})} \\
&= \frac{r_{s3} \frac{r_{s2}r_{s1}r_{s0}}{r_{s2}r_{s1}r_{s0} + r_{ns2}r_{ns1}(1-r_{s0})}}{r_{s3} \frac{r_{s2}r_{s1}r_{s0}}{r_{s2}r_{s1}r_{s0} + r_{ns2}r_{ns1}(1-r_{s0})} + r_{ns3} \frac{r_{ns2}r_{ns1}(1-r_{s0})}{r_{s2}r_{s1}r_{s0} + r_{ns2}r_{ns1}(1-r_{s0})}} \\
&= \frac{r_{s3}r_{s2}r_{s1}r_{s0}}{r_{s3}r_{s2}r_{s1}r_{s0} + r_{ns3}r_{ns2}r_{ns1}(1-r_{s0})} \rightarrow P(S)
\end{aligned} \tag{56}$$

となる。それが、非スパムメールをある確率は

$$\begin{aligned}
P(\bar{S}|W03) &= \frac{P(W03|\bar{S})P(\bar{S})}{P(W03|S)P(S) + P(W03|\bar{S})P(\bar{S})} \\
&= \frac{r_{ns3} \frac{r_{ns2}r_{ns1}(1-r_{s0})}{r_{s2}r_{s1}r_{s0} + r_{ns2}r_{ns1}(1-r_{s0})}}{r_{s3} \frac{r_{s2}r_{s1}r_{s0}}{r_{s2}r_{s1}r_{s0} + r_{ns2}r_{ns1}(1-r_{s0})} + r_{ns3} \frac{r_{ns2}r_{ns1}(1-r_{s0})}{r_{s2}r_{s1}r_{s0} + r_{ns2}r_{ns1}(1-r_{s0})}} \\
&= \frac{r_{ns3}r_{ns2}r_{ns1}(1-r_{s0})}{r_{s3}r_{s2}r_{s1}r_{s0} + r_{ns3}r_{ns2}r_{ns1}(1-r_{s0})} \rightarrow P(\bar{S})
\end{aligned} \tag{57}$$

となる。

この拡張は辞書を作成することによってなされる。

7. 壺問題

ここで、ベイズ統計の典型的な問題を扱う。

二つの壺があるとする。壺 A にはグレーの球が4個と黒の球が 1 個、壺 B にはグレーの球が 2 個と黒の球で 3 個入っているとする。

壺から球を取り出し、この壺が A なのか B なのかを判断したい。




図 5 二つの種類の壺問題

二つの壺 A と B を考える。壺 A はグレーの球と黒の球の比が 4:1 であり、壺 B ではその比率が 2:3 であるとする。

ここで、問題になるのは、壺 A になる確率と壺 B になる確率である。これらは実績のある場合はその値を用い入れればいいが、ない場合はよくわからないので、等しいとおく。すなわち

$$P(A) = P(B) = \frac{1}{2} \quad (58)$$

とする。

ここで、黒い球を引き当てたことを E とし、グレーの球と引き当てたことを $\bar{E}$ とする。つまり

$$\begin{cases} P(E|A) = \frac{1}{5} \\ P(\bar{E}|A) = \frac{4}{5} \end{cases} \quad (59)$$

$$\begin{cases} P(E|B) = \frac{3}{5} \\ P(\bar{E}|B) = \frac{2}{5} \end{cases} \quad (60)$$

である。

黒の球を引き当てた際の壺 A である確率は

$$P(A|E) = \frac{P(E|A)P(A)}{P(E|A)P(A) + P(E|B)P(B)} \quad (61)$$

となる。これが、壺 A である確率は

$$P(B|E) = \frac{P(E|B)P(B)}{P(E|A)P(A) + P(E|B)P(B)} \quad (62)$$

となる。

グレーの球を引き当てた場合は壺 A になる確率は

$$P(A|\bar{E}) = \frac{P(\bar{E}|A)P(A)}{P(\bar{E}|A)P(A) + P(\bar{E}|B)P(B)} \quad (63)$$

である。壺 B になる確率は

$$P(B|\bar{E}) = \frac{P(\bar{E}|B)P(B)}{P(\bar{E}|A)P(A) + P(\bar{E}|B)P(B)} \quad (64)$$

となる。

データとしては $\bar{E}E\bar{E}E\bar{E}$ を得たとする。この場合の A なのか B なのかを論じる。

Step 1

データとしては $\bar{E}E\bar{E}E\bar{E}$ を得た。最初にグレーの球を得た ($\bar{E}$)。したがって、壺 A である確率は

$$\begin{aligned} P(A|\bar{E}) &= \frac{P(\bar{E}|A)P(A)}{P(\bar{E}|A)P(A) + P(\bar{E}|B)P(B)} \\ &= \frac{\frac{4}{5} \times \frac{1}{2}}{\frac{4}{5} \times \frac{1}{2} + \frac{2}{5} \times \frac{1}{2}} \\ &= 0.667 \end{aligned} \quad (65)$$

である。壺 B である確率は

$$\begin{aligned} P(B|\bar{E}) &= \frac{P(\bar{E}|B)P(B)}{P(\bar{E}|A)P(A) + P(\bar{E}|B)P(B)} \\ &= \frac{\frac{2}{5} \times \frac{1}{2}}{\frac{4}{5} \times \frac{1}{2} + \frac{2}{5} \times \frac{1}{2}} \\ &= 0.333 \end{aligned} \quad (66)$$

である。

ここで、最初に $\bar{E}$ を得たのであるから、 $P(A)$ と $P(B)$ は更新される。すなわち

$$\begin{cases} P(A) = P(A|\bar{E}) = 0.667 \\ P(B) = P(B|\bar{E}) = 0.333 \end{cases} \quad (67)$$

となる。

Step 2

データとしては $\bar{E}E\bar{E}E\bar{E}E$ を得たのであるから、2 番目のデータに注目する。2 番目として黒球 (E) を得たのであるから、壺 A である確率は

$$\begin{aligned} P(A|E) &= \frac{P(E|A)P(A)}{P(E|A)P(A) + P(E|B)P(B)} \\ &= \frac{\frac{1}{5} \times 0.667}{\frac{1}{5} \times 0.667 + \frac{3}{5} \times 0.333} \\ &= 0.4 \end{aligned} \quad (68)$$

である。壺 B である確率は

$$\begin{aligned} P(B|E) &= \frac{P(E|B)P(B)}{P(E|A)P(A) + P(E|B)P(B)} \\ &= \frac{\frac{2}{5} \times 0.333}{\frac{4}{5} \times 0.667 + \frac{2}{5} \times 0.333} \\ &= 0.6 \end{aligned} \quad (69)$$

である。ここで、 $P(A)$ と $P(B)$ は以下のように更新される。

$$\begin{cases} P(A) = P(A|E) = 0.4 \\ P(B) = P(B|E) = 0.6 \end{cases} \quad (70)$$

Step 3

データとしては $\bar{E}E\bar{E}E\bar{E}E$ を得たのであるから、3 番目のデータに注目する。3 番目として黒球 (E) を得たのであるから、壺 A である確率は

$$\begin{aligned} P(A|E) &= \frac{P(E|A)P(A)}{P(E|A)P(A) + P(E|B)P(B)} \\ &= \frac{\frac{1}{5} \times 0.4}{\frac{1}{5} \times 0.4 + \frac{3}{5} \times 0.6} \\ &= 0.182 \end{aligned} \quad (71)$$

である。壺 B である確率は

$$\begin{aligned}
P(B|E) &= \frac{P(E|B)P(B)}{P(E|A)P(A) + P(E|B)P(B)} \\
&= \frac{\frac{3}{5} \times 0.6}{\frac{1}{5} \times 0.4 + \frac{3}{5} \times 0.6} \\
&= 0.818
\end{aligned} \tag{72}$$

である。 $P(A)$ と $P(B)$ は更新されて

$$\begin{cases} P(A) = P(A|E) = 0.182 \\ P(B) = P(B|E) = 0.818 \end{cases} \tag{73}$$

となる。

Step 4

データとしては $\bar{E}E\bar{E}E$ を得たのであるから、4 番目のデータに注目する。4 番目としてグレイの球 ($\bar{E}$) を得たのであるから、壺 A である確率は

$$\begin{aligned}
P(A|\bar{E}) &= \frac{P(\bar{E}|A)P(A)}{P(\bar{E}|A)P(A) + P(\bar{E}|B)P(B)} \\
&= \frac{\frac{4}{5} \times 0.182}{\frac{4}{5} \times 0.182 + \frac{2}{5} \times 0.818} \\
&= 0.308
\end{aligned} \tag{74}$$

である。壺 B である確率は

$$\begin{aligned}
P(B|\bar{E}) &= \frac{P(\bar{E}|B)P(B)}{P(\bar{E}|A)P(A) + P(\bar{E}|B)P(B)} \\
&= \frac{\frac{2}{5} \times 0.818}{\frac{4}{5} \times 0.182 + \frac{2}{5} \times 0.818} \\
&= 0.692
\end{aligned} \tag{75}$$

である。

ここで、 $P(A)$ と $P(B)$ は以下のように更新される。

$$\begin{cases} P(A) = P(A|\bar{E}) = 0.308 \\ P(B) = P(B|\bar{E}) = 0.692 \end{cases} \tag{76}$$

Step 5

データとしては $\bar{E}E\bar{E}\bar{E}\bar{E}$ を得たのであるから、5 番目のデータに注目する。5 番目として黒の球 (E) を得たのであるから、壺 A である確率は

$$\begin{aligned}
 P(A|E) &= \frac{P(E|A)P(A)}{P(E|A)P(A) + P(E|B)P(B)} \\
 &= \frac{\frac{1}{5} \times 0.308}{\frac{1}{5} \times 0.308 + \frac{3}{5} \times 0.692} \\
 &= 0.129
 \end{aligned} \tag{77}$$

である。壺 B である確率は

$$\begin{aligned}
 P(B|E) &= \frac{P(E|B)P(B)}{P(E|A)P(A) + P(E|B)P(B)} \\
 &= \frac{3}{5} \times 0.692 \\
 &= 0.871
 \end{aligned} \tag{78}$$

である。 $P(A)$ と $P(B)$ は更新されて以下になる。

$$\begin{cases} P(A) = P(A|E) = 0.182 \\ P(B) = P(B|E) = 0.818 \end{cases} \tag{79}$$

データ取得後の $P(A)$ は $P(B)$ よりかなり小さい。したがって、壺 B である可能性が高い。このように、データ取得後に壺 A か B と判断する。

8. 壺問題の発展形

ここでは、二つのタイプ、つまり壺 A か壺 B しか扱ってこなかった。しかし、壺の数はいくらでも増やせる。これを一般形とする。

壺 A_i とする。つまり i は $1, 2, \dots, m$ と m 種類の壺を考える。この中で、今グレーと黒の 2 種類しか考えていなかったが、 j 種類の色を考え、それを E_j とする。

ここで、必要なデータは壺 A_i である確率である。それがある場合はそれを採用すればいい。それが無い場合は、同じとみなす。すなわち

$$P(A_i) = \frac{1}{m} \tag{80}$$

とする。

あと、必要なのは、壺 A_i の素性である。これは

$$P(E_j|A_i) \tag{81}$$

とする。

$$\sum_j P(E_j|A_i) = 1 \quad (82)$$

である。

もしも我々がデータとして E_i を得たとしよう。対応する確率は以下である。

$$P(A_i|E_i) = \frac{P(E_i|A_i)P(A_i)}{\sum_{i=1}^m P(E_i|A_i)P(A_i)} \rightarrow P(A_i) \quad (83)$$

ここで、 $P(A_i)$ をアップデートしている。

具体的な例を考えよう。

壺として三つを考えよう。つまり、壺 A_1 , A_2 、および A_3 である。この壺になる確率は

$$P(A_1) = P(A_2) = P(A_3) = \frac{1}{3} \quad (84)$$

である。

球の色としては黒、グレイ、白を考える。つまり E_1 , E_2 、および E_3 となる。

ここで、壺 A_1 , A_2 、および A_3 は以下のように特徴づけられる。

$$P(E_1|A_1) = \frac{1}{5}; P(E_2|A_1) = \frac{2}{5}; P(E_3|A_1) = \frac{2}{5} \quad (85)$$

$$P(E_1|A_2) = \frac{3}{5}; P(E_2|A_2) = \frac{1}{5}; P(E_3|A_2) = \frac{1}{5} \quad (86)$$

$$P(E_1|A_3) = \frac{2}{5}; P(E_2|A_3) = \frac{0}{5}; P(E_3|A_3) = \frac{3}{5} \quad (87)$$

もしもわれわれがデータ E_i を取得したら、各確率は以下になる。

$$P(A_1|E_i) = \frac{P(E_i|A_1)}{P(E_i|A_1)P(A_1) + P(E_i|A_2)P(A_2) + P(E_i|A_3)P(A_3)} \quad (88)$$

$$P(A_2|E_i) = \frac{P(E_i|A_2)}{P(E_i|A_1)P(A_1) + P(E_i|A_2)P(A_2) + P(E_i|A_3)P(A_3)} \quad (89)$$

$$P(A_3|E_i) = \frac{P(E_i|A_3)}{P(E_i|A_1)P(A_1) + P(E_i|A_2)P(A_2) + P(E_i|A_3)P(A_3)} \quad (90)$$

これは、容易に m 種類の壺に拡張できて

$$P(A_k|E_i) = \frac{P(E_i|A_k)}{\sum_{j=1}^m P(E_i|A_j)P(A_j)} \quad (91)$$

となる。ここで、球の色は $i=1,2,\dots,l$ となる。これを繰り返していけばいい。

9. まとめ

このまとめを行う。

ここでは m 種類の壺 A_i ($i=1,2,\dots,m$) を考える。この中には数種類の色の球が入っていると
する。

球の色を a, b とし E_a, E_a, E_b のデータを得たとする。

1 回目のデータでは E_a を得た。するとこのデータで $P(A_i)$ になる確率は

$$P(A_1|E_a) = \frac{P(A_1)P(E_a|A_1)}{P(A_1)P(E_a|A_1) + P(A_2)P(E_a|A_2) + \dots + P(A_m)P(E_a|A_m)} \rightarrow P(A_1)$$

...

$$P(A_i|E_a) = \frac{P(A_i)P(E_a|A_i)}{P(A_1)P(E_a|A_1) + P(A_2)P(E_a|A_2) + \dots + P(A_m)P(E_a|A_m)} \rightarrow P(A_i)$$

...

$$P(A_m|E_a) = \frac{P(A_m)P(E_a|A_m)}{P(A_1)P(E_a|A_1) + P(A_2)P(E_a|A_2) + \dots + P(A_m)P(E_a|A_m)} \rightarrow P(A_m)$$

となる。

2 回目のデータで E_a を得ているから

$$P(A_1|E_a) = \frac{P(A_1)P(E_a|A_1)}{P(A_1)P(E_a|A_1) + P(A_2)P(E_a|A_2) + \dots + P(A_m)P(E_a|A_m)} \rightarrow P(A_1)$$

...

$$P(A_i|E_a) = \frac{P(A_i)P(E_a|A_i)}{P(A_1)P(E_a|A_1) + P(A_2)P(E_a|A_2) + \dots + P(A_m)P(E_a|A_m)} \rightarrow P(A_i)$$

...

$$P(A_m|E_a) = \frac{P(A_m)P(E_a|A_m)}{P(A_1)P(E_a|A_1) + P(A_2)P(E_a|A_2) + \dots + P(A_m)P(E_a|A_m)} \rightarrow P(A_m)$$

となる。三回目のデータで E_b を得ているから

$$P(A_1|E_b) = \frac{P(A_1)P(E_b|A_1)}{P(A_1)P(E_b|A_1) + P(A_2)P(E_b|A_2) + \dots + P(A_m)P(E_b|A_m)} \rightarrow P(A_1)$$

...

$$P(A_i|E_b) = \frac{P(A_i)P(E_b|A_i)}{P(A_1)P(E_b|A_1) + P(A_2)P(E_b|A_2) + \dots + P(A_m)P(E_b|A_m)} \rightarrow P(A_i)$$

...

$$P(A_m|E_b) = \frac{P(A_m)P(E_b|A_m)}{P(A_1)P(E_b|A_1) + P(A_2)P(E_b|A_2) + \cdots + P(A_m)P(E_b|A_m)} \rightarrow P(A_m)$$

となる。

更新された $P(A_i)$ の中で突出して大きいものがあれば、それである可能性が高い。

参考文献

ここでは、ベイズ統計の参考文献をあげておく。下記はあくまで参考である。自分に合っているものを選択すればいいと思う。合っているとは、理解がすすむという意味である。

[1] Excelですっきりわかるベイズ統計入門、涌井良幸、涌井貞美、日本実業出版社、2010、東京.