

1. 数量化Ⅰ類:重回帰分析

概要: 数量化Ⅰ類は、重回帰分析において説明変数にカテゴリーデータを含む場合である。
ここではカテゴリーデータを数値変換する方法を示す。

キーワード:数量化Ⅰ類

1.1. 序

重回帰分析として、目的変数として営業成績を考えよう。この説明変数としては、営業はその分野の知識、接客態度などがあげられる。それは、あいまであるが、アンケートで5点満点の点数をつけられているとする。つまり、説明変数は数値データである。しかし、目的変数の説明に、研修を受けた、受けない、といったカテゴリーデータを含む場合がある。研修に参加したかどうかはその糸のやる気と関連していると思われ、それが目的変数に影響を及ぼすと考えられる。そのような場合にどうすればいいのかを議論する。

1.2. 変数が一個の場合の解析

ここでは説明変数 x_1 が1個だけの場合をまず考える。

説明変数はカテゴリーであり、それは優、良、可で評価されるとする。

目的変数である総合成績は数値で与えられている。グループ討議の積極性に関しては優、良、可の三水準を設定する。対応するデータは表1である。

表1 グループ討議の積極性と総合成績の関係

ID	グループ討議	総合成績
1	優	96
2	優	88
3	優	77
4	優	89
5	良	80
6	良	71
7	良	77
8	可	78
9	可	70
10	可	62

この場合グループ討議の水準として優、良、可があるが、それを

$$x_{1(i)} = \begin{cases} 1 & \text{for 優} \\ 0 & \text{for 優以外} \end{cases} \quad (1)$$

$$x_{i(2)} = \begin{cases} 1 & \text{for 良} \\ 0 & \text{for 良以外} \end{cases} \quad (2)$$

$$x_{i(3)} = \begin{cases} 1 & \text{for 可} \\ 0 & \text{for 可以外} \end{cases} \quad (3)$$

と表現する。すると表 1 のデータは表 2 のようになる。

表 2 グループ討議の積極性の数値表現と総合成績の関係

ID	グループ討議x1	x1(1)	x1(2)	x1(3)	総合成績
1	優	1	0	0	96
2	優	1	0	0	88
3	優	1	0	0	77
4	優	1	0	0	89
5	良	0	1	0	80
6	良	0	1	0	71
7	良	0	1	0	77
8	可	0	0	1	78
9	可	0	0	1	70
10	可	0	0	1	62

したがって総合成績を y_i とすると

$$y_i = \beta_0 + \beta_{i(1)}x_{i(1)} + \beta_{i(2)}x_{i(2)} + \beta_{i(3)}x_{i(3)} + \varepsilon_i \quad (4)$$

と表現する。しかし、ここで制約条件

$$x_{i(1)} + x_{i(2)} + x_{i(3)} = 1 \quad (5)$$

があるから、一つの変数は余計である。どれを省略してもいいが、ここでは $x_{i(1)}$ を省略する。

すると

$$y_i = \beta_0 + \beta_{i(2)}x_{i(2)} + \beta_{i(3)}x_{i(3)} + \varepsilon_i \quad (6)$$

となる。 $x_{i(2)} = x_{i(3)} = 0$ が $x_{i(1)} = 1$ を表現している。つまり、実際に利用するデータは表 3 になる。

表 3 グループ討議の積極性と総合成績の関係の最終データ

ID	x1(2)	x1(3)	総合成績
1	0	0	96
2	0	0	88
3	0	0	77
4	0	0	89
5	1	0	80
6	1	0	71
7	1	0	77
8	0	1	78
9	0	1	70
10	0	1	62

よって y_i 予測値 $\hat{y}_i$ として

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_{1(2)}x_{i1(2)} + \hat{\beta}_{1(3)}x_{i1(3)} \quad (7)$$

を仮定し、その実際のデータ y_i からのずれの平方和

$$\begin{aligned} S_e^{(2)} &= \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ &= \frac{1}{n} \sum_{i=1}^n \left[y_i - \left(\hat{\beta}_0 + \hat{\beta}_{1(2)}x_{i1(2)} + \hat{\beta}_{1(3)}x_{i1(3)} \right) \right]^2 \end{aligned} \quad (8)$$

を最小にすることを要請して $\hat{\beta}_0, \hat{\beta}_{1(1)}, \hat{\beta}_{1(2)}$ を求める。

つまり、表 3 を得た以後は重回帰分析と同様である。

重回帰分析と同様なプロセスを以下に示していく。

$\hat{\beta}_0$ で偏微分して

$$\frac{\partial S_e^{(2)}}{\partial \hat{\beta}_0} = -\frac{2}{n} \sum_{i=1}^n \left[y_i - \left(\hat{\beta}_0 + \hat{\beta}_{1(2)}x_{i1(2)} + \hat{\beta}_{1(3)}x_{i1(3)} \right) \right] = 0 \quad (9)$$

これから

$$\hat{\beta}_0 = n \left[\bar{y} - \left(\hat{\beta}_{1(2)}\bar{x}_{1(2)} + \hat{\beta}_{1(3)}\bar{x}_{1(3)} \right) \right] \quad (10)$$

となる。これを代入して

$$\begin{aligned} S_e^{(2)} &= \frac{1}{n} \sum_{i=1}^n \left[y_i - \left(\hat{\beta}_0 + \hat{\beta}_{1(2)}x_{i1(2)} + \hat{\beta}_{1(3)}x_{i1(3)} \right) \right]^2 \\ &= \frac{1}{n} \sum_{i=1}^n \left[(y_i - \bar{y}) - \left[\hat{\beta}_{1(2)}(x_{i1(2)} - \bar{x}_{1(2)}) + \hat{\beta}_{1(3)}(x_{i1(3)} - \bar{x}_{1(3)}) \right] \right]^2 \end{aligned} \quad (11)$$

となる。

式を $\hat{\beta}_{1(2)}$ で偏微分して 0 と置き

$$\frac{\partial S_e^{(2)}}{\partial \hat{\beta}_{1(2)}} = -\frac{2}{n} \sum_{i=1}^n \left[(y_i - \bar{y}) - \left[\hat{\beta}_{1(2)} (x_{i1(2)} - \bar{x}_{1(2)}) + \hat{\beta}_{1(3)} (x_{i1(3)} - \bar{x}_{1(3)}) \right] \right] (x_{i1(2)} - \bar{x}_{1(2)}) = 0 \quad (12)$$

を得る。これから

$$\hat{\beta}_{1(2)} S_{1(2)1(2)}^{(2)} + \hat{\beta}_{1(3)} S_{1(3)1(2)}^{(2)} = S_{y1(2)}^{(2)} \quad (13)$$

となる。

式を $\hat{\beta}_{1(3)}$ で偏微分して

$$\frac{\partial S_e^{(2)}}{\partial \hat{\beta}_{1(3)}} = -\frac{2}{n} \sum_{i=1}^n \left[(y_i - \bar{y}) - \left[\hat{\beta}_{1(2)} (x_{i1(2)} - \bar{x}_{1(2)}) + \hat{\beta}_{1(3)} (x_{i1(3)} - \bar{x}_{1(3)}) \right] \right] (x_{i1(3)} - \bar{x}_{1(3)}) = 0 \quad (14)$$

を得る。これから

$$\hat{\beta}_{1(2)} S_{1(2)1(3)}^{(2)} + \hat{\beta}_{1(3)} S_{1(3)1(3)}^{(2)} = S_{y1(3)}^{(2)} \quad (15)$$

を得る。ただし

$$S_{1(2)1(2)}^{(2)} = \frac{1}{n} \sum_{i=1}^n (x_{i1(2)} - \bar{x}_{1(2)})^2 \quad (16)$$

$$S_{1(2)1(3)}^{(2)} = \frac{1}{n} \sum_{i=1}^n (x_{i1(2)} - \bar{x}_{1(2)}) (x_{i1(3)} - \bar{x}_{1(3)}) \quad (17)$$

$$S_{1(3)1(3)}^{(2)} = \frac{1}{n} \sum_{i=1}^n (x_{i1(3)} - \bar{x}_{1(3)})^2 \quad (18)$$

$$S_{y1(2)}^{(2)} = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y}) (x_{i1(2)} - \bar{x}_{1(2)}) \quad (19)$$

$$S_{y1(3)}^{(2)} = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y}) (x_{i1(3)} - \bar{x}_{1(3)}) \quad (20)$$

である。

式を行列表現すると

$$\begin{pmatrix} S_{1(2)1(2)}^{(2)} & S_{1(2)1(3)}^{(2)} \\ S_{1(2)1(3)}^{(2)} & S_{1(3)1(3)}^{(2)} \end{pmatrix} \begin{pmatrix} \hat{\beta}_{1(2)} \\ \hat{\beta}_{1(3)} \end{pmatrix} = \begin{pmatrix} S_{y1(2)}^{(2)} \\ S_{y1(3)}^{(2)} \end{pmatrix} \quad (21)$$

となる。これから

$$\begin{pmatrix} \hat{\beta}_{l(2)} \\ \hat{\beta}_{l(3)} \end{pmatrix} = \begin{pmatrix} S_{l(2)l(2)}^{(2)} & S_{l(2)l(3)}^{(2)} \\ S_{l(2)l(3)}^{(2)} & S_{l(3)l(3)}^{(2)} \end{pmatrix}^{-1} \begin{pmatrix} S_{yl(2)}^{(2)} \\ S_{yl(3)}^{(2)} \end{pmatrix} = \begin{pmatrix} -11.5 \\ -17.5 \end{pmatrix} \quad (22)$$

となり、 $\hat{\beta}_{l(2)}, \hat{\beta}_{l(3)}$ が求まった。さらにこれらを代入して $\hat{\beta}_0 = 87.5$ が求まる。よって、

$$\begin{aligned} \hat{y} &= \hat{\beta}_0 + \hat{\beta}_{l(2)}x_{il(2)} + \hat{\beta}_{l(3)}x_{il(3)} \\ &= 87.5 - 11.5x_{l(2)} - 17.5x_{l(3)} \end{aligned} \quad (23)$$

となる。数値データの回帰式と形式は同じであるが、 $x_{l(1)}, x_{l(2)}, x_{l(3)}$ の 1 個のみが 1 の値をとるということが異なる。したがって、

$$\hat{y} = 87.5 + \begin{cases} 0 & \text{優の場合} \\ -11.5 & \text{良の場合} \\ -17.5 & \text{可の場合} \end{cases} \quad (24)$$

となる。

1.3. 変数が複数の場合

項目が複数の場合を考える。前節のものに説明変数としてサークルに所属しているかどうかのデータを追加する。サークルに関連する水準としては、所属、無所属の二水準を設定する。対応するデータを表 4 に示す。

表 4 グループ討議の積極性、サークル所属と総合成績の関係

ID	グループ討議	サークル	総合成績
1	優	所属	96
2	優	所属	88
3	優	無所属	77
4	優	無所属	89
5	良	所属	80
6	良	無所属	71
7	良	無所属	77
8	可	所属	78
9	可	所属	70
10	可	無所属	62

この場合サークル所属の有無を反映して、それを

$$x_{2(i)} = \begin{cases} 1 & \text{for 所属} \\ 0 & \text{for 無所属} \end{cases} \quad (25)$$

$$x_{2(2)} = \begin{cases} 1 & \text{for 無所属} \\ 0 & \text{for 所属} \end{cases} \quad (26)$$

と表現する。すると表 1 のデータは表 2 のようになる。

したがって総合成績を y_i とすると

$$y_i = \beta_0 + \beta_{1(1)}x_{1(1)} + \beta_{1(2)}x_{1(2)} + \beta_{1(3)}x_{1(3)} + \beta_{2(1)}x_{2(1)} + \beta_{2(2)}x_{2(2)} + \varepsilon_i \quad (27)$$

と表現する。しかし、ここで制約条件

$$x_{1(1)} + x_{1(2)} + x_{1(3)} = 1 \quad (28)$$

$$x_{2(1)} + x_{2(2)} = 1 \quad (29)$$

があるから、それぞれ一つの変数は余計である。ここでは $x_{1(1)}$ 、 $x_{2(2)}$ を省略する。すると

$$y_i = \beta_0 + \beta_{1(2)}x_{1(2)} + \beta_{1(3)}x_{1(3)} + \beta_{2(1)}x_{2(1)} + \varepsilon_i \quad (30)$$

となる。対応するデータは表 6 になる。

表 5 グループ討議の積極性、サークル所属の数値表現と総合成績の関係

ID	グループ討議x1	x1(1)	x1(2)	x1(3)	サークルx2	x2(1)	x2(2)	総合成績
1	優	1	0	0	所属	1	0	96
2	優	1	0	0	所属	1	0	88
3	優	1	0	0	無所属	0	1	77
4	優	1	0	0	無所属	0	1	89
5	良	0	1	0	所属	1	0	80
6	良	0	1	0	無所属	0	1	71
7	良	0	1	0	無所属	0	1	77
8	可	0	0	1	所属	1	0	78
9	可	0	0	1	所属	1	0	70
10	可	0	0	1	無所属	0	1	62

表 6 グループ討議の積極性、クラブ所属と総合成績の関係の最終データ

ID	x1(2)	x1(3)	x2(1)	総合成績
1	0	0	1	96
2	0	0	1	88
3	0	0	0	77
4	0	0	0	89
5	1	0	1	80
6	1	0	0	71
7	1	0	0	77
8	0	1	1	78
9	0	1	1	70
10	0	1	0	62

よって y_i 予測値 $\hat{y}_i$ として

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_{1(2)}x_{i1(2)} + \hat{\beta}_{1(3)}x_{i1(3)} + \hat{\beta}_{2(1)}x_{i2(1)} \quad (31)$$

を仮定し、その実際のデータ y_i からのずれの平方和

$$\begin{aligned} S_e^{(2)} &= \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ &= \frac{1}{n} \sum_{i=1}^n \left[y_i - \left(\hat{\beta}_0 + \hat{\beta}_{1(2)}x_{i1(2)} + \hat{\beta}_{1(3)}x_{i1(3)} + \hat{\beta}_{2(1)}x_{i2(1)} \right) \right]^2 \end{aligned} \quad (32)$$

を最小にすることを要請して $\hat{\beta}_0, \hat{\beta}_{1(1)}, \hat{\beta}_{1(2)}, \hat{\beta}_{2(1)}$ を求める。

$$\begin{pmatrix} \hat{\beta}_{1(2)} \\ \hat{\beta}_{1(3)} \\ \hat{\beta}_{2(1)} \end{pmatrix} = \begin{pmatrix} S_{1(2)1(2)}^{(2)} & S_{1(2)1(3)}^{(2)} & S_{1(2)2(1)}^{(2)} \\ S_{1(2)1(3)}^{(2)} & S_{1(3)1(3)}^{(2)} & S_{1(3)2(1)}^{(2)} \\ S_{1(2)2(1)}^{(2)} & S_{1(3)2(1)}^{(2)} & S_{2(1)2(1)}^{(2)} \end{pmatrix}^{-1} \begin{pmatrix} S_{y1(2)}^{(2)} \\ S_{y1(3)}^{(2)} \\ S_{y2(1)}^{(2)} \end{pmatrix} = \begin{pmatrix} -10.0 \\ -19.0 \\ 9.0 \end{pmatrix} \quad (33)$$

また $\hat{\beta}_0$ は

$$\hat{\beta}_0 = n \left[\bar{y} - \left(\hat{\beta}_{1(2)}\bar{x}_{1(2)} + \hat{\beta}_{1(3)}\bar{x}_{1(3)} + \hat{\beta}_{2(1)}\bar{x}_{2(1)} \right) \right] = 83.0 \quad (34)$$

と求まる。

よって回帰式は

$$\begin{aligned} \hat{y} &= \hat{\beta}_0 + \hat{\beta}_{1(2)}x_{1(2)} + \hat{\beta}_{1(3)}x_{1(3)} + \hat{\beta}_{2(1)}x_{2(1)} \\ &= 83.0 - 10.0x_{1(2)} - 19.0x_{1(3)} + 9.0x_{2(1)} \\ &= 83.0 + \begin{cases} 0 & \text{優の場合} \\ -10.0 & \text{良の場合} \\ -19.0 & \text{可の場合} \end{cases} + \begin{cases} 0 & \text{無所属の場合} \\ 9.0 & \text{所属の場合} \end{cases} \end{aligned} \quad (35)$$

となる。

1.4. 数値、カテゴリー説明変数が混合している場合

説明変数としては、これまで扱ったカテゴリーの他に通常の数値データの場合がある。カテゴリーを数値化したあとは、重回帰分析と同じであるから、これら混合データを容易に扱うことができる。前節で扱ったデータに、数値データである通学時間を追加する。対応するデータを表 7 に示す。通学時間を x_3 として最終的なデータは表 8 になる。

表 7 グループ討議の積極性、サークル所属、通学時間と総合成績の関係

ID	グループ討議	サークル	通学時間	総合成績
1	優	所属	15	96
2	優	所属	85	88
3	優	無所属	78	77
4	優	無所属	15	89
5	良	所属	57	80
6	良	無所属	29	71
7	良	無所属	64	77
8	可	所属	22	78
9	可	所属	57	70
10	可	無所属	50	62

表 8 グループ討議の積極性、サークル所属、通学時間と総合成績の関係の最終データ

ID	x1(2)	x1(3)	x2(1)	x3	総合成績
1	0	0	1	15	96
2	0	0	1	85	88
3	0	0	0	78	77
4	0	0	0	15	89
5	1	0	1	57	80
6	1	0	0	29	71
7	1	0	0	64	77
8	0	1	1	22	78
9	0	1	1	57	70
10	0	1	0	50	62

$$y_i = \beta_0 + \beta_{1(2)}x_{i1(2)} + \beta_{1(3)}x_{i1(3)} + \beta_{2(1)}x_{i2(1)} + \beta_3x_{i3} + \varepsilon_i \quad (36)$$

よって y_i 予測値 $\hat{y}_i$ として

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_{1(2)}x_{i1(2)} + \hat{\beta}_{1(3)}x_{i1(3)} + \hat{\beta}_{2(1)}x_{i2(1)} + \hat{\beta}_3x_{i3} \quad (37)$$

を仮定し、その実際のデータ y_i からのずれの平方和

$$\begin{aligned} S_e^{(2)} &= \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ &= \frac{1}{n} \sum_{i=1}^n \left[y_i - \left(\hat{\beta}_0 + \hat{\beta}_{1(2)} x_{i1(2)} + \hat{\beta}_{1(3)} x_{i1(3)} + \hat{\beta}_{2(1)} x_{i2(1)} + \hat{\beta}_3 x_{i3} \right) \right]^2 \end{aligned} \quad (38)$$

を最小にすることを要請して $\hat{\beta}_0, \hat{\beta}_{1(1)}, \hat{\beta}_{1(2)}, \hat{\beta}_{2(1)}$ を求める。

$$\begin{pmatrix} \hat{\beta}_{1(2)} \\ \hat{\beta}_{1(3)} \\ \hat{\beta}_{2(1)} \\ \hat{\beta}_3 \end{pmatrix} = \begin{pmatrix} S_{1(2)1(2)}^{(2)} & S_{1(2)1(3)}^{(2)} & S_{1(2)2(1)}^{(2)} & S_{1(2)3}^{(2)} \\ S_{1(3)1(2)}^{(2)} & S_{1(3)1(3)}^{(2)} & S_{1(3)2(1)}^{(2)} & S_{1(3)3}^{(2)} \\ S_{2(1)1(2)}^{(2)} & S_{2(1)1(3)}^{(2)} & S_{2(1)2(1)}^{(2)} & S_{2(1)3}^{(2)} \\ S_{1(2)3}^{(2)} & S_{1(3)3}^{(2)} & S_{2(1)3}^{(2)} & S_{33}^{(2)} \end{pmatrix} \begin{pmatrix} S_{y1(2)}^{(2)} \\ S_{y1(3)}^{(2)} \\ S_{y2(1)}^{(2)} \\ S_{y3}^{(2)} \end{pmatrix} = \begin{pmatrix} -9.75 \\ -19.7 \\ 9.2 \\ -0.126 \end{pmatrix} \quad (39)$$

また $\hat{\beta}_0$ は

$$\hat{\beta}_0 = n \left[\bar{y} - \left(\hat{\beta}_{1(2)} \bar{x}_{1(2)} + \hat{\beta}_{1(3)} \bar{x}_{1(3)} + \hat{\beta}_{2(1)} \bar{x}_{2(1)} + \hat{\beta}_3 \bar{x}_3 \right) \right] = 89.0 \quad (40)$$

と求まる。

よって回帰式は

$$\begin{aligned} \hat{y} &= \hat{\beta}_0 + \hat{\beta}_{1(2)} x_{1(2)} + \hat{\beta}_{1(3)} x_{1(3)} + \hat{\beta}_{2(1)} x_{2(1)} + \hat{\beta}_3 x_3 \\ &= 89.0 - 9.75 x_{1(2)} - 19.7 x_{1(3)} + 9.2 x_{2(1)} - 0.126 x_3 \\ &= 89.0 + \begin{Bmatrix} 0 & \text{優の場合} \\ -9.75 & \text{良の場合} \\ -19.7 & \text{可の場合} \end{Bmatrix} + \begin{Bmatrix} 0 & \text{無所属の場合} \\ 9.2 & \text{所属の場合} \end{Bmatrix} - 0.126 x_3 \end{aligned} \quad (41)$$

となる。

1.5. 寄与率

前節でデータを回帰分析した。この回帰の精度を評価する。ここでは、式の表現を明確にするためにまず記号の表記を整備しておく。

ここでは一つのカテゴリに対して、そのカテゴリの水準数-1 個の変数が採用されている。ここでの評価はそのカテゴリ単位でなす必要がある。この点が重回帰分析と異なる。

データの表記に関して明確に定義しておく。

カテゴリは k で表す。今 p 個のカテゴリがあるとするため、

$$k = 1, 2, \dots, p \quad (42)$$

である。

各カテゴリの利用するデータ数を j で表す。カテゴリ k のデータ数は n_{kj} となる。つまり、カテゴリ水準が 3 つある場合は $n_{kj} = 2$ となる。

各データは i で表す。データ数が n 個であるとするから

$$i=1,2,\dots,n \quad (43)$$

である。

回帰の精度を評価するものとして、重相関係数が用いられる。それは、

$$R = \frac{\sum_{i=1}^n (y_i - \bar{y})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad (44)$$

で与えられる。寄与率は

$$R^2 = \frac{S_R^{(2)}}{S_{yy}^{(2)}} = \frac{S_{yy}^{(2)} - S_e^{(2)}}{S_{yy}^{(2)}} = 1 - \frac{S_e^{(2)}}{S_{yy}^{(2)}} \quad (45)$$

となる。

上で用いている分散は標本のものであるから、母集団と関連づけを考慮した不偏分散を用いた

$$R^{*2} = 1 - \frac{\frac{n}{\phi_e} S_e^{(2)}}{\frac{n}{\phi_T} S_{yy}^{(2)}} \quad (46)$$

も評価される。ただし $S_e^{(2)}$ の自由度 ϕ_e は

$$\phi_e = n - \left(\sum_{k=1}^p n_{kj} + 1 \right) \quad (47)$$

である。 $S_e^{(2)}$ の表式から明らかに、その中では変数の平均、目的変数の平均が表れる。したがって説明変数の数である $\sum_{k=1}^p n_{kj}$ に1を加えた数の制約条件があり、その分の自由度が減少する。

$S_{yy}^{(2)}$ には $\bar{y}$ が利用されているから自由度が一つ減る。すなわち

$$\phi_T = n - 1 \quad (48)$$

となる。この R^{*2} のことを自由度調整済寄与率という。

1.6. 説明変数の選択

重回帰分析の場合と同様、目的変数に対して効いている説明変数のみをモデルに含めたい、という要望がある。

データ数を増やすとそれがあまり効いてなくても一致の度合いはよくなる。変数を追加することが有効かどうかは変数追加前後の誤差分散の減少量が、追加後変数の誤差分散よりも大きいかどうかで判断する。

この説明変数の選択をするプロセスを検討する。これは基本的に重回帰分析と同じであるが、この場合特有のことも生じる。

【Step0】

まず定数項だけを考える。それをモデル Model0 とする。つまり回帰式

$$Y_0 = \bar{y} \quad (49)$$

である。これから、

$$S_{e(M0)}^{(2)} = S_{yy}^{(2)} = \frac{1}{n} \sum_{i=1}^n (y_i - Y_0)^2 \quad (50)$$

を評価する。

【Step1】

次のステップとして Model0 に $(x_{k(j)})$ の中でどの変数に取組むのがよいのかを検討する。

それを Model1 と呼ぶ。こ

一つの変数 x_i を取り込んだ回帰式

$$Y_{ki} = b_0 + \sum_{j=1}^{n_{kj}} b_{1kj} x_{k(j)i} \quad (51)$$

を定義し、対応する $b_0, b_{1kj=1}, b_{1kj=2}, b_{1kj=n_{kj}}$ を求める。

それに対応する分散

$$S_{ke(M1)}^{(2)} = \frac{1}{n} \sum_{i=1}^n (y_i - Y_{ki})^2 \quad (52)$$

を評価する。

y の分散 $S_{yy}^{(2)}$ と残差平方和 $S_e^{(2)}$ を考え、以下の分散比を評価する。

$$F_{0k} = \frac{(nS_{e(M0)}^{(2)} - nS_{ek(M1)}^{(2)}) / (\phi_{e(M0)} - \phi_{e(Mk1)})}{nS_{ek(M1)}^{(2)} / \phi_{e(Mk1)}} \quad (53)$$

は $F(\phi_T - \phi_{ek(M1)}, \phi_{ek(M1)})$ に従う。ただし、 ϕ_T 、 $\phi_{e(M1)}$ はそれぞれの自由度であり

$$\phi_{e(M0)} = n - 1 \quad (54)$$

$$\phi_{ek(M1)} = n - (n_{kj} + 1) \quad (55)$$

である。よって、これを全ての P セットの変数について評価する。推定確率 P として、

$$F_{0i} \geq F(\phi_{e(M0)} - \phi_{ek(M1)}, \phi_{ek(M1)}, P) \text{ のものがなければ定数でいく。解析はこれで終わる。}$$

$$F_{0k} \geq F(\phi_{e(M0)} - \phi_{ek(M1)}, \phi_{ek(M1)}, P) \text{ のものがあれば、その中から最大の変数を選択 } k = k_1 \text{ する。}$$

【Step2】

変数 $k = k_1$ の他にもう一つ変数 l を追加することの有効性を検討する。これを **Model2** と呼ぶ。

変数 x_{k_1} と残りの変数の一つ x_l 取り込んだ回帰式

$$Y_{li} = b_0 + \sum_{j=1}^{n_{k1j}} b_{1k1j} x_{k1(j)i} + \sum_{j=1}^{n_{lj}} b_{1lj} x_{l(j)i} \quad (56)$$

を定義し、対応する $b_0, b_{1k1j=1}, b_{1k1j=2}, \dots, b_{1k1j=n_{k1j}}, b_{2lj=1}, b_{2lj=2}, \dots, b_{2lj=n_{lj}}$ を求める。

それに対応する分散

$$S_{ek1l(M2)}^{(2)} = \frac{1}{n} \sum_{i=1}^n (y_i - Y_{k1li})^2 \quad (57)$$

を評価する。

さらに対応する分散比

$$F_{0k1l} = \frac{(nS_{ek1(M1)}^{(2)} - nS_{ek1l(M2)}^{(2)}) / (\phi_{ek1(M1)} - \phi_{ek1l(M2)})}{nS_{ek1l(M2)}^{(2)} / \phi_{ek1l(M2)}} \quad (58)$$

を評価する。ただし、

$$\phi_{ek1l(M2)} = n - (n_{k1j} + n_{lj} + 1) \quad (59)$$

である。これを全ての残りの $p-1$ 個の変数 l について評価する。

$$F_{0k1l} \geq F(\phi_{ek1(M1)} - \phi_{ek1l(M2)}, \phi_{ek1l(M2)}, P) \text{ のものがなければ 1 変数の Model 1 でいく。解析はこ}$$

れで終わる。

$$F_{0k1l} \geq F(\phi_{ek1(M1)} - \phi_{ek1l(M2)}, \phi_{ek1l(M2)}, P) \text{ のものがあれば、その中から最大の変数を選択 } l = l_2 \text{ す}$$

る。

【Step3】

変数 $k = k_1$ 、 $l = l_2$ の他にもう一つ変数 m を追加することの有効性を検討する。これを Model3 と呼ぶ。

変数 x_{k_1} 、 x_{l_2} と残りの変数の一つ x_m 取り込んだ回帰式

$$Y_{k_1 l_2 m i} = b_0 + \sum_{j=1}^{n_{k_1 j}} b_{1 k_1 j} x_{k_1(j)i} + \sum_{j=1}^{n_{l_2 j}} b_{2 l_2 j} x_{l_2(j)i} + \sum_{j=1}^{n_{m j}} b_{3 m j} x_{m(j)i} \quad (60)$$

を定義し、対応する $b_0, b_{1 k_1 j=1}, b_{1 k_1 j=2}, \dots, b_{1 k_1 j=n_{k_1 j}}, b_{2 l_2 j=1}, b_{2 l_2 j=2}, \dots, b_{2 l_2 j=n_{l_2 j}}, b_{3 m j=1}, b_{3 m j=2}, \dots, b_{3 m j=n_{m j}}$ を求め

る。それに対応する分散

$$S_{ek_1 l_2 m(M3)}^{(2)} = \frac{1}{n} \sum_{i=1}^n (y_i - Y_{k_1 l_2 m i})^2 \quad (61)$$

を評価する。

さらに分散比

$$F_{0 k_1 l_2 m} = \frac{\left(n S_{ek_1 l_2(M2)}^{(2)} - n S_{ek_1 l_2 m(M3)}^{(2)} \right) / \left(\phi_{ek_1 l_2(M2)} - \phi_{ek_1 l_2 m(M3)} \right)}{n S_{ek_1 l_2 m(M3)}^{(2)} / \phi_{ek_1 l_2 m(M3)}} \quad (62)$$

を評価する。ただし、

$$\phi_{ek_1 l_2 m(M3)} = n - (n_{k_1 j} + n_{l_2 j} + n_{m j} + 1) \quad (63)$$

である。これを全ての残りの $p-2$ 個の変数 m について評価する。推定確率を P として

$$F_{0 k_1 l_2 m} \geq F(\phi_{ek_1 l_2(M2)} - \phi_{ek_1 l_2 m(M3)}, \phi_{ek_1 l_2 m(M3)}, P) \text{ のものがなければ 2 変数の Model2 でいく。解析}$$

はこれで終わる。

$$F_{0 k_1 l_2 m} \geq F(\phi_{ek_1 l_2(M2)} - \phi_{ek_1 l_2 m(M3)}, \phi_{ek_1 l_2 m(M3)}, P) \text{ のものがあれば、その中から最大の変数 } m = m_3$$

を選択する。

この手順を最後の変数まで繰り返していく。

1.7. まとめ

この章のまとめをする。

数量化 I 類の検討をした。数量化 I 類は、重回帰分析で、説明変数がカテゴリーデータを含む場合にそうすればいいのかを示す解析である。