

2. 数量化Ⅱ類:判別分析

概要: 数量化Ⅱ類は、判別分析において説明変数にカテゴリーデータを含む場合である。ここではカテゴリーデータを数値変換する方法を示す。

キーワード:数量化Ⅱ類

2.1. 序

判別分析では、目的変数がカテゴリーデータで、説明変数が数値データであった。この説明変数にカテゴリーデータを含む場合がある。このような解析を数量化Ⅱ類と呼ぶ。ここでは、そのような場合にどうすればいいのかを議論する。

2.2. 説明変数が一個の場合の判別分析

まずは健常者とある疾病にかかっている患者に対する一種類の検査：吐き気に対するデータについて考える。

表 1 健常者、患者の吐き気に対する答え

No.	種類	吐き気(x1)
1	健常者	無し
2	健常者	少
3	健常者	無し
4	健常者	無し
5	健常者	無し
6	患者	少
7	患者	多
8	患者	少
9	患者	少
10	患者	多

表 2 健常者、患者の吐き気に対するダミー変数

No.	種類	x1(2)	x1(3)
1	健常者	0	0
2	健常者	1	0
3	健常者	0	0
4	健常者	0	0
5	健常者	0	0
6	患者	1	0
7	患者	0	1
8	患者	1	0
9	患者	1	0
10	患者	0	1

吐き気の場合は「多」、「少」、「無」の三つのカテゴリーデータになる。この質的変数に対して以下のようなダミー変数を定義する。

$$x_{1(2)} = \begin{cases} 1 & \text{for 少} \\ 0 & \text{for 少以外} \end{cases} \quad (1)$$

$$x_{1(3)} = \begin{cases} 1 & \text{for 多} \\ 0 & \text{for 多以外} \end{cases} \quad (2)$$

このダミー変数は質的変数の個数-1個を導入する。ここでの場合は「多」、「少」、「無」の三つであるから、二つを導入する。すると、下表のようになる。このデータに基づいて、変数が二つの場合の判別分析を形式的に適用する。

判別分析の場合は変数が正規分布に従っているということが前提であった。それに対してここではデータは 0 と 1 しかないから正規分布には従わない。このことに留意しておこう。

データの基本的な量を評価していく。

健常者データ

$$n^{[1]} = 5 \quad (3)$$

$$\hat{\mu}_{1(2)}^{[1]} = \bar{x}_{1(2)}^{[1]} = \frac{\sum x_{i1(2)}^{[1]}}{n^{[1]}} = \frac{0+1+0+0+0}{5} = \frac{1}{5} \quad (4)$$

$$\hat{\mu}_{1(3)}^{[1]} = \bar{x}_{1(3)}^{[1]} = \frac{\sum x_{i1(3)}^{[1]}}{n^{[1]}} = \frac{0+0+0+0+0}{5} = 0 \quad (5)$$

$$s_{(2)(2)}^{[1]2} = \frac{\sum (x_{i1(2)}^{[1]} - \bar{x}_{1(2)}^{[1]})^2}{n^{[1]} - 1} = \frac{(0-0.2)^2 + (1-0.2)^2 + (0-0.2)^2 + (0-0.2)^2 + (0-0.2)^2}{4} \quad (6)$$

$$s_{(3)(3)}^{[1]2} = \frac{\sum \left(x_{i(3)}^{[1]} - \bar{x}_{i(3)}^{[1]} \right)^2}{n^{[1]} - 1} = \frac{(0-0)^2 + (0-0)^2 + (0-0)^2 + (0-0)^2 + (0-0)^2}{4} \quad (7)$$

$$\begin{aligned} s_{(2)(3)}^{[1]2} &= \frac{\sum \left(x_{i(2)}^{[1]} - \bar{x}_{i(2)}^{[1]} \right) \left(x_{i(3)}^{[1]} - \bar{x}_{i(3)}^{[1]} \right)}{n^{[1]} - 1} \\ &= \frac{(0-0.2)(0-0) + (1-0.2)(0-0) + (0-0.2)(0-0) + (0-0.2)(0-0) + (0-0.2)(0-0)}{4} \end{aligned} \quad (8)$$

患者データ

$$n^{[2]} = 5 \quad (9)$$

$$\hat{\mu}_{i(2)}^{[2]} = \bar{x}_{i(2)}^{[2]} = \frac{\sum x_{i(2)}^{[2]}}{n^{[2]}} = \frac{1+0+1+1+0}{5} = \frac{3}{5} \quad (10)$$

$$\hat{\mu}_{i(3)}^{[2]} = \bar{x}_{i(3)}^{[2]} = \frac{\sum x_{i(3)}^{[2]}}{n^{[2]}} = \frac{0+1+0+0+1}{5} = \frac{2}{5} \quad (11)$$

$$s_{(2)(2)}^{[2]2} = \frac{\sum \left(x_{i(2)}^{[2]} - \bar{x}_{i(2)}^{[2]} \right)^2}{n^{[2]} - 1} = \frac{(1-0.6)^2 + (0-0.6)^2 + (1-0.6)^2 + (1-0.6)^2 + (0-0.6)^2}{4} \quad (12)$$

$$s_{(3)(3)}^{[2]2} = \frac{\sum \left(x_{i(3)}^{[2]} - \bar{x}_{i(3)}^{[2]} \right)^2}{n^{[2]} - 1} = \frac{(0-0.4)^2 + (1-0.4)^2 + (0-0.4)^2 + (0-0.4)^2 + (1-0.4)^2}{4} \quad (13)$$

$$\begin{aligned} s_{(2)(3)}^{[2]2} &= \frac{\sum \left(x_{i(2)}^{[2]} - \bar{x}_{i(2)}^{[2]} \right) \left(x_{i(3)}^{[2]} - \bar{x}_{i(3)}^{[2]} \right)}{n^{[2]} - 1} \\ &= \frac{(1-0.6)(0-0.4) + (0-0.6)(1-0.4) + (1-0.6)(0-0.4) + (1-0.6)(0-0.4) + (0-0.6)(1-0.4)}{4} \end{aligned} \quad (14)$$

これから、グループ 1,2 共通のパラメータは

$$\hat{\mu}_{i(2)} = \frac{\hat{\mu}_{i(2)}^{[1]} + \hat{\mu}_{i(2)}^{[2]}}{2} = \frac{0.2 + 0.6}{2} = 0.4 \quad (15)$$

$$\hat{\mu}_{i(3)} = \frac{\hat{\mu}_{i(3)}^{[1]} + \hat{\mu}_{i(3)}^{[2]}}{2} = \frac{0 + 0.4}{2} = 0.2 \quad (16)$$

$$\hat{\sigma}_{(2)(2)}^2 = \frac{\left(n^{[1]} - 1 \right) s_{(2)(2)}^{[1]2} + \left(n^{[2]} - 1 \right) s_{(2)(2)}^{[2]2}}{\left(n^{[1]} - 1 \right) + \left(n^{[2]} - 1 \right)} = 0.25 \quad (17)$$

$$\hat{\sigma}_{(3)(3)}^2 = \frac{(n^{[1]} - 1)s_{(3)(3)}^{[1]2} + (n^{[2]} - 1)s_{(3)(3)}^{[2]2}}{(n^{[1]} - 1) + (n^{[2]} - 1)} = 0.15 \quad (18)$$

$$\hat{\sigma}_{(2)(3)}^2 = \frac{(n^{[1]} - 1)s_{(2)(3)}^{[1]2} + (n^{[2]} - 1)s_{(2)(3)}^{[2]2}}{(n^{[1]} - 1) + (n^{[2]} - 1)} = -0.15 \quad (19)$$

これから以下の量が評価される。

$$\hat{\Sigma} = \begin{pmatrix} \hat{\sigma}_{(2)(2)} & \hat{\sigma}_{(2)(3)} \\ \hat{\sigma}_{(2)(3)} & \hat{\sigma}_{(3)(3)} \end{pmatrix} = \begin{pmatrix} 0.250 & -0.150 \\ -0.150 & 0.150 \end{pmatrix} \quad (20)$$

この逆行列は

$$\hat{\Sigma}^{-1} = \begin{pmatrix} \hat{\sigma}^{(2)(2)} & \hat{\sigma}^{(2)(3)} \\ \hat{\sigma}^{(2)(3)} & \hat{\sigma}^{(3)(3)} \end{pmatrix} = \begin{pmatrix} 10.00 & 10.00 \\ 10.00 & 16.67 \end{pmatrix} \quad (21)$$

となる。この線形判別関数の推定式は以下ようになる。

$$\begin{aligned} \hat{z} &= [\hat{\mu}_{l(2)}^{[1]} - \hat{\mu}_{l(2)}^{[2]}, \hat{\mu}_{l(3)}^{[1]} - \hat{\mu}_{l(3)}^{[2]}] \begin{pmatrix} \hat{\sigma}^{(2)(2)} & \hat{\sigma}^{(2)(3)} \\ \hat{\sigma}^{(2)(3)} & \hat{\sigma}^{(3)(3)} \end{pmatrix} \begin{pmatrix} x_{l(2)} - \hat{\mu}_{l(2)} \\ x_{l(3)} - \hat{\mu}_{l(3)} \end{pmatrix} \\ &= [0.20 - 0.60, 0 - 0.40] \begin{pmatrix} 10.00 & 10.00 \\ 10.00 & 16.67 \end{pmatrix} \begin{pmatrix} x_{l(2)} - 0.40 \\ x_{l(3)} - 0.20 \end{pmatrix} \\ &= 5.33 - 8.00x_{l(2)} - 10.67x_{l(3)} \\ &= 5.33 + \begin{cases} 0 & \text{無} \\ -8.0 & \text{少} \\ -10.67 & \text{多} \end{cases} \end{aligned} \quad (22)$$

この値に対して判別方式

$$\hat{z} \geq 0 \Leftrightarrow \bar{D}^{[1]2} \leq \bar{D}^{[2]2} \Leftrightarrow \text{母集団}[1](\text{健常者})\text{に属する} \quad (23)$$

$$\hat{z} < 0 \Leftrightarrow \bar{D}^{[1]2} > \bar{D}^{[2]2} \Leftrightarrow \text{母集団}[2](\text{患者})\text{に属する} \quad (24)$$

を適用する。

数量化Ⅱ類では、質的変数をダミー変数に変換している。そのダミー変数を量的変数として、形式的にマハラノビスの距離を求めている。ダミー変数は正規分布にしたがわないから、正規分布にもとづく判別の判断はできない。したがって、実際のもとのデータに適用し、その成否を判断する。

表 3 にスコアと判断結果を示す。それをまとめ直したものが表 4 である。

健常者に対する誤判別は 0.2、患者に対する誤判別は 0 である。

表 3 健常者、患者の吐き気に対するダミー変数とスコア

No.	種類	x1(2)	x1(3)	スコア	結果
1	健常者	0	0	5.33	健常者
2	健常者	1	0	-2.67	患者
3	健常者	0	0	5.33	健常者
4	健常者	0	0	5.33	健常者
5	健常者	0	0	5.33	健常者
6	患者	1	0	-2.67	患者
7	患者	0	1	-5.34	患者
8	患者	1	0	-2.67	患者
9	患者	1	0	-2.67	患者
10	患者	0	1	-5.34	患者

表 4 判別表

アンケート結果	判別結果		誤判別確率
	健常者	患者	
健常者	4	1	0.2
患者	0	5	0

2.3. 変数が二個以上の場合の判別分析

まずは健常者とある疾病にかかっている患者に対する二種類の検査：吐き気、頭痛に対するデータについて考える。

表 5 健常者、患者の吐き気、頭痛に関するデータ

No.	種類	吐き気(x1)	頭痛(x2)
1	健常者	無し	少
2	健常者	少	無し
3	健常者	無し	無し
4	健常者	無し	無し
5	健常者	無し	無し
6	患者	少	多
7	患者	多	無し
8	患者	少	少
9	患者	少	多
10	患者	多	少

吐き気の場合は「多」、「少」、「無」の三つのカテゴリーデータになる。この質的変数に対して以下のようなダミー変数を定義する。

$$x_{1(2)} = \begin{cases} 1 & \text{for 少} \\ 0 & \text{for 少以外} \end{cases} \quad (25)$$

$$x_{1(3)} = \begin{cases} 1 & \text{for 多} \\ 0 & \text{for 多以外} \end{cases} \quad (26)$$

同様に頭痛に対して次のようにダミー変数を定義する。

$$x_{2(2)} = \begin{cases} 1 & \text{for 少} \\ 0 & \text{for 少以外} \end{cases} \quad (27)$$

$$x_{2(3)} = \begin{cases} 1 & \text{for 多} \\ 0 & \text{for 多以外} \end{cases} \quad (28)$$

するとこれに対するダミー変数データは表 6 のようになる。

表 6 健常者、患者の吐き気、頭痛に関するダミー変数データ

No.	種類	x1(2)	x1(3)	x2(2)	x2(3)
1	健常者	0	0	1	0
2	健常者	1	0	0	0
3	健常者	0	0	0	0
4	健常者	0	0	0	0
5	健常者	0	0	0	0
6	患者	1	0	0	1
7	患者	0	1	0	0
8	患者	1	0	1	0
9	患者	1	0	0	1
10	患者	0	1	1	少

線形判別関数の推定式は次のようになる。

$$\begin{aligned}
\hat{z} &= (\hat{\mu}^{[1]} - \hat{\mu}^{[2]})^t \hat{\Sigma}^{-1} (x - \hat{\mu}) \\
&= 12.80 - 9.60x_{1(2)} - 20.80x_{1(3)} - 6.40x_{2(2)} - 14.40x_{2(3)} \\
&= 12.80 + \begin{Bmatrix} 0 & (\text{吐き気無}) \\ -9.60 & (\text{吐き気少}) \\ -20.80 & (\text{吐き気多}) \end{Bmatrix} + \begin{Bmatrix} 0 & (\text{頭痛無}) \\ -6.40 & (\text{頭痛少}) \\ -14.40 & (\text{頭痛多}) \end{Bmatrix}
\end{aligned} \quad (29)$$

これに対して判別方式

$$\hat{z} \geq 0 \Leftrightarrow \bar{D}^{[1]2} \leq \bar{D}^{[2]2} \Leftrightarrow \text{母集団}[1](\text{健常者})\text{に属する} \quad (30)$$

$$\hat{z} < 0 \Leftrightarrow \bar{D}^{[1]2} > \bar{D}^{[2]2} \Leftrightarrow \text{母集団}[2](\text{患者})\text{に属する} \quad (31)$$

を適用する。

2.4. 誤判別の確率

スコアおよび判別結果より判別表を作成して誤判別の確率を評価する。それは以下である。

表 7 判別表

データ結果	判別結果		計
	健常者	患者	
健常者	5	0	5
患者	0	5	5
計	5	5	10

2.5. 変数選択

まず、吐き気と頭痛のどちらの変数を取り入れるのかを検討する。吐き気だけを取り込んだ場合の F_0 の値は 8.168 であった。同様に頭痛だけを取り込んだ場合の F_0 の値は 2.466 となる。これらより、1 つだけ質的変数を取り込むのなら吐き気の方がよい。

次に吐き気を取り込んだ段階で、さらに頭痛を取り込む価値があるかどうかを検討する。

$$F_0 = \frac{(n^{[1]} + n^{[2]} - p - r - 1)n^{[1]}n^{[2]}\{\hat{D}_{x(p+r)}^2([1],[2]) - \hat{D}_{x(p)}^2([1],[2])\}}{r\{(n^{[1]} + n^{[2]} - 2)(n^{[1]} + n^{[2]}) + n^{[1]}n^{[2]}\hat{D}_{x(p)}^2([1],[2])\}} \quad (32)$$

$$\text{に } p=2, r=2, \hat{D}_{x(p)}^2([1],[2]) = \hat{D}_{x1(2)x1(3)}^2([1],[2]) = 7.468$$

$$\hat{D}_{x(p+r)}^2([1],[2]) = \hat{D}_{x1(2)x1(3)x2(2)x2(3)}^2([1],[2]) = 19.20 \text{ を代入して}$$

$$\begin{aligned} F_0 &= \frac{(5+5-2-2-1) \times 5 \times 5 \{19.20 - 7.468\}}{2\{(5+5-2)(5+5) + 5 \times 5 \times 7.468\}} \\ &= 2.749 \end{aligned} \quad (33)$$

となる。

これより、頭痛も判別方式に取り込む意味があることになる。

2.6. 変数に量的変数と質的変数が混在する場合の判別分析

データに量的変数と質的変数が混在している場合でも、質的変数をダミー変数に変換して同様な解析ができる。

表 8 健常者・患者のデータ

No.	種類	吐き気(x1)	頭痛(x2)	検査値1(x3)	検査値2(x4)
1	健常者	無し	少	50	15.5
2	健常者	少	無し	69	18.4
3	健常者	無し	無し	93	26.4
4	健常者	無し	無し	76	22.9
5	健常者	無し	無し	88	18.6
6	患者	少	多	43	16.9
7	患者	多	無し	56	21.6
8	患者	少	少	38	12.2
9	患者	少	多	21	16.0
10	患者	多	少	25	10.5

2.7. まとめ

この章のまとめをする。

判別分析は目的変数がカテゴリーデータで、説明変数が数値データである。数量化Ⅱ類では、この説明変数にカテゴリーデータが混じった場合にどうするかを議論した。