

4. 数量化 IV 類: 親近性分析

概要: 数値データでは、二つのデータの関連性を評価することができた。では、カテゴリデータとカテゴリデータの関係性はみれないのであろうか？それを解析するのが数量化 IV 類と呼ばれるものである。カテゴリのままでは、解析できないので、このカテゴリを数値化する。ここではカテゴリデータを数値変換する方法を示す。

キーワード: 数量化 IV 類

4.1. 序

n 個の対象があり、2 つずつのペアをつくりその間に親近性 r_{ij} を定義できるものとする。

下の表がそれに対応する。10 種類の自動車に対して互いの類似度を評価している。

数量化 IV 類はこの親近性にもとづいて対象に数値を与え、親近性の大きなペアは近くに、小さいペアは遠くにいくようにする。表の例でいうと、どの車とどの車が類似しているかを評価する。コレスポンデンス解析では、2 種類のデータの関連性を調べていた。しかし、この数量化 IV 類では、1 種類のデータの関連性を調べる。これは、カテゴリデータだから意味があるものとなる。

表 1 各種車の関連性

		1	2	3	4	5	6	7	8	9	10
		クラウン	セドリック	サニー	マークII	カローラ	スカイライン	マーチ	フィット	RAV4	パジェロ
1	クラウン	10									
2	セドリック	9	10								
3	サニー	6	7	10							
4	マークII	7	9	8	10						
5	カローラ	5	6	8	8	10					
6	スカイライン	2	3	6	3	6	10				
7	マーチ	2	3	5	4	7	6	10			
8	フィット	1	2	4	3	5	5	9	10		
9	RAV4	1	1	2	1	3	3	7	8	10	
10	パジェロ	2	3	3	4	5	2	5	5	4	10

4.2. 数量化

対象 i に与える数量を x_i とする。親近性 r_{ij} の大きいペアはその間のユークリッド平方距離が小さくなるようにする。

$$Q = - \sum_i \sum_{j(i \neq j)} r_{ij} (x_i - x_j)^2 \quad (1)$$

を最大にするように $\{x_i\}$ を定める。

Q を最大化するということは、以下のように解釈できる。

r_{ij} が親近性を表すとする、 $-r_{ij}$ は非親近性を表す。一方、対象 i と j に数値 x_i と x_j を与えるとき、これらの近さはユークリッドの平方距離 $(x_i - x_j)^2$ となる。対象間の相違度をはかる 2 種類の測度 $-r_{ij}$ 、 $(x_i - x_j)^2$ のベクトルで表現し、その内積が Q になる。つまり、非親近性 $\{-r_{ij}\}$ ともっともよく対応する $\{x_i\}$ を求めることを意味する。ここで、 $\{x_i\}$ の分散が 1 になるという制約をつけ、大きさの任意性を制限する。つまり、

$$\begin{aligned} S^{(2)} &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= \frac{1}{n} \sum_{i=1}^n x_i^2 - \frac{1}{n^2} \left(\sum_{i=1}^n x_i \right)^2 \\ &= 1 \end{aligned} \quad (2)$$

ここで Lagrange の未定乗数法を用いて

$$L = -\sum_i \sum_{j(i \neq j)} r_{ij} (x_i - x_j)^2 - \lambda \left\{ \frac{1}{n} \sum_{i=1}^n x_i^2 - \frac{1}{n^2} \left(\sum_{i=1}^n x_i \right)^2 \right\} \quad (3)$$

となる。これを x_i で偏微分して

$$\begin{aligned} \frac{\partial L}{\partial x_i} &= -2 \sum_j \sum_{j(i \neq j)} r_{ij} (x_i - x_j) - \lambda \left\{ 2 \frac{1}{n} x_i - \frac{2}{n^2} \sum_{i=1}^n x_i \right\} \\ &= -2 \sum_j (r_{ij} + r_{ji}) (x_i - x_j) - \lambda \left\{ \frac{2}{n} x_i - \frac{2}{n^2} \sum_{i=1}^n x_i \right\} \\ &= 0 \end{aligned} \quad (4)$$

となる。原点は任意に取ることができるため、 $\bar{x} = 0$ 、すなわち

$$\frac{1}{n} \sum_{i=1}^n x_i = 0 \quad (5)$$

とすると、

$$\sum_j (r_{ij} + r_{ji}) x_j - \left\{ \frac{\lambda}{n} + \sum_j (r_{ij} + r_{ji}) \right\} x_i = 0 \quad (6)$$

となる。ここで、

$$h_{ij} = h_{ji} = r_{ij} + r_{ji} \quad (7)$$

$$\mu = \frac{\lambda}{n} \quad (8)$$

とおくと

$$\sum_j h_{ij} x_j - \left\{ \mu + \sum_j h_{ij} \right\} x_i = 0 \quad (9)$$

となる。

r_{ij} にどんな値が入っても数量化の基準 Q は変わらないから、

$$\sum_j h_{ij} = \sum_j (r_{ij} + r_{ji}) = 0 \quad (10)$$

を満足するように、 r_{ii} を定めることにする。すなわち

$$h_{ii} = \sum_{j \neq i} h_{ij} \quad (11)$$

とする。すると

$$\sum_j h_{ij} x_j - \mu x_i = 0 \quad (12)$$

となる。これは H_{ij} の固有値問題に帰着する。上の式に x_i をかけて和をとると

$$\mu = \frac{\sum_i \sum_j h_{ij} x_i x_j}{\sum_i x_i^2} = \frac{Q}{n} \quad (13)$$

となる。

求める数量は $\{x_i\}$ は固有値問題の最大固有値に対する固有ベクトルの要素を用いる。

上の式で i に関する和をとると

$$\sum_i \sum_j h_{ij} x_j - \mu \sum_i x_i = 0 \quad (14)$$

となる。これより

$$\mu \sum_i x_i = \sum_j \left(\sum_i h_{ij} \right) x_j = 0 \quad (15)$$

を得る。

この解析は容易に多次元化できる。第二固有値、固有ベクトルまでとり、それを 2 次元平面上にプロットすればいい。

二つの項目の距離は、第一固有値、固有ベクトル、第二固有値、固有ベクトルをそれぞれ $\mu^{(1)}, x_i^{(1)}$ 、 $\mu^{(2)}, x_i^{(2)}$ とすると、項目 i と j の距離（親近性）は距離 d_{ij}

$$d_{ij} = \sqrt{\frac{\mu^{(1)}}{\mu^{(1)} + \mu^{(2)}} [x_i^{(1)} - x_j^{(1)}]^2 + \frac{\mu^{(2)}}{\mu^{(1)} + \mu^{(2)}} [x_i^{(2)} - x_j^{(2)}]^2} \quad (16)$$

で評価できる。

4.3. まとめ

この章のまとめをおこなう。

1 種類のカテゴリーデータの類似性を調べる数量化 IV 類の方法を示した。