

2. 独立係数解析

概要: ここでは、目的変数と複数の説明変数からなる独立係数解析を紹介する。前章で扱ったCS分析では目的変数と説明変数は数値データであった。独立係数解析は、そのデータがカテゴリーの場合である。この解析もCS分析同様に目的変数を向上させるためには、どの説明変数(Item:項目)を向上させればいいのかを示す。独立係数解析の場合は、説明変数の各水準に対して調整残差が定義される。それは、その水準が目的変数に対してどれだけ重要かを表す指標である。これから、目的を達成するための説明変数の水準を選択し、選択した水準から達成率を定義する。独立係数解析においては、目的変数と説明変数の関連を表す独立係数が大きく、各項目の達成率が低い説明変数が選択される。

キーワード:説明変数;目的変数;カテゴリーデータ;独立値;独立係数;調整残差;達成率;CS分析;CS相関係数

2.1. 序

レストランに客を集客したいという要望がある。すなわち、来客数を増やしたい。そのためには、何をすればいいのか考える。来客数を増やすには、メニューの充実、接客態度などがあげられる。来客数を目的変数、メニュー、接客態度を目的変数にすればいいことが分かる。

この章では、図1に示すように、一つの目的変数と複数の説明変数からなるデータを扱う。このデータ形式はCS分析と全く同じである。しかし、データの形式は全てカテゴリーである。データの値は、カテゴリーの水準の個数である。数値データの場合は、水準は1,2,3,...のようなものであった。カテゴリーデータの場合は、高い、低いなどになる。カテゴリーデータの水準には、2種類ある。高い、低いのようなカテゴリーの水準は、その水準に順番がある。一方、A社、B社、C社のような水準には順番がない。数値データの場合は、自動的にデータの順番には意味があった。後者のようにデータの水準に順番がないのはカテゴリーデータ特有のものとなる。このため、独立係数解析の場合は、調整残差というパラメータが新たに出現する。これは、目的を達成するためには、説明変数の水準は何であるべきかを示すものである。

ここで、数値データについて議論しておく。数値データの場合は前述のように、水準は1,2,3,...のようなものであった。これらを使って分析する場合、実際はこの数値の線形性を仮定している。つまり、2は1の2倍、3は1の3倍という仮定をしている。このような仮定はあることをやった、やらないというような場合は正しいと考えられる。しかし、いいと

思うか悪いと思うかのように感性を数値化する場合はその仮定が成り立たない場合が多い。このような場合は、数値データであるが、それをカテゴリーとして扱う方がいい場合がある。ここでは、カテゴリーデータを扱う独立係数解析を紹介する。




図 1 独立係数の扱うデータの構造

2.2. 項目選択の定性的説明

前節で述べたように項目の選択は目的変数と説明変数の関連性と、説明変数の満足度から選択される。このことについてさらに議論をする。データの関連性、満足度は前章の数値データとは定義は異なるが、同じように対応するものを評価している。それぞれの求め方はこの章で後に議論する。

まず、変数には目的変数と説明変数があった。我々の目標は目的変数を向上させることである。しかし、やる行為は説明変数を向上させることである。したがって、説明変数を向上させることが、目的変数を向上させることにつながるかどうかを知ることがまず必要である。

そこで、まず説明変数と目的変数の関係性を確認する。この場合は説明変数の状態は気にしない。説明変数の状態が悪い場合、目的変数の状態も悪く、説明変数の状態が良い場合、目的変数の状態も良いかをチェックする。そうなっていれば、説明変数を向上させることは意味があるし、そうなっていなければ、説明変数を向上させることは意味がないということになる。

第一ステップの関係性をチェックした後、説明変数の状態を議論する。

第一ステップでは目的変数と説明変数の関連性を判断する。その関係性が弱ければ、その説明変数の状態がどうあろうと関係がない、ということになる。

その関係性が強いと判断された説明変数の状態が悪ければ、それを向上させることは意味がある。その説明変数の状態が良ければそれに取り組む必要はない。

独立係数分析に適用させた CS 分析では、以上の説明変数の関係性、すなわち重要度とそのものの状態値の二つを考慮してどれに取り組むべきかを判断する。

ここで、留意すべきことがある。この解析においては、目的変数と説明変数の関係に注目している。しかし、説明変数間の関係には注目していない。すなわち、これらの解析においては、説明変数間の関連性は無視している。つまり、説明変数は互いに独立であることを暗に仮定していることになる。

2.3. アンケート項目

ここでは、1つの目的変数と5個の説明変数を扱う。目的変数 y は顧客の満足度とする。

5個の説明変数 x (Item1~5)は以下とする。オリジナルデータは全て1~5の数値データとする。

- ◆ Item1(x_1):顧客の仕事の理解
- ◆ Item2(x_2):顧客の質問に対する対応
- ◆ Item3(x_3):プロジェクト推進力
- ◆ Item4(x_4):情報提供力
- ◆ Item5(x_5):施策設定力

ここでの解析は、顧客の満足度を上げるためには、どの説明変数に取り組めばいいのかを示すことを目的とする。

2.4. 単純集計

得られたデータを単純集計する。目的変数の平均、分散を μ_y 、 $\sigma_{yy}^{(2)}$ 、説明変数 i の平均、

分散を μ_{x_i} 、 $\sigma_{xx_i}^{(2)}$ とすると、それらは

$$\mu_y = \frac{1}{n} \sum_{k=1}^n y_k \quad (1)$$

$$\sigma_{yy}^{(2)} = \frac{1}{n-1} \sum_{k=1}^n (y_k - \mu_y)^2 \quad (2)$$

$$\mu_{x_i} = \frac{1}{n} \sum_{k=1}^n x_{ik} \quad (3)$$

$$\sigma_{xx_i}^{(2)} = \frac{1}{n-1} \sum_{k=1}^n (x_{ik} - \mu_{x_i})^2 \quad (4)$$

となり、規格化値は

$$z_{yk} = \frac{y_k - \mu_y}{\sqrt{\sigma_{yy}^{(2)}}} \quad (5)$$

$$z_{xik} = \frac{x_{ik} - \mu_{x_i}}{\sqrt{\sigma_{xx_i}^{(2)}}} \quad (6)$$

となる。ここで、 n はデータの個数である。

相関係数に関しては CS 分析の章で議論した。相関係数は、この解析では利用しないが以下の二つがある。

まず、目的変数と説明変数間の相関係数は

$$r_{yi} = \frac{\sigma_{yi}^{(2)}}{\sqrt{\sigma_{yy}^{(2)} \sigma_{xx_i}^{(2)}}} \quad (7)$$

である。ただし、

$$\sigma_{yi}^{(2)} = \frac{1}{n-1} \sum_{k=1}^n (y_k - \mu_y)(x_{ik} - \mu_{x_i}) \quad (8)$$

である。

説明変数間の相関係数は

$$r_{ij} = \frac{\sigma_{ij}^{(2)}}{\sqrt{\sigma_{xx_i}^{(2)} \sigma_{xx_j}^{(2)}}} \quad (9)$$

となる。ただし

$$\sigma_{ij}^{(2)} = \frac{1}{n-1} \sum_{k=1}^n (x_{ik} - \mu_{x_i})(x_{jk} - \mu_{x_j}) \quad (10)$$

である。

ここで、述べておくべきことは、説明変数と目的変数の相関係数は大きく、説明変数間の相関係数は小さいことが望ましい、ということである。後者は、先に述べた説明変数は互いに独立であることをこの解析では仮定していることに起因する。

2.5. データのカテゴリ化の意義

まだ正規の算数教育を受けていない小学 1 年生は対数的感覚であるが、正規の算数教育を受けると線形感覚になっていく。

同じような試験を数が 5 以上数えられない部族に対しておこなうと、対数的感覚になるという。

われわれは、この対数感覚から抜け出せていないことが多い。

金持を考えよう。我々は 1 千万以下の給料の人に対してはその数値に敏感であるが、以

上の金持ちが年収 10 億だろうが、20 億だろうがあまり感覚はない。つまり、100 万と 200 万には敏感であるが、10 億と 20 億の違いには鈍感になってくる。つまり、我々の感覚は対数であることが多い。

何故われわれの感覚は、この対数的であることが多いのだろうか？

敵が 100m 先と 200m 先に一人ずついるとしよう。

敵の数は 2 であるが、一人目の敵の方が自分にとっては脅威である。対数的な感覚は自分の身を守るために必要なことである。




図 2 実際と感覚。

ギリシャの天文学者ヒッパルコスが夜空で最も明るい星を 1 等星、次に明るい星を 2 等星、確認できる限界の星の明るさを 6 等星とした。その後、光の量を定量的に評価することができるようになった。すると、等級と光の量の関係は $Q(n) = (\sqrt[n]{100})^{-n+1} Q_1$ の関係にあることがわかった。

また、Cocos はカレーチェーン店で有名であるが、その中のカレーの辛さに 1 辛、2 辛、3 辛がある。辛さは辛さ成分カプサイシンの量できまると言われているが、この辛さは $Q(n) = 2^{n-1} Q_1$ であることが知られている。

以上より、人の感覚を数値化した場合、その値は線形でない場合が多いことが知られて

いる。つまり、人の感覚は差ではなく、比に従うことが多い。

やった、やらないの客観的なデータではなく、いいと思うか、悪いと思うかのデータの場合、それは線形性を仮定できる数値データであるとみなさない方がいい場合が多い。

2.6. アンケート評点のカテゴリーデータ化

我々は 350 人の顧客データを扱う。つまり、データの個数 n は 350 である。

アンケートデータの場合は、序で指摘したように数値データをカテゴリー化することが有力である。アンケートの数値は人の感覚を数値にしたもので、それは一般に線形に推移しない。つまり、数値の値が 2 倍であることは、実際にその項目の何かが 2 倍になっていることを意味しない。したがって、カテゴリー化は一つの方策である。このようにデータは数値でも、実際は感覚を数値化している場合が多い。このような場合、目的変数としては、どの数値以上を実現したいかをえいやで決め、上に述べたように数値データをカテゴリー化するしかない。説明変数は、カテゴリー化した目的変数をもとに、どの水準の評価を得ればいいのか、を変換せずに評価できる。つまり、感覚で区切るのは目的変数だけであり、あとは解析で区切りの位置を設定できる。このことは、調整残差の章の後で再び議論する。

ここでは、まず簡単化のために目的変数、説明変数ともにえいやで区切る操作をする。

まず、数値データをカテゴリーデータに変換する。ここでは、数値データ 4,5 は high、1,2,3 は low とする（表 1）。（この水準数はいくらでもかまわない）すると、もとのデータは表 2 のように変形される。

表 1 アンケート項目と変数

Variable	Nonation	ItemNo	Questionary	Score
Objective	y		Customer satisfaction	high/low
Explanatory	x_1	Item1	Understanding of customer work	high/low
	x_2	Item2	Quality of reply for customers' request	high/low
	x_3	Item3	Project promotion ability	high/low
	x_4	Item4	Effective information providing ability	high/low
	x_5	Item5	Proposal ability	high/low

表 2 独立係数評価のためのデータ

ID	Item1(x_1)	Item2(x_2)	Item3(x_3)	Item4(x_4)	Item5(x_5)	y
1	high	high	high	high	high	low
2	high	low	low	low	low	low
3	low	low	low	low	low	low
4	high	high	high	high	high	high
5	high	high	high	high	high	low
6	low	low	low	low	low	low
7	high	high	high	high	high	high
8	high	low	low	low	low	low
9	low	low	low	low	low	low
10	low	low	low	low	low	low
11	high	high	high	high	high	high
12	low	low	low	low	low	low
13	low	low	low	low	low	low
14	low	high	low	low	low	low
15	high	low	low	low	low	low
16	low	low	low	low	low	low
17	high	high	high	high	high	high
18	high	low	low	low	low	low
19	high	high	low	high	low	low
20	high	high	low	low	low	low
21	high	high	low	high	low	low

すると、1 つの Item 毎に表 3 のようなデータが得られる。

このデータを解釈することを試みる。

このクロス集計表の i -th 行 j -th 列の個数データを x_{ij} と表す。したがって、この場

合は

$$\begin{cases} x_{11} = 188 \\ x_{12} = 33 \\ x_{21} = 33 \\ x_{22} = 96 \end{cases} \quad (11)$$

となる。この表のことをクロス集計表と呼ぶ。

表 3 Item1 に対するクロス集計表と各水準の比率

	Score	y		sum	Item1 levle ratio k_i
		high	low		
Item1	high	188	33	221	0.63
	low	33	96	129	0.37
	sum	221	129	350	
	y level ratio r_j	0.63	0.37		

2.7. 独立値

クロス集計表から独立値をどうやって求めていくかを示す。

まず、Item 1 の各水準に対応する独立比 k_i を求める。まず、Item1 の high の水準を考える。目的変数である y の水準の high と low の合計を求め、そのトータルの数に対する比を k_1 とする。Item1 の low の水準に対して同様に k_2 を求める。これらは、 y の値に依存しない比率と考えることができる。

次に目的変数 y に関する独立比 r_j を求める。まず、 y の high の水準を考える。Item1 の high と low の合計を求め、そのトータルの数に対する比を r_1 とする。 y の low の水準に対して同様に r_2 を求める。これらは、Item1 の値に依存しない比率と考えることができる。これらの評価したものを表 3 に示す。

セル (i, j) に対する独立値を a_{ij} とし、それを以下のように定義する。

$$a_{ij} = k_i r_j N \quad (12)$$

ここで、 N は全データ数である。もしも、目的変数 y と Item1 が無関係であれば、実際の値はこの値になるはずである。表 4 はこの独立値を示している。

表 4 Item1 の独立値.

	Score	y	
		high	low
Item1	high	139.55	81.45
	low	81.45	47.55

この独立比の積の和は

$$\begin{aligned}
\sum_{i=1}^m \sum_{j=1}^l k_i r_j &= \sum_{i=1}^m k_i \left(\sum_{j=1}^l r_j \right) \\
&= \sum_{i=1}^m k_i \\
&= 1
\end{aligned} \tag{13}$$

と期待通り 1 になる。つまり、独立値の総和は N になる。

2.8. 依存性の検定

もしもデータが完全に独立値となれば、それは明らかに依存性がないと判定できる。しかし、実際のデータは一般に独立値とは異なる。実際の値は確率変数であるから、データを取得するたびに違う値を取る。したがって、データが独立である場合でも、そのバラツキから独立値と実際のデータは一般に異なる。したがって、目的変数と説明変数は本当は独立であっても、実際のデータでは依存性があるように見えるものが得られる。そこで、実際のデータ値の違いが、独立であったとしても生じる範囲内のものであるのかどうか判断する必要がある。それが、検定であり、以下のように評価する。

我々は独立値 a_{ij} の値を知っている。また、対応する実際のデータ x_{ij} も知っている。これから

$$\begin{aligned}
\chi^2 &= \sum_{i=1}^l \sum_{j=1}^m \frac{(x_{ij} - a_{ij})^2}{a_{ij}} \\
&= \sum_{i=1}^l \sum_{j=1}^m \chi_{ij}^2
\end{aligned} \tag{14}$$

を評価することができる。ただし、

$$\chi_{ij}^2 = \frac{(x_{ij} - a_{ij})^2}{a_{ij}} \tag{15}$$

である。これは自由度 $(l-1)(m-1)$ の χ^2 分布に従う。

表 3 のセル(1,1) 対応する χ_{11}^2 は

$$\begin{aligned}
\chi_{11}^2 &= \frac{(188 - 139.55)^2}{139.55} \\
&= 16.6
\end{aligned} \tag{16}$$

となる。全ての和は

$$\begin{aligned}
\chi^2 &= \chi_{11}^2 + \chi_{12}^2 + \chi_{21}^2 + \chi_{22}^2 \\
&= \frac{(188-139.55)^2}{139.55} + \frac{(33-81.45)^2}{81.45} + \frac{(33-81.45)^2}{81.45} + \frac{(96-47.55)^2}{47.55} \\
&= 123.85
\end{aligned} \tag{17}$$

これは、一般的に以下のように表現される。

$$\chi^2 = \sum_i \sum_j \chi_{ij}^2 \tag{18}$$

$$\begin{aligned}
\chi_{ij}^2 &= \frac{(x_{ij} - a_{ij})^2}{a_{ij}} \\
&= \left(\frac{x_{ij} - a_{ij}}{\sqrt{a_{ij}}} \right)^2
\end{aligned} \tag{19}$$

これが、独立であった場合の実際のデータとの差として期待される量となる。理想的には 0 であり、確率的にはこれが小さければ、独立値とみなすことができる。

この χ^2 は、 χ^2 分布に従う。自由度 ϕ の χ^2 分布は

$$f_{\phi}(x) = \frac{1}{2^{\frac{\phi}{2}} \Gamma\left(\frac{\phi}{2}\right)} x^{\frac{\phi-2}{2}} \exp\left(-\frac{x}{2}\right) \tag{20}$$

である。これを図 3 に示す。 χ^2 分布は非対称であるが、自由度が増加するに従って、なだらかになり、かつ対称性も良くなる。




図 3 自由度 ϕ の χ^2 分布

片側推定確率を P とすると、それに対応する P 値である χ_c^2 は

$$\int_0^{\chi_c^2} f_\phi(x) dx = \frac{1}{2^{\frac{\phi}{2}} \Gamma\left(\frac{\phi}{2}\right)} \int_0^{\chi_c^2} x^{\frac{\phi-2}{2}} \exp\left(-\frac{x}{2}\right) dx = P \quad (21)$$

から、求まる。この場合の推定確率は、分布が非対称なため、上の式で定義されるように常に片側確率となる。

この変数の自由度を考える。

目的変数、説明変数の水準数をそれぞれ m および l とする。それぞれの水準に対応する確率は足して 1 となるようになっている。すなわち

$$\begin{cases} r_i = \frac{1}{N} \sum_{j=1}^m x_{ij} \\ k_j = \frac{1}{N} \sum_{i=1}^l x_{ij} \end{cases} \quad (22)$$

として、

$$\begin{cases} \sum_{i=1}^l r_i = 1 \\ \sum_{j=1}^m k_j = 1 \end{cases} \quad (23)$$

としている。

したがって、その自由度はそれぞれ水準数から 1 引いたものとなっている。以上より χ^2 の自由度 ϕ は

$$\phi = (m-1)(l-1) \quad (24)$$

である。ここでの例では、 $m=2$ および $l=2$ である。対応する自由度 ϕ は

$$\begin{aligned} \phi &= (m-1)(l-1) \\ &= (2-1)(2-1) \\ &= 1 \end{aligned} \quad (25)$$

である。推定確率 $P=0.95$ とすると、対応する P 値は

$$\chi_c^2 = 3.84 \quad (26)$$

となる。したがって、

$$\chi^2 > \chi_c^2 \quad (27)$$

となれば、二つの変数、つまり目的変数と解析している項目とは関連性がある、と言える。そうでない場合は関連性があるとは言えない。

検定に関しては、関連する章で詳細に議論する。ここでは、この検定でやっていることを簡単に説明する。

この検定においては関連性がないと仮定して、解析をすすめている。関連性がある場合、つまり仮説が否定される場合は、はっきり関連性があると結論付けられる。関連性がない場合、つまり仮定が肯定される場合は、関連性があるとは言えないと曖昧に言えるに過ぎない。つまり、関連性があるとは言えない、の内容には二つある。本当は関連性があるかもしれないが、このデータでは誤差が大き過ぎてあるとは言えない場合と、本当に関連性がない場合である。この両者をこのデータから区別はできない。

このように検定においては、立てた仮説が否定された場合にのみ、はっきり結論づけることができる。そのため、この立てた仮説は帰無仮説と呼ばれる。

2.9. 独立係数

前節の検定では、目的変数と各項目の関連性の有無を調べた。関連性のある場合、その関連性の強さを評価したい。それ判定には χ^2 の値を利用する。 χ^2 の値が大きければ、関連

性が強く、小さければ関連性が弱い、ということと言える。あとは、それを定量的に議論したい。 χ^2 の値はデータ数が増えれば大きくなる。つまり、データ数に依存する。したがって、その値だけで依存性が評価できない。

そこで、あるデータ数が与えられた場合、 χ^2 の値の最小値と最大値を評価する。この最大値を使って、関連性を表す独立係数を評価する。

ここでは、実際のデータというよりも、解析のしくみを考えるための議論をする。そのため、ここでは、議論を明確にするためにこれまでと違う水準数の多い例題を扱う。

中華料理、日本料理、フランス料理の年代別嗜好を議論する。料理は中華料理、日本料理、フランス料理の3種類、年代は20から60代の5種類を考える。各年代はどの種類の料理を好きなのか、を解析する。トータルの人数を500とする。

χ^2 の最小値を考える。

年代の構成比と料理嗜好の比率を表があるとする。これから、対応する人数はそれぞれの比率を掛けたものに全体の人数をかけたものになる。実際のデータがこれと同じであり、

χ^2 は0になる。したがって、 χ^2 の最小値は0である。

表 5 年代と料理種類の比率の設定

		Dish			Age ratio
		Chinese	Japanese	French	
Age	mid-20				0.2
	mid-30				0.3
	mid-40				0.4
	mid-50				0.3
	mid-60				0.2
Dish ratio		0.5	0.2	0.3	1

表 6 年代と料理種類に対する独立値

		Dish			Age ratio
		Chinese	Japanese	French	
Age	mid-20	50	20	30	0.2
	mid-30	75	30	45	0.3
	mid-40	100	40	60	0.4
	mid-50	75	30	45	0.3
	mid-60	50	20	30	0.2
Dish ratio		0.5	0.2	0.3	1

次に、 χ^2 の最大値を求める。最大値は、その比を満足した状態で、独立値からできるだけ大きくはずれた場合である。それは、縦の列、または横の行で一つのセルのみが値を持つ場合である。その例を表 7 に示す。対応する独立値を表 8 に示す。対応する χ^2 は 1000 となる。

表 7 偏ったデータ

		Dish			Age ratio
		Chinese	Japanese	French	
Age	mid-20	100	0	0	0.2
	mid-30	0	200	0	0.4
	mid-40	0	0	200	0.4
	mid-50	0	0	0	0
	mid-60	0	0	0	0
Dish ratio		0.2	0.4	0.4	1

表 8 表 7 に対応する独立値

		Dish			Age ratio
		Chinese	Japanese	French	
Age	mid-20	20	40	40	0.2
	mid-30	40	80	80	0.4
	mid-40	40	80	80	0.4
	mid-50	0	0	0	0
	mid-60	0	0	0	0
Dish ratio		0.2	0.4	0.4	1

χ^2 の最大値の一般解を得たい。したがって、変数 a , b , および c を表 9 のように設定する。対応する独立値は表 10 に示す。

表 9 χ^2 が最大になるクロス集計表

		Dish			Age ratio
		Chinese	Japanese	French	
Age	Mid-20	a	0	0	$\frac{a}{N}$
	Mid-30	0	b	0	$\frac{b}{N}$
	Mid-40	0	0	c	$\frac{c}{N}$
	Mid-50	0	0	0	0
	Mid-60	0	0	0	0
Dish ratio		$\frac{a}{N}$	$\frac{b}{N}$	$\frac{c}{N}$	1

表 10 χ^2 が最大になる場合の独立値

		Dish			Age ratio
		Chinese	Japanese	French	
Age	Mid-20	$\frac{a^2}{N^2} N$	$\frac{ab}{N^2} N$	$\frac{ac}{N^2} N$	$\frac{a}{N}$
	Mid-30	$\frac{ba}{N^2} N$	$\frac{b^2}{N^2} N$	$\frac{bc}{N^2} N$	$\frac{b}{N}$
	Mid-40	$\frac{ca}{N^2} N$	$\frac{cb}{N^2} N$	$\frac{c^2}{N^2} N$	$\frac{c}{N}$
	Mid-50	0	0	0	0
	Mid-60	0	0	0	0
Dish ratio			$\frac{b}{N}$	$\frac{c}{N}$	1

この場合の χ^2 は以下のように与えられる。

$$\begin{aligned}
\chi^2 &= \frac{\left(a - \frac{a^2}{N}\right)^2}{\frac{a^2}{N}} + \frac{\left(\frac{ab}{N}\right)^2}{\frac{ab}{N}} + \frac{\left(\frac{ac}{N}\right)^2}{\frac{ac}{N}} \\
&\quad + \frac{\left(\frac{ba}{N}\right)^2}{\frac{ba}{N}} + \frac{\left(b - \frac{b^2}{N}\right)^2}{\frac{b^2}{N}} + \frac{\left(\frac{bc}{N}\right)^2}{\frac{bc}{N}} \\
&\quad + \frac{\left(\frac{ca}{N}\right)^2}{\frac{ca}{N}} + \frac{\left(\frac{cb}{N}\right)^2}{\frac{cb}{N}} + \frac{\left(c - \frac{c^2}{N}\right)^2}{\frac{c^2}{N}} \\
&= \frac{\left(a - \frac{a^2}{N}\right)^2}{\frac{a^2}{N}} + \frac{\left(b - \frac{b^2}{N}\right)^2}{\frac{b^2}{N}} + \frac{\left(c - \frac{c^2}{N}\right)^2}{\frac{c^2}{N}} + \frac{2}{N}(ab + bc + ca)
\end{aligned} \tag{28}$$

最初の項は以下のように変形される。

$$\begin{aligned}
\frac{\left(a - \frac{a^2}{N}\right)^2}{\frac{a^2}{N}} &= N \left(\frac{a - \frac{a^2}{N}}{a} \right)^2 \\
&= N \left(1 - \frac{a}{N} \right)^2 \\
&= N \left(1 - 2\frac{a}{N} + \frac{a^2}{N^2} \right) \\
&= N - 2a + \frac{a^2}{N}
\end{aligned} \tag{29}$$

他の項も同様に計算されて、

$$\begin{aligned}
\chi^2 &= 3N - 2(a + b + c) + \frac{a^2 + b^2 + c^2}{N} + \frac{2}{N}(ab + bc + ca) \\
&= 3N - 2N + \frac{a^2 + b^2 + c^2 + 2(ab + bc + ca)}{N} \\
&= 3N - 2N + \frac{(a + b + c)^2}{N} \\
&= 2N
\end{aligned} \tag{30}$$

となる。ここで、 χ^2 は a , b , および c を含んでいない、ということに注目しよう。これは、いかなる a , b , および c でも用いることができるということである。ただし、

$$a + b + c = N \tag{31}$$

である。

表 9 が χ^2 の最大値を与える、と仮定していた。それをこれから証明する。

表 9 において、 $a \rightarrow a - \Delta$ とし、 Δ を隣のセルに移すことを考える。移すのであるから Δ は正である。その結果を表 11 に示す。この変形で χ^2 は減少することを示せばいい。

この変形されたものに対応する独立値を表 12 に示す。ここで、 χ^2 がいかなる Δ を用いても減少することを示せばいい。

導出の過程で、我々は Δ の 2 次の項は無視する。それは、もともと小さな量と仮定しているから問題ない。

表 11 χ^2 が最大になる表の変形

		Dish			Age ratio
		Chinese	Japanese	French	
Age	Mid-20	$a - \Delta$	Δ	0	$\frac{a}{N}$
	Mid-30	0	b	0	$\frac{b}{N}$
	Mid-40	0	0	c	$\frac{c}{N}$
	Mid-50	0	0	0	0
	Mid-60	0	0	0	0
Dish ration		$\frac{a - \Delta}{N}$	$\frac{b + \Delta}{N}$	$\frac{c}{N}$	1

表 12 χ^2 が最大になる表を変形したものに対する独立値

		Dish			Age ratio
		Chinese	Japanese	French	
Age	Mid-20	$\frac{a(a-\Delta)}{N}$	$\frac{a(b+\Delta)}{N}$	$\frac{ac}{N}$	$\frac{a}{N}$
	Mid-30	$\frac{b(a-\Delta)}{N}$	$\frac{b(b+\Delta)}{N}$	$\frac{bc}{N}$	$\frac{b}{N}$
	Mid-40	$\frac{c(a-\Delta)}{N}$	$\frac{c(b+\Delta)}{N}$	$\frac{c^2}{N}$	$\frac{c}{N}$
	Mid-50	0	0	0	0
	Mid-60	0	0	0	0
Dish ration		$\frac{a-\Delta}{N}$	$\frac{b+\Delta}{N}$	$\frac{c}{N}$	1

χ^2 以下のように評価される。

$$\begin{aligned}
 \chi^2 &= \frac{\left(a - \Delta - \frac{a(a-\Delta)}{N}\right)^2}{\frac{a(a-\Delta)}{N}} + \frac{\left(\Delta - \frac{a(b+\Delta)}{N}\right)^2}{\frac{a(b+\Delta)}{N}} + \frac{\left(\frac{ac}{N}\right)^2}{\frac{ac}{N}} \\
 &\quad + \frac{\left(\frac{b(a-\Delta)}{N}\right)^2}{\frac{b(a-\Delta)}{N}} + \frac{\left(b - \frac{b(b+\Delta)}{N}\right)^2}{\frac{b(b+\Delta)}{N}} + \frac{\left(\frac{bc}{N}\right)^2}{\frac{bc}{N}} \\
 &\quad + \frac{\left(\frac{c(a-\Delta)}{N}\right)^2}{\frac{c(a-\Delta)}{N}} + \frac{\left(\frac{c(b+\Delta)}{N}\right)^2}{\frac{c(b+\Delta)}{N}} + \frac{\left(c - \frac{c^2}{N}\right)^2}{\frac{c^2}{N}} \\
 &= \frac{\left(a - \Delta - \frac{a(a-\Delta)}{N}\right)^2}{\frac{a(a-\Delta)}{N}} + \frac{\left(b - \frac{b(b+\Delta)}{N}\right)^2}{\frac{b(b+\Delta)}{N}} + \frac{\left(c - \frac{c^2}{N}\right)^2}{\frac{c^2}{N}} \\
 &\quad + \frac{\left(\Delta - \frac{a(b+\Delta)}{N}\right)^2}{\frac{a(b+\Delta)}{N}} + \frac{ac}{N} + \frac{b(a-\Delta)}{N} + \frac{bc}{N} + \frac{c(a-\Delta)}{N} + \frac{c^2}{N}
 \end{aligned} \tag{32}$$

Eq. (32) の項は以下のように変形される。

$$\begin{aligned}
\frac{\left(a - \Delta - \frac{a(a-\Delta)}{N}\right)^2}{\frac{a(a-\Delta)}{N}} &= \frac{\left[\frac{a(a-\Delta)}{N}\right]^2 \left(1 - \frac{N}{a}\right)^2}{\frac{a(a-\Delta)}{N}} \\
&= \frac{a(a-\Delta)}{N} \left(1 - \frac{N}{a}\right)^2 \\
&= N - 2a + \frac{a^2}{N} + \left(2 - \frac{N}{a} - \frac{a}{N}\right)\Delta
\end{aligned} \tag{33}$$

$$\begin{aligned}
\frac{\left(b - \frac{b(b+\Delta)}{N}\right)^2}{\frac{b(b+\Delta)}{N}} &= \frac{\left[\frac{b(b+\Delta)}{N}\right]^2 \left(1 - \frac{N}{b+\Delta}\right)^2}{\frac{b(b+\Delta)}{N}} \\
&= \frac{b(b+\Delta)}{N} \left(1 - \frac{2N}{b+\Delta} + \left(\frac{N}{b+\Delta}\right)^2\right) \\
&= \frac{b(b+\Delta)}{N} - 2b + \frac{bN}{b+\Delta} \\
&= \frac{b(b+\Delta)}{N} - 2b + \frac{bN}{b\left(1 + \frac{\Delta}{b}\right)} \\
&= \frac{b(b+\Delta)}{N} - 2b + N\left(1 - \frac{\Delta}{b}\right) \\
&= N - 2b + \frac{b^2}{N} + \left(\frac{b}{N} - \frac{N}{b}\right)\Delta
\end{aligned} \tag{34}$$

$$\begin{aligned}
\frac{\left(c - \frac{c^2}{N}\right)^2}{\frac{c^2}{N}} &= \frac{\left(\frac{c^2}{N}\right)^2 \left(1 - \frac{N}{c}\right)^2}{\frac{c^2}{N}} \\
&= \frac{c^2}{N} \left(1 - \frac{2N}{c} + \frac{N^2}{c^2}\right) \\
&= N - 2c + \frac{c^2}{N}
\end{aligned} \tag{35}$$

これらを纏めて

$$\begin{aligned}
& N - 2a + \frac{a^2}{N} + \left(2 - \frac{N}{a} - \frac{a}{N}\right)\Delta \\
& + N - 2b + \frac{b^2}{N} + \left(\frac{b}{N} - \frac{N}{b}\right)\Delta \\
& + N - 2c + \frac{c^2}{N} \\
& = 3N - 2(a + b + c) + \frac{1}{N}(a^2 + b^2 + c^2) \\
& + \left(2 - \frac{N}{a} - \frac{a}{N} + \frac{b}{N} - \frac{N}{b}\right)\Delta
\end{aligned} \tag{36}$$

を得る。Eq. (32)の次の項を解析すると

$$\begin{aligned}
\frac{\left(\Delta - \frac{a(b+\Delta)}{N}\right)^2}{\frac{a(b+\Delta)}{N}} &= \frac{\left[\frac{a(b+\Delta)}{N}\right]^2 \left(1 - \frac{N}{a(b+\Delta)}\Delta\right)^2}{\frac{a(b+\Delta)}{N}} \\
&= \frac{a(b+\Delta)}{N} \left[1 - \frac{2N}{a(b+\Delta)}\Delta\right] \\
&= \frac{a(b+\Delta)}{N} - 2\Delta \\
&= \frac{ab}{N} + \left(-2 + \frac{a}{N}\right)\Delta
\end{aligned} \tag{37}$$

これまでの項を纏めると

$$\begin{aligned}
& \frac{ab}{N} + \left(-2 + \frac{a}{N}\right)\Delta + \frac{ac}{N} + \frac{b(a-\Delta)}{N} + \frac{bc}{N} + \frac{c(a-\Delta)}{N} + \frac{c^2}{N} \\
& = \frac{2}{N}(ab + bc + ca) + \left(-2 + \frac{a}{N} - \frac{b}{N}\right)\Delta
\end{aligned} \tag{38}$$

となる。さらに、全てを纏めると χ^2 は

$$\begin{aligned}
\chi^2 &= N + \frac{1}{N}(a^2 + b^2 + c^2) \\
&\quad + \left(2 - \frac{N}{a} - \frac{a}{N} + \frac{b}{N} - \frac{N}{b}\right)\Delta \\
&\quad + \frac{2}{N}(ab + bc + ca) + \left(-2 + \frac{a}{N} - \frac{b}{N}\right)\Delta \\
&= N + \frac{1}{N}(a + b + c)^2 - \left(\frac{1}{a} + \frac{1}{b}\right)N\Delta \\
&= 2N - \left(\frac{1}{a} + \frac{1}{b}\right)N\Delta \\
&= \chi_{\max}^2 - \left(\frac{1}{a} + \frac{1}{b}\right)N\Delta
\end{aligned} \tag{39}$$

となる。したがって、 χ^2 は減少する。したがって、もとの形式のデータは最大値を与えるものである。

ここでは、 χ^2 の最大値の一般形を求めることを検討する。我々は二つの種類のカテゴリーデータ x と y を扱う。表 13 に示すように x は m 個の水準があり、 y は l 個の水準があるとすると、ここで、 $m \leq l$ とする。この扱いは一般性を失わせることはない。一般には、 m と l の小さい方を k とすると、これは

$$k = \text{Min}[m, l] \tag{40}$$

と表現される。今の場合はである。 $x_1, x_2, \dots, x_k$ に対応する比率を $f_1, f_2, \dots, f_k$ とする。ここでは、 χ^2 の最大値を求めようとしているわけであるから、データは各行、列で一つのみあり、 $y_1, y_2, \dots, y_k$ は $x_1, x_2, \dots, x_k$ と同じであり、残りは $y_{k+1} = y_{k+2} = \dots = y_l = 0$ となる。この様相は表 13 に示している。 $y_1, y_2, \dots, y_k$ に関する比率は $g_1, g_2, \dots, g_k$ と表現すると、それらは

$$g_1 = f_1, g_2 = f_2, \dots, g_k = f_k, g_{k+1} = g_{k+2} = \dots = g_l = 0 \tag{41}$$

となる。

表 13 χ^2 が最大になる表の一般形

	y_1	y_2	$\cdots$	y_k	$\cdots$	y_l	x ratio
x_1	Nf_1	0	0	0	0	0	f_1
x_2	0	Nf_2	0	0	$\cdots$	0	f_2
$\vdots$	$\vdots$	$\ddots$	$\ddots$	$\ddots$	$\ddots$	$\vdots$	$\vdots$
x_k	0	0	0	Nf_k	0	0	f_k
v ratio	g_1	g_2	$\cdots$	g_k	0	0	

表 14 χ^2 が最大になる表の一般形に対する独立値

	y_1	y_2	$\cdots$	y_k	$\cdots$	y_l	Ratio
x_1	Nf_1^2	Nf_1f_2	$\cdots$	Nf_1f_k	0	0	f_1
x_2	Nf_2f_1	Nf_2^2	$\cdots$	Nf_2f_k	0	0	f_2
$\vdots$	$\vdots$	$\ddots$	$\ddots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_k	Nf_kf_1	Nf_kf_2	$\cdots$	Nf_k^2	0	0	f_k
Ratio	f_1	f_2	$\cdots$	f_k	0	0	

対応する独立値を表 14 に示す。

表 14 に示すの χ^2 の 1 行目の要素の和は

$$\begin{aligned}
 & \frac{(Nf_1 - Nf_1^2)^2}{Nf_1^2} + \frac{(0 - Nf_1f_2)^2}{Nf_1f_2} + \cdots + \frac{(0 - Nf_1f_k)^2}{Nf_1f_k} \\
 &= \frac{N^2f_1^2(1-f_1)^2}{Nf_1^2} + Nf_1f_2 + \cdots + Nf_1f_k \\
 &= N(1-f_1)^2 + Nf_1(f_2 + f_3 + \cdots + f_k) \\
 &= N(1-f_1)^2 + Nf_1(1-f_1) \\
 &= N(1-f_1)(1-f_1+f_1) \\
 &= N(1-f_1)
 \end{aligned} \tag{42}$$

となる。他の行も同じように評価すると χ^2 は

$$\begin{aligned}
 \chi^2 &= N(1-f_1) + N(1-f_2) + \cdots + N(1-f_k) \\
 &= kN - (f_1 + f_2 + \cdots + f_k)N \\
 &= (k-1)N
 \end{aligned} \tag{43}$$

となる。ここで、

$$f_1 + f_2 + \dots + f_k = 1 \quad (44)$$

を利用している。つまり、 χ^2 最大値は

$$\chi^2_{\max} = (k-1) \times N \quad (45)$$

となる。これは、 $f_1, f_2, \dots, f_k$ の値に依存しないことに注意しよう。偏っていることが本質的であり、その場合に χ^2 は最大値になる。

χ^2 の最大値がわかったので、この最大値で規格化された以下の係数を定義する。

$$r_c = \sqrt{\frac{\chi^2}{N \times (k-1)}} \quad (46)$$

これは、独立係数と呼ばれるものである。これは、0 から 1 の間の数値をとり、1 に近いほど、両データの関連性は高いということが言える。

先の例では独立係数は

$$r_c = \sqrt{\frac{\chi^2}{N \times (k-1)}} = \sqrt{\frac{123.85}{350 \times (2-1)}} = 0.59 \quad (47)$$

となる。

2.10. 調整残差

ここで、再び表 14 に示す顧客満足度を扱う。

これまでで、二つのカテゴリーデータの関連性の強さは独立係数で表現されることを示した。我々はさらに、目的変数と説明変数の水準の関連を調べたい。それは、調整残差で表現される。

ここでは、簡単化のためにカテゴリーの水準が目的変数、説明変数ともにそれぞれ二つのみの場合を扱う。

対応する χ^2 は以下のように評価される。

$$\begin{aligned} \chi^2 = & \frac{(x_{11} - Nk_1r_1)^2}{Nk_1r_1} + \frac{(x_{12} - Nk_1r_2)^2}{Nk_1r_2} \\ & + \frac{(x_{21} - Nk_2r_1)^2}{Nk_2r_1} + \frac{(x_{22} - Nk_2r_2)^2}{Nk_2r_2} \end{aligned} \quad (48)$$

ここで

$$\begin{cases} k_1 + k_2 = 1 \\ r_1 + r_2 = 1 \end{cases} \quad (49)$$

これらは、データと以下のように関連づけられる。

$$\begin{cases} \frac{x_{11} + x_{12}}{N} = k_1 \\ \frac{x_{11} + x_{21}}{N} = r_1 \\ x_{22} = N - (x_{11} + x_{12} + x_{21}) \end{cases} \quad (50)$$

これらから、全てのデータは x_{11} を使って、以下のように導かれる。

$$\begin{cases} x_{12} = Nk_1 - x_{11} \\ x_{21} = Nr_1 - x_{11} \\ x_{22} = N - (x_{11} + Nk_1 - x_{11} + Nr_1 - x_{11}) \\ \quad = (1 - k_1 - r_1)N + x_{11} \end{cases} \quad (51)$$

すると χ^2 は以下のようにになる。

$$\begin{aligned} \chi^2 &= \frac{(x_{11} - Nk_1r_1)^2}{Nk_1r_1} \\ &\quad + \frac{[Nk_1 - x_{11} - Nk_1(1 - r_1)]^2}{Nk_1r_2} \\ &\quad + \frac{[Nr_1 - x_{11} - N(1 - k_1)r_1]^2}{Nk_2r_1} \\ &\quad + \frac{[(1 - k_1 - r_1)N + x_{11} - N(1 - k_1)(1 - r_1)]^2}{Nk_2r_2} \\ &= \frac{(x_{11} - Nk_1r_1)^2}{Nk_1r_1} + \frac{(x_{11} - Nk_1r_1)^2}{Nk_1r_2} + \frac{(x_{11} - Nk_1r_1)^2}{Nk_2r_1} + \frac{(x_{11} - Nk_1r_1)^2}{Nk_2r_2} \\ &= \frac{(x_{11} - Nk_1r_1)^2}{N} \left(\frac{k_2r_2 + k_2r_1 + k_1r_2 + k_1r_1}{k_1r_1k_2r_2} \right) \\ &= \frac{(x_{11} - Nk_1r_1)^2}{Nk_1r_1k_2r_2} \\ &= \frac{(x_{11} - Nk_1r_1)^2}{Nk_1(1 - k_1)r_1(1 - r_1)} \end{aligned} \quad (52)$$

これは、 x_{11} だけで表現されていることに注目しよう。

同様なことが、 x_{12} に注目しても導き出される。

$$\begin{aligned}
\chi^2 &= \frac{(x_{11} - Nk_1r_1)^2}{Nk_1(1-k_1)r_1(1-r_1)} \\
&= \frac{(Nk_1 - x_{12} - Nk_1r_1)^2}{Nk_1(1-k_1)r_1(1-r_1)} \\
&= \frac{[x_{12} - Nk_1(1-r_1)]^2}{Nk_1(1-k_1)r_1(1-r_1)}
\end{aligned} \tag{53}$$

x_{21} に注目すると

$$\begin{aligned}
\chi^2 &= \frac{(x_{11} - Nk_1r_1)^2}{Nk_1(1-k_1)r_1(1-r_1)} \\
&= \frac{[x_{21} - N(1-k_1)r_1]^2}{Nk_1(1-k_1)r_1(1-r_1)}
\end{aligned} \tag{54}$$

x_{22} に注目すると

$$\begin{aligned}
\chi^2 &= \frac{(x_{11} - Nk_1r_1)^2}{Nk_1(1-k_1)r_1(1-r_1)} \\
&= \frac{[x_{22} - N(1-k_1)(1-r_1)]^2}{Nk_1(1-k_1)r_1(1-r_1)}
\end{aligned} \tag{55}$$

χ^2 は一定であるから、以下が導かれる。

$$\begin{aligned}
\frac{(x_{11} - Nk_1r_1)^2}{Nk_1(1-k_1)r_1(1-r_1)} &= \frac{[x_{12} - Nk_1(1-r_1)]^2}{Nk_1(1-k_1)r_1(1-r_1)} \\
&= \frac{[x_{21} - N(1-k_1)r_1]^2}{Nk_1(1-k_1)r_1(1-r_1)} \\
&= \frac{[x_{22} - N(1-k_1)(1-r_1)]^2}{Nk_1(1-k_1)r_1(1-r_1)}
\end{aligned} \tag{56}$$

ここで、

$$\begin{aligned}
\xi_{ij} &= \frac{x_{ij} - a_{ij}}{\sqrt{a_{ij}(1-k_i)(1-r_j)}} \\
&= \frac{x_{ij} - a_{ij}}{\sqrt{N[k_i r_j][(1-k_i)(1-r_j)]}}
\end{aligned} \tag{57}$$

と定義すると

$$\begin{aligned}
 \chi^2 &= \frac{(x_{ij} - a_{ij})^2}{\sqrt{a_{ij}(1-k_i)(1-r_j)}} \\
 &= \frac{(x_{ij} - a_{ij})^2}{\sqrt{N[k_i r_j][(1-k_i)(1-r_j)]}} \\
 &= \xi_{ij}^2
 \end{aligned} \tag{58}$$

となる。ここで、 ξ_{ij} を調整残差と呼ぶ。

したがって、 χ^2 はそれぞれのセルの値を使って表現される。これらの絶対値は全て同じである。

次に、調整残差の意味について定性的に考える。

まず、調整残差の符号について考える。符号は分子によって決まる。分子は

$$x_{ij} - a_{ij} \tag{59}$$

である。

調整残差は以下のように変形される。

$$\begin{aligned}
 \xi_{ij} &= \frac{x_{ij} - a_{ij}}{\sqrt{Nk_i r_j (1-k_i)(1-r_j)}} \\
 &= \frac{x_{ij} - a_{ij}}{\sqrt{a_{ij} \left(1 - \frac{n_i}{N}\right) \left(1 - \frac{n_j}{N}\right)}}
 \end{aligned} \tag{60}$$

もとのデータが何行何列の場合でも、あるセルに注目し、そのセルとそれ以外と考えれば、同じ値になる。すなわち、調整残差は、複数行からなるデータのあるセルに注目し、そのセルとそれ以外と考えた場合の独立係数を評価し、その 1 次をとったものである。したがって、それは独立係数と同様に大切さを表すが、大切さの中でも、そのセルの大切さを表しているといえる。

セル (1,2) を考える。対応するデータは x_{12} である。我々は以下を得る。

$$x_{11} + x_{12} = k_1 N \tag{61}$$

したがって、

$$x_{12} = k_1 N - x_{11} \tag{62}$$

となる。したがって、調整残差の分子は

$$\begin{aligned} x_{12} - k_1 r_2 N &= k_1 N - x_{11} - k_1 r_2 N \\ &= -x_{11} + k_1 (1 - r_2) N \\ &= -(x_{11} - k_1 r_1 N) \end{aligned} \quad (63)$$

となり、これはセル (1,1) の場合の分子の符号を反対にしたものである。したがって、2x2 クロス集計表の調整残差は表 15 のようになる。ここで、 ξ は、

$$\xi = \xi_{11} \quad (64)$$

である。つまり、全ての数値の絶対値は等しい。

表 15 2x2 クロス集計表の調整残差一般形

ξ	$-\xi$
$-\xi$	ξ

また、分子はデータの独立値からのずれを表す。それが正であれば、水準 j を実現するために正の依存性の強さを持ち、負であれば、水準 j を実現できない依存性の強さを表している。

調整残差と独立係数は両者とも依存性を、調整残差はさらにそれにその符号をつける。したがって、調整残差は独立係数と同様に関連性の強さを表現し、符号はそれが正の向きか負の向きかを表現している。つまり、調整残差 ξ_{ij} はその項目水準 i の目的変数の水準 j に対する関連性の強さを表す規格化値である。その符号は、水準が関連性についてどの方向で寄与するのかを表現している。

この調整残差は χ^2 の項の 1 次式であった。 χ^2 分布は標準正規分布に従う変数の 2 乗和の従う確率分布である。

項目 1 の調整残差を評価する。その結果を表 16 に示す。この値は $z_p (P=0.95)$ より大きいので、これは有意であると判断される。

表 16 Item 1 の調整残差

		Customers' satisfaction	
		high	low
Item1	high	11.13	-11.13
	low	-11.13	11.13

表 17 に示すような二つの極端な形式のデータを扱い、調整残差の意味をさらに検討する。一つは均一であり、一つは偏ったものである。

均一のデータ場合の調整残差は 0 であり、偏ったデータの場合の調整残差は 4.47 である。

表 17 均一および偏ったデータおよびそれらに対する調整残差

		Customers' satisfaction		Item ratio	Adjust residual			Independent factor
Item		high	low			high	low	
	high	5	5	0.5	high	0.00	0.00	0
	low	5	5		low	0.00	0.00	

		Customers' satisfaction		Item ratio	Adjust residual			Independent factor
Item		high	low			high	low	
	high	10	0	0.5	high	4.47	-4.47	1
	low	0	10		low	-4.47	4.47	

次に、表 18 に示すように我々は偏ったデータの値を変動させる。この場合、全ての調整残差および独立係数の値は同じである。Item に関して考えると、その Item のどの水準が主なのかに依存せず調整残差および独立係数は同じ値になる。満足度に関しても、満足度がどのくらいかには依存せず、調整残差および独立係数の値は同じである。つまり、調整残差も分布が均一か偏っているのかのみをみていることになる。すなわち、調整残差はその項目の水準の重要性のみを見ていて、その項目がどの程度達成されているのかは見ていない、ということになる。

表 18 水準の数値を変えた場合の調整残差と独立値

		Customers' satisfaction		Item ratio	Adjust residual			Independent factor
		high	low			high	low	
Item	high	4	0	0.2	high	4.47	-4.47	1
	low	0	16		low	-4.47	4.47	

		Customers' satisfaction		Item ratio	Adjust residual			Independent factor
		high	low			high	low	
Item	high	8	0	0.4	high	4.47	-4.47	1
	low	0	12		low	-4.47	4.47	

		Customers' satisfaction		Item ratio	Adjust residual			Independent factor
		high	low			high	low	
Item	high	10	0	0.5	high	4.47	-4.47	1
	low	0	10		low	-4.47	4.47	

		Customers' satisfaction		Item ratio	Adjust residual			Independent factor
		high	low			high	low	
Item	high	12	0	0.6	high	4.47	-4.47	1
	low	0	8		low	-4.47	4.47	

		Customers' satisfaction		Item ratio	Adjust residual			Independent factor
		high	low			high	low	
Item	high	16	0	0.8	high	4.47	-4.47	1
	low	0	4		low	-4.47	4.47	

上で扱ったように、データに偏りがある場合はクロスセルにのみ入ると仮定する。すると、クロスセルの二つのセルに入る個数は和が一定であれば、調整残差は不変であった。これを解析的に示す。

表 19 偏ったクロス集計表の一般形

		Customers' satisfaction		Item ratio
		high	low	
Item	high	N_1	0	r_1
	low	0	N_2	
Item ratio		k_1		

上の仮定を満足するために、表 19 を作成する。この表では、セルの(1,1)に N_1 、セルの(2,2)に N_2 のデータがあり、その他は 0 である。全てのデータ数を N とすると、

$$N = N_1 + N_2 \quad (65)$$

であり、

$$r_1 = k_1 = \frac{N_1}{N} \quad (66)$$

である。調整残差 ξ_{11} は

$$\begin{aligned}
\xi_{11} &= \frac{x_{11} - a_{11}}{\sqrt{a_{11}(1-k_1)(1-r_1)}} \\
&= \frac{N_1 - Nk_1r_1}{\sqrt{Nk_1r_1(1-k_1)(1-r_1)}} \\
&= \frac{N_1 - N\left(\frac{N_1}{N}\right)^2}{\sqrt{N\left(\frac{N_1}{N}\right)^2\left(1-\frac{N_1}{N_1}\right)\left(1-\frac{N_1}{N}\right)}} \\
&= \frac{N\left[\frac{N_1}{N} - \left(\frac{N_1}{N}\right)^2\right]}{\sqrt{N\left(\frac{N_1}{N}\right)^2\left(1-\frac{N_1}{N_1}\right)^2}} \\
&= \sqrt{N} \frac{\frac{N_1}{N}\left(1-\frac{N_1}{N_1}\right)}{\left(\frac{N_1}{N}\right)\left(1-\frac{N_1}{N_1}\right)} \\
&= \sqrt{N}
\end{aligned} \tag{67}$$

となる。つまり、 N_1 の値に依存しない。

また、上のことは調整残差の絶対値の最大値は $\sqrt{N}$ であることを意味する。したがって、これで規格化した調整残差

$$\begin{aligned}
\xi_{0ij} &= \frac{\xi_{ij}}{\sqrt{N}} \\
&= \frac{x_{ij} - a_{ij}}{\sqrt{a_{ij}\left[N(1-k_i)(1-r_j)\right]}}
\end{aligned} \tag{68}$$

は、-1 から 1 の間の値を取る。その絶対値が 1 に近いほど依存性が強い。また、符号が正であれば、総合満足度の水準 j を満足する方向に働き、負であれば満足しない方向に働く。

調整残差のあたゐそのものはデータ数に依存していた。しかし、この規格化調整残差を用いると、その値は-1 から 1 に収まり、1 に近いほうが項目水準の重要性が高いと議論できる。

以上の議論は 2x2 集計表の結果であったが、これを任意のクロス集計表で考えることができる。すなわち、対応する規格化調整残差は、前と同じように

$$\xi_{0ij} = \frac{x_{ij} - a_{ij}}{\sqrt{a_{ij}\left[N(1-k_i)(1-r_j)\right]}} \tag{69}$$

で与えられる。これは、その項目の水準の目的変数のある水準 j に対する寄与率を表している、と捉えることができる。

前述のように、調整残差は複数のセルからなるデータのあるセルに注目して操作していることになる。

つまり、以下の操作を施していることに相当する。

たとえば、複数の説明変数のデータ 4×2 のデータがあったとしよう。ここで、(1,1)のセルに対する調整残差は以下のことをやっている。そのセルとそれ以外、というデータ構造に変形し、その後に解析している。つまり、注目するセルとそれ以外という扱いにして、データを 2×2 の集計表に変形してからその注目するセルの依存性をみていることになる。その調整残差の2乗はそのデータの独立係数となる。

つまり、調整残差はそのセルの目的変数の水準 j に対する寄与の強さ、その符号でその向きを表している。

2.11. データのカテゴリー化再び

この解析の初めに、数値データのカテゴリー化をした。その際には、単純に数値データを区切りカテゴリー化した。ここで、調整残差を利用してカテゴリー化することを考える。

まず、目的変数のカテゴリー化は客観的に決定することはできない。目的とする数値以上のものを **high**、それに達しないものを **low** とする。

説明変数の区切りは、以下のように解析的に設定することができる。

説明変数のほうは、離散値であればそのまま、連続値であれば、適当に領域に区切りその代表値に置き換える。

アンケートデータの場合は、説明変数に対する満足度を数値で 1,2,3,4,5 のようにあらわしていた。この状態のままで調整残差を評価する。そして、総合満足度で **high** を得るために、説明変数でどの水準を得なければならないのか、が調整残差の解析から評価できる。

必要な水準が明らかになり、そのあるべき水準の達成率を評価する。

独立係数は以前のままか、この説明変数をカテゴリー化したデータを使って評価したものの中からいずれかで評価する。

2.12. 達成率

これまで、みてきたように独立係数、および調整残差はそれぞれ、全体および水準の目的変数に対する重要性を表しているが、その達成率は表していない。我々は、調整残差の値から、その項目が目的変数実現に対して重要かどうかを判断し、その達成率としてカウントする項目を選択する。その項目がどの程度達成されているのかを評価する。規格化された調整残差の値は-1 から 1 を取る。その正の値の基準値を設定する。そして、その値以上の項目を選択項目とし、その達成率を ζ_i とする。 i は項目を表す。場合によっては、複数の水準が選択項目となる。

項目 1 では、その達成率は 0.63 である。

表 20 は達成率もまとめて表記している。これらのデータを利用し、次に示す CS 分析を行っていく。

表 20 満足度に関するデータのまとめ

	Item1	Item2	Item3	Item4	Item5
Level achievement ratio	0.63	0.59	0.32	0.5	0.41
Independent factor	0.59	0.57	0.38	0.53	0.49
Dependence(χ^2 evaluation)	yes	yes	yes	yes	yes
Normalized level achievement ratio	1.23	0.88	-1.48	0.08	-0.7
Normalized independent factor	1.08	0.75	-1.78	0.19	-0.23
Contribution score	1.63	1.15	-2.31	0.19	-0.23
Rquired improvement score	-0.11	-0.09	0.21	0.08	0.33

2.13. CS 分析による項目の選択

これまでで、我々は各項目の独立係数と達成率を得た。これらのデータを使い、CS 分析で取り組むべき項目を選択する。項目は P 個あるとする。

2.13.1. 規格化

まず最初に達成率の規格化を行う。それらの平均と標準偏差は

$$\mu_{\varsigma} = \frac{1}{p} \sum_{i=1}^p \varsigma_i \quad (70)$$

$$\sigma_{\varsigma} = \sqrt{\frac{1}{p} \sum_{i=1}^p (\varsigma_i - \mu_{\varsigma})^2} \quad (71)$$

である。すると達成率の規格化値は

$$z_{\varsigma i} = \frac{\varsigma_i - \mu_{\varsigma}}{\sigma_{\varsigma}} \quad (72)$$

となる。

次に独立係数の規格化値を求める。それらの平均と標準偏差は

$$\mu_{r_c} = \frac{1}{p} \sum_{i=1}^p r_{c,i} \quad (73)$$

$$\sigma_{r_c} = \sqrt{\frac{1}{p} \sum_{i=1}^p (r_{ci} - \mu_{r_c})^2} \quad (74)$$

である。すると独立係数の規格化値は

$$z_{r_{ci}} = \frac{r_{ci} - \mu_{r_c}}{\sigma_{r_c}} \quad (75)$$

となる。

したがって、各アイテム毎にベクトル $a_i = (z_{r_{ci}}, z_{\eta_{ci}})$ を得る。これを、次の貢献度、改善必要度の評価で利用する。

2.13.2. 貢献度と改善必要度

図 4 に示すように、規格化された独立係数と達成度をプロットする。高い独立係数値はその項目が重要であることを意味する。また、高い達成度はその項目が満足のいく水準に達していることを意味する。したがって、改善必要度は、重要であって、達成度の低いもののほど高い値となる。これを、どのように数値として導き出すのであろうか？

この図の中で -45° の方向は、重要であって、達成度の低い方向に相当する。したがって、この軸に対する射影は改善必要度に相当すると考えることができる。

この図の中で 45° の方向は、重要であって、達成度の高い方向に相当する。したがって、この軸に対する射影は貢献度に相当すると考えることができる。

それらに対応する数値は以下のように評価できる。

貢献度の方向に対応する単位ベクトルを $\mathbf{e}_G$ 、改善必要度に対応する単位ベクトルを $\mathbf{e}_B$ とすると、それらは

$$\begin{cases} \mathbf{e}_G = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right) \\ \mathbf{e}_B = \left(\frac{1}{\sqrt{2}}, -\frac{1}{\sqrt{2}} \right) \end{cases} \quad (76)$$

で与えられる。したがって、各項目の貢献度 G_i は

$$\begin{aligned} G_i &= \mathbf{a}_i \cdot \mathbf{e}_G \\ &= (z_{r_{ci}}, z_{\eta_{ci}}) \cdot \frac{1}{\sqrt{2}} (1, 1) \\ &= \frac{1}{\sqrt{2}} (z_{r_{ci}} + z_{\eta_{ci}}) \end{aligned} \quad (77)$$

で与えられる。一方、各項目の改善必要度 B_i は以下のように与えられる。

$$\begin{aligned}
B_i &= \mathbf{a}_i \cdot \mathbf{e}_B \\
&= (z_{r_i}, z_{\eta_i}) \cdot \frac{1}{\sqrt{2}}(1, -1) \\
&= \frac{1}{\sqrt{2}}(z_{r_i} - z_{\eta_i})
\end{aligned} \tag{78}$$

その項目を有意とするかどうかは、あらかじめ、その値を設定しておく必要がある。たとえば、1 以上と定めておく。

図 5 に評価した改善必要度と貢献度を示す。Item1 と Item2 が顧客の満足度に貢献しており、明確な改善必要項目は見当たらない。




図 4 満足度に対する CS プロット.




図 5 貢献度と改善必要度

2.14. CS 相関係数

CS の観点から、いまの状況がいい状況なのか悪い状況なのかを判断したい。

重要な項目の達成率が高く、そうでない項目の達成率が低い、というのがいい状態であり、その逆が悪い状態である。

z_{ri} と $z_{\mu i}$ の相関係数 $r_{z_r z_\mu}$ がそれに相当する。つまり、

$$r_{z_r z_\mu} = \frac{\sigma_{z_r z_\mu}^{(2)}}{\sqrt{\sigma_{z_r z_r}^{(2)}} \sqrt{\sigma_{z_\mu z_\mu}^{(2)}}} \quad (79)$$

で評価できる。

$$\sigma_{z_r z_r}^{(2)} = \frac{1}{p} \sum_{i=1}^p z_{ri}^2 \quad (80)$$

$$\sigma_{z_\mu z_\mu}^{(2)} = \frac{1}{p} \sum_{i=1}^p z_{\mu i}^2 \quad (81)$$

$$\sigma_{z_r z_\mu}^{(2)} = \frac{1}{p} \sum_{i=1}^p z_{ri} z_{\mu i} \quad (82)$$

これを CS 相関係数と呼ぶ。これは-1 から 1 の範囲の値をとり、1 に近いほどいい状態、-1 に近いほど悪い状態、ということになる。

この例では CS 相関係数は 0.96 で、非常にいい状態であることがわかる。これが、貢献項目はあるが、改善必要項目はない、という状態に対応する。

2.15. 説明変数の向上と目的変数の向上の関係

回帰分析では、説明変数を変動させた場合、目的変数はどれだけ変動するかを予想していた。回帰分析の場合は相関係数が変わらないとして、説明変数と目的変数の関連を利用して、それを評価していた。

同じようなことをカテゴリーデータでできるのであろうか？すなわち、説明変数の達成率を向上させた場合、目的変数値はどのくらい向上するであろうか？カテゴリーデータの場合はそのような理論は存在しない。ここでは、その理論を検討する。

数値データでは相関係数は変わらないとしていた。これと同じことをするためには、カテゴリーデータでは、独立係数は変わらないとすればいい。

		Customers' satisfaction		ratio
		high	low	
Item	yes	x_{11}	x_{12}	k_1
	no	x_{21}	x_{22}	k_2
ratio		r_1	r_2	

図 6 仮定するデータの変動

2.15.1. 2x2 クロス集計の回帰分析

ここでは、2x2 のクロス集計データを扱う。対応するデータの形式を図 6 に示す。

顧客の満足度が高い比率は r_1 、低い比率は r_2 とする。

Item の水準は yes と no とする。yes は望ましい水準でその比は k_1 、no は望ましくない水準でその比は k_2 とする。したがって、我々は、 k_1 を上げたい。その時に、 r_1 はいくらになるのか、ということである。

最初のデータを $x_{11}, x_{12}, x_{21}, x_{22}$ とする。それから、比は以下ようになる。

$$k_1 = \frac{x_{11} + x_{12}}{N} \quad (83)$$

$$k_2 = \frac{x_{21} + x_{22}}{N} \quad (84)$$

$$r_1 = \frac{x_{11} + x_{21}}{N} \quad (85)$$

$$r_2 = \frac{x_{12} + x_{22}}{N} \quad (86)$$

ここで N は全データ数であり

$$N = x_{11} + x_{12} + x_{21} + x_{22} \quad (87)$$

となる。

我々は k_1 を上げたい。したがって、その比が増加して k' になったとする。すると

$$k'_1 = k_1 + \Delta k_1 \quad (88)$$

と表現される。ここで、増分 Δk_1 は正である。 k_2 は 減少し $k'_2 = k_2 - \Delta k_1$ となる。この Δk_1

は与えられるものとする。我々は、この場合の r_1 と r_2 の変化を検討する。

我々が設定するのは比の変化である。

対応して、データがどのように変動するのか、仮定および検討する必要がある。

まず、以下のように変動すると仮定する。

$$\begin{cases} x_{11} \rightarrow x'_{11} \\ x_{12} \rightarrow x'_{12} \\ x_{21} \rightarrow x'_{21} \\ x_{22} \rightarrow x'_{22} \end{cases} \quad (89)$$

この変動をより詳しく検討する。

項目に対して施策を施すわけであるから、もともとその項目に満足していた人は、そのまま変動しないとする。つまり、もともと x_{11} と x_{12} であったデータはそのままであると仮定する。つまり、施策を施しても、その項目に対して、yes だった人は、そのまま yes であると仮定する。

もともと x_{21} と x_{22} であった人の一部は変化すると仮定する。つまり、施策を施して、その項目に対して、no だった人の一部は、yes に転じる。

k_1 の増加は x_{21} が Δ_{21} 減少し、 x_{22} が Δ_{22} 減少することによって実現される。したがって、 Δk_1 は以下のように表現される。

$$\Delta_{21} + \Delta_{22} = N\Delta k_1 \quad (90)$$

さらに Δ_{21} は x_{11} に単純に追加され、 Δ_{22} の一部は x_{11} に追加され、残りは x_{12} に追加されるとする。つまり、高い満足度の人はそのまま高い満足度であり、低い満足度で項目が yes になった人の一部が高い満足度になると仮定する。すると、以下のようになる。

$$\begin{cases} x'_{11} = x_{11} + \Delta_{21} + r_\kappa \Delta_{22} \\ x'_{12} = x_{12} + (1 - r_\kappa) \Delta_{22} \end{cases} \quad (91)$$

ここで、 r_κ は項目で no だった人が yes に転じた場合、満足度が高くなる確率である。

この r_κ を独立係数 r_c で表すことを提考える。

r_c が 1 であれば、全ての人の満足度は高くなり、全て x_{11} に追加される。つまり、 r_c が 1 の場合は r_κ は 1 である。一方、 r_c が 0 であれば、関連性はないのであるから、半分は x_{11} に、半分は x_{12} に追加される。つまり、 r_c が 0 のときは r_κ は 0.5 である。その間は線形に変動すると仮定する。すると

$$r_\kappa = \frac{1}{2}(1 + r_c) \quad (92)$$

となる。

我々は、式 (90)を利用して Δ_{21} を除去する。そして

$$\begin{cases} x'_{11} = x_{11} + N\Delta k_1 - (1 - r_\kappa) \Delta_{22} \\ x'_{12} = x_{12} + (1 - r_\kappa) \Delta_{22} \end{cases} \quad (93)$$

を得る。

高い満足度の増分は $r_\kappa \Delta_{22}$ であり、対応する高い満足度の比率は

$$r'_1 = r_1 + \frac{r_\kappa \Delta_{22}}{N} \quad (94)$$

となる。これは、 Δ_{22} について解けば

$$\Delta_{22} = N \frac{r'_1 - r_1}{r_\kappa} \quad (95)$$

となる。

ここで、独立係数は変わらない、つまり χ^2 は変わらないと仮定する。

$$\chi^2 = \frac{(x_{11} - Nk_1 r_1)^2}{Nk_1(1-k_1)r_1(1-r_1)} = \frac{(x'_{11} - Nk'_1 r'_1)^2}{Nk'_1(1-k'_1)r'_1(1-r'_1)} \quad (96)$$

これは、以下のように変形される。

$$\begin{aligned} \chi^2 &= \frac{(x'_{11} - Nk'_1 r'_1)^2}{Nk'_1(1-k'_1)r'_1(1-r'_1)} \\ &= \frac{[x_{11} + N\Delta k_1 - (1-r_\kappa)\Delta_{22} - Nk'_1 r'_1]^2}{Nk'_1(1-k'_1)r'_1(1-r'_1)} \\ &= \frac{\left[x_{11} + N\Delta k_1 - N\left(\frac{1-r_\kappa}{r_\kappa}\right)(r'_1 - r_1) - Nk'_1 r'_1 \right]^2}{Nk'_1(1-k'_1)r'_1(1-r'_1)} \\ &= N \frac{\left\{ \left[\frac{x_{11}}{N} + \Delta k_1 + \left(\frac{1-r_\kappa}{r_\kappa}\right)r_1 \right] - \left[\left(\frac{1-r_\kappa}{r_\kappa}\right) + k'_1 \right] r'_1 \right\}^2}{k'_1(1-k'_1)r'_1(1-r'_1)} \end{aligned} \quad (97)$$

したがって、以下を得る。

$$\frac{\chi^2}{N} k'_1(1-k'_1)r'_1(1-r'_1) = \left\{ \left[\frac{x_{11}}{N} + \Delta k_1 + \left(\frac{1-r_\kappa}{r_\kappa}\right)r_1 \right] - \left[\left(\frac{1-r_\kappa}{r_\kappa}\right) + k'_1 \right] r'_1 \right\}^2 \quad (98)$$

ここで、以下の変数を導入する

$$A \equiv \frac{\chi^2}{N} k'_1(1-k'_1) \quad (99)$$

$$B \equiv \frac{x_{11}}{N} + \Delta k_1 + \left(\frac{1-r_\kappa}{r_\kappa}\right)r_1 \quad (100)$$

$$C = \left(\frac{1-r_\kappa}{r_\kappa}\right) + k'_1 \quad (101)$$

すると式 Eq. (98) は、以下のようになる。

$$Ar'_1(1-r'_1) = (B - Cr'_1)^2 \quad (102)$$

これは、 r'_1 について以下のように解かれる。

$$r'_1 = \frac{A + 2BC \pm \sqrt{A[A + 4B(C - B)]}}{2(A + C^2)} \quad (103)$$

ここでは、解が二つ導かれたが以下で示すように一つは不適である。

まず項 $C - B$ の符号を考える。

$$\begin{aligned}
C - B &= \left(\frac{1 - r_k}{r_k} \right) + k_1' - \frac{x_{11}}{N} - \Delta k_1 - \left(\frac{1 - r_k}{r_k} \right) r_1 \\
&= \left(\frac{1 - r_k}{r_k} \right) (1 - r_1) + k_1' - \frac{x_{11}}{N} \\
&= \left(\frac{1 - r_k}{r_k} \right) (1 - r_1) + \frac{x_{11} + x_{12}}{N} - \frac{x_{11}}{N} \\
&= \left(\frac{1 - r_k}{r_k} \right) (1 - r_1) + \frac{x_{12}}{N} > 0
\end{aligned} \tag{104}$$

したがって、 $C - B$ は正である。

次にセル(1,1)の調整残差を考える。この調整残差は正であり、

$$x_{11}' - Nk_1'r_1' > 0 \tag{105}$$

となる。これは、

$$B - Cr_1' > 0 \tag{106}$$

となる。これは以下のように変形される。

$$\begin{aligned}
B - Cr_1' &= B - \frac{A + 2BC + \sqrt{A[A + 4B(C - B)]}}{2(A + C^2)} C \\
&= \frac{2AB + 2BC^2 - AC - 2BC^2 - \sqrt{A^2C^2 + 4ABC^2(C - B)}}{2(A + C^2)} \\
&= \frac{2AB - AC - AC\sqrt{1 + \frac{4B}{A}(C - B)}}{2(A + C^2)} \\
&= \frac{2AB - AC \left[1 + \sqrt{1 + \frac{4B}{A}(C - B)} \right]}{2(A + C^2)} \\
&< \frac{2AB - 2AC}{2(A + C^2)} \\
&= \frac{2A(B - C)}{2(A + C^2)} < 0
\end{aligned} \tag{107}$$

したがって、一つの解は不適である。

もう一つの解は以下のように変形される。

$$\begin{aligned}
B - Cr_1' &= B - \frac{A + 2BC - \sqrt{A[A + 4B(C - B)]}}{2(A + C^2)} C \\
&= \frac{2AB - AC \left[1 - \sqrt{1 + \frac{4B}{A}(C - B)} \right]}{2(A + C^2)} \\
&= \frac{2AB + AC \left[\sqrt{1 + \frac{4B}{A}(C - B)} - 1 \right]}{2(A + C^2)} > 0
\end{aligned} \tag{108}$$

したがって、これは解になりうる。よって、変動した高い満足度の比率として

$$r_1' = \frac{A + 2BC - \sqrt{A[A + 4B(C - B)]}}{2(A + C^2)} \tag{109}$$

を得る。

表 21 一般的なクロス集計表および、対応する実効的な 2x2 クロス集計表

		Total satisfaction				
		Levels	high	plane	low	ratio
Item	significant high	x ₁₁	x ₁₂	x ₁₃	k ₁	
	high	x ₂₁	x ₂₂	x ₂₃	k ₂	
	plane	x ₃₁	x ₃₂	x ₃₃	k ₃	
	low	x ₄₁	x ₄₂	x ₄₃	k ₄	
	significant low	x ₅₁	x ₅₂	x ₅₃	k ₅	
	ratio	r ₁	r ₂	r ₃		

		Total satisfaction				
		Levels	high	plane	low	ratio
Item	significant high	x _{11m}	x _{12m}			k _{1m}
	high					
	plane	x _{21m}	x _{22m}			k _{2m}
	low					
	significant low					
	ratio	r ₁	r _{2m}			

以上で求めた Δr_1 を Item P (Item の番号を P としている) の満足度の向上比率の差分

Δr_{p1} とし、その足し合わせ

$$\Delta r_1 = \sum_p \Delta r_{p1} \quad (110)$$

がトータルの満足比率の増加量になると考える。

表 22 Item5 の解析結果まとめ

Item5	高い	低い	総計	比率
高い	108	36	144	0.41
低い	42	164	206	0.59
総計	150	200	350	1
比率	0.43	0.57	1	

独立係数	0.49
目標達成比率	0.46
chai2	85.53
r1'	0.46

2.15.2. 一般形のクロス集計表の回帰分析

クロス集計表の一般形は 2 x 2 ではない。そのようなものであっても、達成度を評価するさいに調整残差をもとに二つのグループに分けた。つまり、データを以下のように変形した。

$$\begin{cases} x_{11m} = x_{11} + x_{21} \\ x_{12m} = x_{12} + x_{13} + x_{21} + x_{23} \\ x_{21m} = x_{32} + x_{41} + x_{51} \\ x_{22m} = x_{32} + x_{33} + x_{42} + x_{43} + x_{52} + x_{53} \end{cases} \quad (111)$$

あとは同じ解析となる。

2.16. 部分グループの解析

我々はここまで、グループトータルの解析を行ってきた。ここでは、トータルのグループは複数のサブグループからなる場合を考える。各サブグループはトータルのグループの特性とは異なることが一般的である。したがって、取り扱わなければならない項目はサブグループごとに異なると思われる。ここでは、サブグループの扱う項目と検討する。

ここで、我々は項目の重要性、すなわち独立係数は全体とサブグループで同じであると仮定する。違いは、達成率であるとする。

項目 i の達成率を ς_{Gi} とすると、サブグループの規格化値の増分は、

$$\Delta z_{Gi} = \frac{\varsigma_{Gi} - \varsigma_i}{\sigma_{\varsigma}} \quad (112)$$

となる。

サブグループの達成率は

$$z_i \rightarrow z_i + \Delta z_{Gi} \quad (113)$$

とする。後は、同じ取り扱いになる。

2.17. 個別グループの解析

我々はここまで、グループトータルの解析を行ってきた。ここでは、サブグループではなくて、個々の一つのデータ、つまり個別グループのデータ得た場合に、全体グループでの解析をどう反映させるか考える。

全体グループの解析においては、我々が提示できるのは、グループトータルとしての以下の値である。

- 目的変数、説明変数のカテゴリー化のための臨界値
- 全体の独立係数
- 各項目の達成率
- 各項目の改善必要素
- 各項目の貢献度
- 重点項目

個別グループの得られるデータは、目的変数、説明変数に対する評点である。したがって、達成率は0か100であり、あまり全体の評価との突き合わせは適当とは思われない。全体の評価との突き合わせは以下が妥当と考える。

個別グループとしては、

- 目的変数の評点とその目標値に対してどうか
- 重点項目の評点とその目標値に対してどうか
- その他の項目の評点とその目標値に対してどうか

をみればいい。

その他に何かできるであろうか？

あとは、その個別グループの得た評点の、グループトータルに対する立ち位置を示すことができる。その場合は、先に述べたように、グループトータルの評点の平均値 μ と標準偏差 σ を目的変数、各説明変数毎に求めておく。個別グループの評点を x とした場合、

$$z = \frac{x - \mu}{\sigma} \quad (114)$$

と規格化値を求め、このグループ全体に対する確率 P を

$$P = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right) dz \quad (115)$$

として評価すればいい。これがその個別グループのグループ全体に対する立ち位置になる。たとえば、 $P \geq 0.6$ の項目がこのグループの優れている点、 $P < 0.5$ はこの個別グループの改善を必要とする点と考えることができる。

以上で述べて来たことは、あくまでグループトータルとしての特徴を基準にしている。

おおまかには正しいであろうが、個別グループには個別グループそのものの特徴があり、グループ全体平均の特徴と同じというわけではない。したがって、グループトータルから言えることは、参考として捉えることが望ましいと考えている。

2.18. 独立係数の取り扱い

独立係数 r_c は 0 から 1 の間の値をとり、その範囲からはずれた値になることはない。したがって、0.1 から 0.2 の変化と 0.9 から 1.0 への変化は等価ではない可能性がある。後者のほうが臨界点に近いので難しい可能性がある。しかしながら、CS 分析ではこれらは同じ扱いとなる。

そこで、独立係数 r_c の代りに変数 ζ を利用することを提案する (図 7)。

$$\zeta = \frac{1}{2} \ln \left(\frac{1+r_c}{1-r_c} \right) \quad (116)$$

この変数は独立係数 r_c が 0 から 1 に変動するとき 0 から ∞ に変動する。同様な解析はこの ζ を用いて行うことができる。




図 7 変数変換

2.19. 数値データとカテゴリーデータの得失

前章で示した CS 分析はデータが数値であり、ここで示した独立係数解析では、その数値データをカテゴリー化していた。両者はほとんど同じことを解析する。ここでは、両解析

の得失を簡単に議論する。

まず、数値に客観性がある場合は、数値データそのものを扱うほうがいいと思う。客観性とは、たとえば2は1より二倍いい、というような関係が成り立つ場合である。ここで、示したように、カテゴリーデータの場合は、データの区切りはある程度感覚にゆだねられるからである。そのような客観性があまりない場合、全体のデータの連続性がないデータの場合はカテゴリーデータのほうが解析にふさわしいように思う。また、期間の長さ、会社名など、数値化できないようなデータはカテゴリー解析するしかない。

カテゴリーデータの場合は、目的変数は区切りを恣意的に決めるしかないが、説明変数の区切りは調整残差から決めることができる。

数値データの場合にその項目の重要度を示すパラメータとして相関がある。これは、一方が増えれば他方も増える、という関係を表す量である。したがって、目的変数、説明変数の関係が全領域である程度一定でないとうまくいかない。相関係数は扱う領域全体の傾向をあらわしているからである。ある部分的な領域のみで関連性が大きくなる、という場合はその関連性を見落としてしまう。データの途中の領域に最適領域があるような場合は特に見落とす。カテゴリーデータ解析では、このような特性をうまく拾ってくれる可能性が高い。

数値データ分析では、回帰分析が簡便に利用できるというメリットがある。カテゴリーデータの場合でもその回帰分析はここで示したようにできるが、そのプロセスはそれほどやさしくない。

2.20. まとめ

この章のまとめを行う。

セル (i, j) の独立値 a_{ij} 配下のように与えられる。

$$a_{ij} = k_i r_j N$$

k_i は説明変数の水準 i に対する比率で、目的変数である満足度の結果には無関係である。

N は全データ数である。 r_j は目的変数である満足度の水準 j に対応する比率で、説明変数の結果には無関係である。クロス集計表の依存性は以下の値の独立値からのずれと関連する量の和 χ^2 で評価できる。

$$\chi^2 = \sum_{i,j} \frac{(x_{ij} - a_{ij})^2}{a_{ij}}$$

これは、説明変数、目的変数が独立であれば、この変数は χ^2 分布に従う。したがって、この変数が、 χ^2 分布の臨界値より大きいのか、小さいかで依存性を推定確率と結び付けて予想できる。

目的変数、説明変数の水準の数を m 、 l とすると、この自由度 ϕ は以下ようになる。

$$\phi = (m-1)(l-1)$$

推定確率を P とすると対応する P 値は以下になる。

$$\chi_c^2 = \chi^2(\phi, P)$$

したがって、 χ^2 が χ_c^2 よりも大きければ、依存性ありと判断でき、小さければ、依存性があるとは言えないことがわかる。

この χ^2 の最大値 $\chi_{\max}^2$ は

$$\chi_{\max}^2 = N \times (k-1)$$

で与えられる。したがって、独立係数

$$r_c = \sqrt{\frac{\chi^2}{N \times (k-1)}}$$

を定義できる。この独立係数は依存性の強さを表す。その値は 0 から 1 をとり、1 に近いほど依存性は強くなる。

調整残差

$$\xi_{ij} = \frac{x_{ij} - a_{ij}}{\sqrt{a_{ij} \left(1 - \frac{n_i}{N}\right) \left(1 - \frac{n_j}{N}\right)}}$$

がさらに定義される。これは、その項目の目的変数 j に対する水準 i の寄与を表す。この値の最大値は $\sqrt{N}$ である。したがって、その値で規格化した

$$\xi_{0ij} = \frac{\xi_{ij}}{\sqrt{N}}$$

は -1 から 1 の間の数値を取る。この規格化された調整残差の値に臨界値を設定すれば、その目的変数の水準を実現するために有意な説明変数の水準を選択できる。その選択された水準の達成率 ς_i を定義し、評価できる。

独立係数と達成率から CS 分析を行うことができる。

説明変数の達成率を Δk_1 向上させると、目的変数の満足度は

$$r_1' = \frac{A + 2BC - \sqrt{A[A + 4B(C - B)]}}{2(A + C^2)}$$

となることを示した。ただし、係数は

$$A \equiv \frac{\chi^2}{N} k_1' (1 - k_1')$$

$$B \equiv \frac{x_{11}}{N} + \Delta k_1 + \left(\frac{1 - r_k}{r_k} \right) r_1$$

$$C = \left(\frac{1 - r_k}{r_k} \right) + k_1'$$

$$r_k = \frac{1}{2} (1 + r_c)$$

で与えられる。

サブグループの達成率の全体に対する増分は

$$\Delta z_{Gi} = \frac{\zeta_{Gi} - \zeta_i}{\sigma_\zeta}$$

で与えられ、その達成率は

$$z_i \rightarrow z_i + \Delta z_{Gi}$$

となる。これらを用いて CS 分析をしていく。

サブグループでなく、データ値が基本的に 1 個しかない場合、つまり個別グループのデータの扱いを議論した。この場合は、そのデータの全体に対する立ち位置を示す。

項目の重要性をここでは、独立係数 r_c で評価したが、それは 0 から 1 の範囲をとり、その範囲外の値はとれない。したがって、端点に近づくにつれ、その変動は困難になる。そのため、以下の変数変換をおこなうことを提案した。

$$\zeta = \frac{1}{2} \ln \left(\frac{1 + r_c}{1 - r_c} \right)$$

CS 分析での場合に扱う数値データとここでの独立係数解析で扱うカテゴリーデータの得失は以下である。

数値に客観性や連続性がある場合は、数値データ解析もカテゴリーデータ解析も同様な結果を示すことが予想される。数値データのほうが、その後の回帰分析に容易につなげていくことができる。

ただし、ある一部の領域でのみ関連性が明らかな場合や、特性がなめらかでない場合は、カテゴリーデータ解析のほうが特徴をあぶりだせる可能性が高い。カテゴリーデータの場合は、カテゴリー化はある程度、恣意的になる。

図 8 はこれまでの解析のフローを示している。




図 8 解析フロー