

3. 決定木分析

概要: 決定木分析は、あることを決定するために、複数の項目を考慮する場面に適用される。この分析では、ある項目の水準に応じて決定事項が明白に決まる場合は、それが肯定であっても否定であってもその項目が選択される。その選択される仕組みをエントロピー関数で表現する。通常はこのエントロピー関数が用いられるが、ここではそのエッセンスを把握し、新たな関数を提案し、同様の結果を得ることができることを示す。

キーワード:決定木;エントロピー;項目エントロピー;距離;項目水準エントロピー;ジニ係数

3.1. 序

日常生活の中では、意思決定する場面が多々ある。花見をするのか、運動会を開催するのか、どの大学を受験するのか等である。それらの決定をする際、さまざまなことを考慮する必要がある。花見の場合では、その日の天気、風の強さ、その場の込み具合、そこに至るまでの時間、等である。このようなものを考える場合、すべての条件が最適か最悪に揃う場合はまれである。考える条件がまちまちの水準の場合にどう意思決定していくのか、という問題に行き当たる。

意志決定法として決定木分析がある。この解析では意志決定する目的項目と意思決定に関連する複数の説明項目のデータを扱う。目的項目と説明項目の解っているデータから、どのような説明変数組み合わせ条件の場合に目的変数の結果が明白になるかを示すものである。これから、説明項目がわかっていて目的変数の値がわかっていないとする新たなメンバーが来た場合、その目的変数はどうなるのかを予想する。または、目的変数の水準は、説明項目のどのような組み合わせと連動するのかを予想する。この方法は簡便であるため、多くの場面で利用されている。ここではその決定木分析の解説をする。まず、通常の方法で解析し、その課題を述べる。次に、新たに関数を導入し、それを利用して具体的な解析を行う。

3.2. 決定木分析のデータ構造

決定木分析の詳細を解析していく。目的変数はカテゴリーデータとする。その水準数は2が基本であるが、2よりも多い複数の場合にも拡張する。

説明変数はカテゴリーデータであるとする。数値データの場合は、それを二分割し、カテゴリーデータ的な扱いをする。

つまり、この解析では、目的変数はカテゴリー、説明変数はカテゴリーを扱う。両者が数値の場合も、カテゴリーに変換するため、このデータ構造も扱うことができる。

3.3. 正直村と嘘つき村

決定木を考える前に、正直村と嘘つき村という有名な問題を検討する。それは以下のよう
に与えられる。

旅人が分かれ道にやってきた。片方は正直村に、もう片方は嘘つき村へ続いている。

そこに村人がやってきた。その村人は正直村から来たのか、嘘つき村から来たのか旅人
にはわからない。

旅人は、この村人に一回だけ質問をして正直村へ行く道を知りたい。

村人は質問に対して Yes か No しか答えない。

旅人は村人に何と聞けばいいだろうか？

この問題の答えは、片方の道を指して、あなたが住んでいるのはこちらですか？と聞く、
というものである。

もし、指差した方向が正直村だったとしよう。

聞いた相手が正直村から来た村人であったら、”はい”と答える。

聞いた相手が嘘つき村から来た人であったら、違うため”はい”と答える。

もし、指差した方向が嘘つき村だったとしよう。

聞いた相手が正直村から来た村人であったら、”いいえ”と答える。

聞いた相手が嘘つき村から来た人であったら、合っているため”いいえ”と答える。

つまり、旅人は”はい”という答えを得たらその道を行けばいいし、”いいえ”という答え
を得たら指した道でないほうへ行けばいい。

上の問題では、正直者も嘘つきものも旅人が決定するのに同じように有効な結論を与え
る。つまり、完全な嘘つきは完全な正直と同じ情報を与える。

以上のことを表 1 に示す。

人が決断できるかどうかを考えた場合、正直の反対は嘘ではなく、正直と嘘が混じり合
った状態である。

表 1 村人の答

Q:こちらが正直村ですか？		村人の出身地	
		正直村	嘘つき村
旅人が 指さした方向	正直村	はい	はい
	嘘つき村	いいえ	いいえ

3.4. 花見

まず、簡単な例として花見について考えてみよう。

花見をするかどうか(Yes か No か)は天気と関連すると考える。もしも天気が晴れの場合、かならず花見をするのであれば(花見をする確率 1)、天気が晴れの場合は決定で花見をする、となる。もしも天気が雨の場合、かならず花見をしないのであれば(花見をする確率 0) 天気が雨の場合は決定で花見をしない、になる。天気が曇りの場合は花見をする場合としない場合(花見をする確率 0.5)があるので、この場合はどうするのか決定できない、いうことになる。つまり、決定という観点からすると、花見をする確率が 0 でも 1 でも同様に決定でき、確率が 0.5 の場合は決定できない、ということになる。

以上のことを定量的に扱うためにエントロピー関数やジニ係数が導入される。これらは決定できる場合は値が 0、決定できない場合は 0 よりも大きい、という特徴を有する。つまり、その値の大きさは決定のしづらさを定量的に表現する。

3.4.1. 花見に対する決定木解析データ構造

花見に対する決定木のデータをみていく。

花見をするかどうか(Yes か No か)は天気、風速、湿度と関連すると考え、表 2 のデータを取得したとする。このデータから、与えられた天気、風速、湿度がある場合、花見をするか、しないか、を判断したい。この場合、花見をする、しないに対して、どの項目から考えていけばいいのかを検討する。つまり、どの項目が判別に最も有効かの判断をする。その判断を定量的に行うためにエントロピー関数を導入する。

表 2 花見に対する基本データ

天気	風速	湿度	花見
晴れ	強い	高い	No
曇り	弱い	高い	Yes
曇り	強い	低い	No
晴れ	弱い	高い	Yes
雨	弱い	高い	No

3.4.2. エントロピーとゲイン比

花見をする、しないの判断を定量的にする基準量としてエントロピー info を

$$\text{info} = -p \log_a p - (1-p) \log_a (1-p) \quad (1)$$

と定義する。ここで、 p は目的とすることが起こる確率である。つまり花見をする(Yes)となる確率である。これが 0 に近い場合は花見に行かないと判断できる。また、これが 1 に近い場合は花見に行く判断できる。これが 0.5 近傍であれば判断できない、と表現する。

この関数の詳細をみていこう。

エントロピー関数の第1項を構成成分で示したものが図1である。これは $-\log_a p$ と p の二つの関数を掛けあわせること構成される。この掛け合わせた関数は0から1の範囲で正、0,1で0となる。




図1 エントロピーの第1項の構成

次に最大値について考えてみる。最初の項目を p で微分して0とおく。

$$\begin{aligned} \frac{\partial(-p \log_a p)}{\partial p} &= -\frac{1}{\log_a e} \frac{\partial(-p \ln p)}{\partial p} \\ &= -\frac{1}{\log_a e} (\ln p + 1) \\ &= 0 \end{aligned} \tag{2}$$

これを満足する p は底 a に依存せず

$$\begin{aligned} p &= \frac{1}{e} \\ &= 0.37 \end{aligned} \tag{3}$$

となる。底が2,3,5の場合の最初の項目を図2に示す。 p に関して非対称であり、ピークは式(3)の位置にある。この非対称性は決定に関しては定性的にはあまりよろしくない性質であるが、実際は他の関数と抱き合わせで利用されるので、この性質はその場合は消失する。




図 2 様々な底におけるエントロピーの第1項

また、分布は底によらず相似形であり、絶対値が違うだけである。それは以下に示す対数関数の性質から明らかである。

$$-p \log_{\alpha} p = -\frac{1}{\ln \alpha} p \ln p \quad (4)$$

エントロピーの全体の項を考慮したものを図 3 に示す。この場合は確率 p に関して分布は対称になる。エントロピーは p の値が 0 と 1 で 0 になり、その中間の値でそれより大きな値になる。




図 3 様々な底におけるエントロピー

エントロピーの値が大きいほど判断ができないということになる。ここでは花見をするか、しないかの二通りが最終的な判断となる。したがって、その確率がそれぞれ1/2になった場合に最も判断できない、ということになる。このことについては、後に詳しく議論する。

ここで採用しているエントロピーの底の値について考える。

最終的な判断が m 通りの場合を考える。すべての場合で確率が同じ場合、すなわち

$$p = \frac{1}{m} \quad (5)$$

の場合に判断困難、つまりエントロピーが最大になる。この場合にエントロピーの値が1になるように底の値を定めることにする。すなわち

$$\begin{aligned} \text{info} &= -np \log_{\alpha} p \\ &= -m \frac{1}{m} \log_{\alpha} \frac{1}{m} \\ &= \log_{\alpha} m \\ &= 1 \end{aligned} \quad (6)$$

とする。これから、

$$\alpha = m \quad (7)$$

とすればいいことがわかる。つまり目的変数の水準の数を底の値とすると、エントロピーの

最大値は1になる。ここでは、目的変数の花見をする、しないの2通りを扱っているので、底の値は2となる。すると、一番判断できないinfoの値は1で、明確に判断できる場合は0と単純にすることができる。

ここでは判断できない、ということを、すべての場合で確率が同じになる、と仮定した。この議論は後に一般的になされる。そこでは、一番エントロピー関数が最大値をとる場合、すべての確率が同じになる、という上の仮定が正しいことが確認される。

まず、花見をするうえで天気、風速、湿度のどれを最初に考えるかを判断する。

いずれの項目も考えない場合のエントロピーは

$$\begin{aligned}\text{info} &= -\frac{2}{5}\log_2\left(\frac{2}{5}\right) - \frac{3}{5}\log_2\left(\frac{3}{5}\right) \\ &= 0.971\end{aligned}\tag{8}$$

となる。

次に表3をもとに、単独の項目を考えた場合のそれぞれのエントロピーを考える。

まず天気について考える。

天気には水準として、晴れ、曇り、雨があり、それぞれになる確率は2/5、2/5、1/5である。これに対するエントロピーはこの確率を考慮して

$$\begin{aligned}\text{info}[\text{天気}] &= \frac{2}{5}\left[-\frac{1}{2}\log_2\left(\frac{1}{2}\right) - \frac{1}{2}\log_2\left(\frac{1}{2}\right)\right] \\ &\quad + \frac{2}{5}\left[-\frac{1}{2}\log_2\left(\frac{1}{2}\right) - \frac{1}{2}\log_2\left(\frac{1}{2}\right)\right] \\ &\quad + \frac{1}{5}\left[-\frac{0}{1}\log_2\left(\frac{0}{1}\right) - \frac{1}{1}\log_2(1)\right] \\ &= \frac{2}{5}\times 1 + \frac{2}{5}\times 1 + \frac{1}{5}\times 0 \\ &= 0.8\end{aligned}\tag{9}$$

と評価する。つまり、それぞれの水準に対してのエントロピーを計算し、その水準が起こる確率で重みづけして和をとる。

他の水準も同様に計算すると

$$\begin{aligned}\text{info}[\text{風速}] &= \frac{2}{5}\left[-\frac{0}{2}\log_2\left(\frac{0}{2}\right) - \frac{2}{2}\log_2\left(\frac{2}{2}\right)\right] \\ &\quad + \frac{3}{5}\left[-\frac{2}{3}\log_2\left(\frac{2}{3}\right) - \frac{1}{3}\log_2\left(\frac{1}{3}\right)\right] \\ &= \frac{2}{5}\times 0 + \frac{3}{5}\times 0.918 \\ &= 0.551\end{aligned}\tag{10}$$

$$\begin{aligned}
\text{info}[\text{湿度}] &= \frac{4}{5} \left[-\frac{2}{4} \log_2 \left(\frac{2}{4} \right) - \frac{2}{4} \log_2 \left(\frac{2}{4} \right) \right] \\
&\quad + \frac{1}{5} \left[-\frac{0}{1} \log_2 \left(\frac{0}{1} \right) - \frac{1}{1} \log_2 \left(\frac{1}{1} \right) \right] \\
&= \frac{4}{5} \times 1 + \frac{1}{5} \times 0 \\
&= 0.8
\end{aligned} \tag{11}$$

よって、各項目を考慮することによってエントロピーは減少していることがわかる。

表 3 単独項目に対する基本データ

		花見		
		Yes	No	合計
		2	3	5

天気			花見		
			Yes	No	合計
	晴れ		1	1	2
	曇り		1	1	2
	雨		0	1	1

		花見		
		Yes	No	合計
風速	強い	0	2	2
	弱い	2	1	3

		花見		
		Yes	No	合計
湿度	高い	2	2	4
	低い	0	1	1

ある項目を選択することによる効果はそのエントロピーの減少量をその項目のエントロピーで割った **gain ratio** で評価される。この値が大きいほど、その項目は有効である、と判断する。Gain だけで選択しないのは、info を 0.8 から 0.6 に減少させるよりも 0.4 から 0.2 に減少させるほうが大変であり、それをより評価するためである。極端な場合を考える。Info が 0.8 から 0.6 になった場合はエントロピーが 0.2 減ったことになる。しかしエントロピー 0.6 では何をすればいいのかははっきりしない。Info が 0.2 から 0 になる場合もエントロピーは同じく 0.2 減っているが info は 0 であるから何をすればいいのかははっきりしている。つまり減った先の info の値が小さい方が何をすればいいのかははっきりする。このことを表現す

るため、gain ではなく gain ratio を採用する。

各項目の gain ratio は以下のように評価される。

$$\begin{aligned}\text{gain ratio}[\text{天気}] &= \frac{\text{info-info}[\text{天気}]}{\text{info}[\text{天気}]} \\ &= \frac{0.971 - 0.8}{0.8} \\ &= 0.214\end{aligned}\tag{12}$$

$$\begin{aligned}\text{gain ratio}[\text{風速}] &= \frac{\text{info-info}[\text{風速}]}{\text{info}[\text{風速}]} \\ &= \frac{0.971 - 0.551}{0.551} \\ &= 0.762\end{aligned}\tag{13}$$

$$\begin{aligned}\text{gain ratio}[\text{湿度}] &= \frac{\text{info-info}[\text{湿度}]}{\text{info}[\text{湿度}]} \\ &= \frac{0.971 - 0.8}{0.8} \\ &= 0.214\end{aligned}\tag{14}$$

したがって項目としては風速を選択する。これにより、第一ステップの決定木が図 4 のように構成される。

風速が強い場合は info は 0 であるため、花見はやらない、となる。これに関しては判断は明確にできる。もし、風速が弱かった場合は info は 0.918 である。これは 1 に近いので、この場合は花見をするか、しないか判断できないということになる。したがって、次の段階にすすむことになる。




図 4 第一段階の決定木

表 4 風速弱いに注目した 2nd ステップの基本データ

天気	風速	湿度	花見
晴れ	強い	高い	No
曇り	弱い	高い	Yes
曇り	強い	低い	No
晴れ	弱い	高い	Yes
雨	弱い	高い	No

風速弱い

天気	湿度	花見
曇り	高い	Yes
晴れ	高い	Yes
雨	高い	No

風速弱い

花見		
Yes	No	合計
2	1	3

		花見		
		Yes	No	合計
天気	晴れ	1	0	1
	曇り	1	0	1
	雨	0	1	1

		花見		
		Yes	No	合計
湿度	高い	2	1	3
	低い	0	0	0

風力が弱い場合を抜き出した基本データを表 4 に示す。

これで同様な解析をしていく。

全体のエントロピーは

$$\begin{aligned} \text{info} &= -\frac{2}{3} \log_2 \left(\frac{2}{3} \right) - \frac{1}{3} \log_2 \left(\frac{1}{3} \right) \\ &= 0.918 \end{aligned} \quad (15)$$

となる。

天気の項目のエントロピーは

$$\begin{aligned}
\text{info}[\text{天気}] &= \frac{1}{3} \left[-\frac{1}{1} \log_2 \left(\frac{1}{1} \right) - \frac{0}{1} \log_2 \left(\frac{0}{1} \right) \right] \\
&\quad + \frac{1}{3} \left[-\frac{1}{1} \log_2 \left(\frac{1}{1} \right) - \frac{0}{1} \log_2 \left(\frac{0}{1} \right) \right] \\
&\quad + \frac{1}{3} \left[-\frac{0}{1} \log_2 \left(\frac{0}{1} \right) - \frac{1}{1} \log_2 \left(\frac{1}{1} \right) \right] \\
&= \frac{1}{3} \times 0 + \frac{1}{3} \times 0 + \frac{1}{3} \times 0 \\
&= 0
\end{aligned} \tag{16}$$

となる。

湿度の場合は水準が低い場合のデータが一つもない。この場合はデータの不備である。

この場合の扱いは様々であるが、ここでは対応するエントロピーを **0** とみなす。この扱いにおいては他のデータを操作する必要がない。**0** 以外の場合は他のデータをどう変形するか決まり事をつくる必要がる。項目の選択には利用するが、そのこと自体に対応する行動は保留にする。

$$\begin{aligned}
\text{info}[\text{湿度}] &= \frac{3}{3} \left[-\frac{2}{3} \log_2 \left(\frac{2}{3} \right) - \frac{1}{3} \log_2 \left(\frac{1}{3} \right) \right] \\
&= \frac{3}{3} \times 0.918 \\
&= 0.918
\end{aligned} \tag{17}$$

各項目の gain ratio は

$$\begin{aligned}
\text{gain ratio}[\text{天気}] &= \frac{\text{info} - \text{info}[\text{天気}]}{\text{info}[\text{天気}]} \\
&= \frac{0.918 - 0}{0} \\
&= \infty
\end{aligned} \tag{18}$$

$$\begin{aligned}
\text{gain ratio}[\text{湿度}] &= \frac{\text{info} - \text{info}[\text{湿度}]}{\text{info}[\text{湿度}]} \\
&= \frac{0.918 - 0.918}{0.918} \\
&= 0
\end{aligned} \tag{19}$$

となる。よって、天気を考えればいい。対応する決定木を図 5 に示す。また、これですべて確定しているので、湿度は考慮する必要がない。




図 5 第二段階の決定木

3.5. 目的変数の水準が複数ある場合

前節で目的変数が花見をする、しないの二つであった。それが複数ある場合について考える。まず 3 水準の場合を考える。それぞれに対応する確率を p_1, p_2, p_3 とする。ただし、送る場合はこの 3 種類のみで互いに排他的であるとする。すると

$$0 \leq p_1, p_2, p_3 \leq 1 \quad (20)$$

$$p_1 + p_2 + p_3 = 1 \quad (21)$$

が成り立つ。対応するエントロピー info は

$$\text{info} = p_1 \log_3 p_1 + p_2 \log_3 p_2 + p_3 \log_3 p_3 \quad (22)$$

となる。

ある項目を考える。その項目の水準が二つあり、それぞれの水準での目的変数の確率がわかっているものとする。するとその項目のエントロピーは

$$\begin{aligned} \text{info}[\text{項目}] = & r_A [p_{1A} \log_3 p_{1A} + p_{2A} \log_3 p_{2A} + p_{3A} \log_3 p_{3A}] \\ & + r_B [p_{1B} \log_3 p_{1B} + p_{2B} \log_3 p_{2B} + p_{3B} \log_3 p_{3B}] \end{aligned} \quad (23)$$

となる。

以上を踏まえて一般化ができる。

目的変数の水準を m 個、ある項目の水準を s 個とした場合、対応するエントロピーは

$$\text{info}[\text{項目}] = \sum_{j=1}^s r_j \sum_{i=1}^m p_{ij} \log_m p_{ij} \quad (24)$$

となる。

3.6. データが数値データである場合

これまでデータはカテゴリーデータであった。データとしては数値データである場合もある。この場合は数値データをカテゴリー化する。そのカテゴリー化の方法は二通りが考えられる。

3.6.1. カテゴリー化法 1 (two region model)

0 から 100 の数値データがある場合、領域を区分せずに、数値の小さい方から目的変数がいずれかに偏っている区切りの数値を探す。その区切りで数値データをそれ以下、それ以上とカテゴリー化し、これまでの解析をおこなう。または、数値の大きい方から目的変数がいずれかに偏っている区切りの数値を探す。その区切りで数値データをそれ以下、それ以上とカテゴリー化し、これまでの解析をおこなう。いずれかの小さいほうのエントロピー値をその項目のものとして採用する。

もし、その項目が選択されたら、目的変数の偏っている部分をすべて捨て去り、残りの部分のデータを利用し、解析をつづける。この場合でも他の項目の選択、データ削除の操作によって偏りの領域が発生するから、同一項目が複数回登場する可能性がある。しかし、データ領域が **overlap** することはない。この方法においてはプログラムで自動的に判断できる。

連続値をそのまま用いると、外れ値がある場合に、そこで区分が止まってしまう。したがって、連続値の場合は、ある程度の区切りをつけて区分した離散値に変更したほうがいいと考えている。そして判断する確率を有限の小さな値にしておけば、データに数個の外れ値があったとしてもそれを無視して解析を遂行できる。

以上のモデルのことを **two region model** と呼ぶ。

3.6.2. カテゴリー化法 2(regional model)

すなわち、0 から 100 の数値データがある場合、0-50 を低い、51-100 を高いとして、カテゴリー化する。区分は任意である。あとの取り扱いは同じである。この場合は同じ項目が複数回登場することはない。この方法においては、データを取得した後、どのようなカテゴリーに分類するかをその都度考えてデータ編集する必要がある。

以上のモデルのことを **regional model** と呼ぶ。

3.7. ジニ係数

ジニ係数はエントロピー関数と同様な性質を持ち、こちらもしばしば利用される。それは

$$I_G = 1 - \sum_{i=1}^m p_i^2 \quad (25)$$

で与えられる。ここで目的変数の水準数を m としている。この関数においても目的変数のどれかの水準の生起確率が 1 であれば 0 になる。最も判断しにくい、すべての水準の確率が同じである場合は

$$\begin{aligned} I_G &= 1 - \sum_{i=1}^m p_i^2 \\ &= 1 - m \left(\frac{1}{m} \right)^2 \\ &= 1 - \frac{1}{m} \end{aligned} \quad (26)$$

となる。これは 0 より大きいが 1 にはならない。つまり、水準数によってジニ関数の最大値は変動する(図 6)。




図 6 Gini 係数とエントロピー関数の比較

この問題を克服するにはジニ係数を

$$I_G = \frac{1 - \sum_{i=1}^m p_i^2}{1 - \frac{1}{m}} \quad (27)$$

のように変形すればいい。これによりジニ係数は目的変数の水準数によらず 0 から 1 の範囲を変動する。

さらには確率の累乗係数も 2 である必然性はない。1 より大きければ必要な性質は満足する。つまり、関数の一般形は

$$I_G = \frac{1 - \sum_{i=1}^m p_i^\gamma}{1 - m \left(\frac{1}{m} \right)^\gamma} \quad (28)$$

と表現されるであろう。

エラー! 参照元が見つかりません。に様々な γ におけるジニ係数を示す。目的変数の水準数は 2 と固定している。 γ が大きくなるほどジニ係数は大きくなる。すなわち、決定が困難になる。




図 7 様々な γ におけるジニ係数

これを水準数が s 項目 A に適用すると対応する関数は

$$I_G[\text{Factor A}] = \sum_{j=1}^s r_j \left[\frac{1 - \sum_{i=1}^m p_{ij}^\gamma}{1 - m \left(\frac{1}{m} \right)^\gamma} \right] \quad (29)$$

となる。これからエントロピーと同様 Gain ratio を定義できて

$$\text{Gain ratio}[\text{Factor A}] = \frac{I_G - I_G[\text{Factor A}]}{I_G[\text{Factor A}]} \quad (30)$$

となる。あとはエントロピー関数と同様な解析となる。

3.8. 新たなエントロピーの関数形

カテゴリーデータの決定木の場合はエントロピーを導入した。これは生起確率が 0,1 の場合は 0 になり、それ以外では 0 より大きくなる。さらに使われている log 関数の底を目的変数の水準数にすれば、全てのエントロピーの総和の最大値は 1 になることを保障する。この関数を利用するおかげで、エントロピーが 0 に近いのか、1 に近いかで決定木を構成できる。

上で本質的なのは生起確率が

- 0,1 の場合は 0 になり、それ以外では 0 より大きくなる
- 全水準のエントロピーの総和が 1 になる

ということである。

この関数で問題があるとすれば各エントロピー成分の最大値が生起確率 0.5 でなく 0.37 で得られるということである。このエントロピーの望ましい性質を保持した状態で、この課題を克服できる他の関数形があるか検討する。

info として

$$\text{info} = \alpha \sin^\gamma(\pi p) \quad (31)$$

を提案する。これは先に導入したエントロピーと同様に生起確率が 0,1 の場合は 0 になり、それ以外では 0 より大きくなる。さらに $p=1/2$ で最大値を持つという望ましいと思われる性質を持っている。 γ はパラメータであり、関数上の性質を保った状態で関数の形状を変化させる。 α は係数であり、何の値であっても上の性質を乱さない。あとは、全水準のエントロピーの総和の最大値が 1 である、という性質を係数で調整する。

目的変数の水準が 2 個の場合はトータルの info は

$$\text{info} = \alpha \sin^\gamma(\pi p_1) + \alpha \sin^\gamma(\pi p_2) \quad (32)$$

となる。ただし

$$p_1 + p_2 = 1 \quad (33)$$

である。この場合の info の最大値は

$$p_1 = p_2 = \frac{1}{2} \quad (34)$$

で得られる。この場合の info を 1 になるようにしたい。それは

$$\begin{aligned}
\text{info}_{\max} &= \alpha \sin^{\gamma} \left(\frac{\pi}{2} \right) + \alpha \sin^{\gamma} \left(\frac{\pi}{2} \right) \\
&= 2 \sin^{\gamma} \left(\frac{\pi}{2} \right) \alpha \\
&= 1
\end{aligned} \tag{35}$$

より

$$\alpha = \frac{1}{2 \sin^{\gamma} \left(\frac{\pi}{2} \right)} = \frac{1}{2} \tag{36}$$

となる。したがって、**info** は

$$\text{info} = \frac{1}{2} \sin^{\gamma} (p\pi) \tag{37}$$

と定義されるであろう。

目的変数の水準数が m の場合は

$$\text{info} = \frac{1}{m} \frac{\sin^{\gamma} (p\pi)}{\sin^{\gamma} \left(\frac{\pi}{m} \right)} \tag{38}$$

と置けばいい。

既存モデルと提案モデルの第 1 項の比較を図 8 に示す。既存モデルは確率に低い方にバイアスがかかっているが、提案モデルは対称である。

既存モデルと提案モデルの全体の比較を図 9 に示す。両モデルともに対称である。提案モデルの方は γ で関数の形状を変化させることができる。 $\gamma=0.5$ で既存モデルと提案モデルはほぼ一致する。 $\gamma=1$ 以上では提案モデルが常に小さなエントロピー値を示すことがわかる。




図 8 様々な α におけるエントロピーの第 1 項。点線は既存モデル




図 9 $\alpha = 2$ における提案エントロピーと既存モデルの比較

目的変数の水準を m 個、ある項目の水準を s 個とした場合、対応するエントロピーは

$$\text{info}[\text{項目}] = \sum_{j=1}^s r_j \sum_{i=1}^m \frac{1}{m} \frac{\sin^\gamma(p_{ij}\pi)}{\sin^\gamma\left(\frac{\pi}{m}\right)} \quad (39)$$

となる。ただし

$$\sum_{i=1}^m p_{ij} = 1 \quad (40)$$

である。

3.9. エントロピー最大条件の評価

これまではエントロピーが最大になる条件をどの確率も一定になると仮定してきた。ここでそれを証明しておく。

まず水準数が 3 個場合の図 10 に示す通常のモデルを考える。

この場合は

$$\text{info} = -p_1 \log_3 p_1 - p_2 \log_3 p_2 - p_3 \log_3 p_3 \quad (41)$$

となる。ただし、

$$p_1 + p_2 + p_3 = 1 \quad (42)$$

である。この条件で実際に p_1, p_2, p_3 を変動させたものを図に示す。確かに $p_1 = p_2 = p_3 = \frac{1}{3}$ で最大値をとるように見える。




図 10 通常モデルで目的変数の水準数が 3 の場合

一方、図 11 に示す新しいモデルでも同様にすると、

$$\text{info} = \frac{1}{3} \frac{\sin(p_1\pi)}{\sin\left(\frac{\pi}{3}\right)} + \frac{1}{3} \frac{\sin(p_2\pi)}{\sin\left(\frac{\pi}{3}\right)} + \frac{1}{3} \frac{\sin(p_3\pi)}{\sin\left(\frac{\pi}{3}\right)} \quad (43)$$

として、実際に p_1, p_2, p_3 を変動させたものを図に示す。確かに $p_1 = p_2 = p_3 = \frac{1}{3}$ で最大値をとるように見える。




図 11 new モデルで目的変数の水準数が 3 の場合

一般に水準数 m の各水準のエントロピー関数を $\text{info}_m(p)$ とおくと、エントロピーは

$$\text{info} = \sum_{i=1}^m \text{info}_m(p_i) \quad (44)$$

となる。ここで確率に対しては

$$\sum_{i=1}^m p_i = 1 \quad (45)$$

という制約条件がある。したがって、対応するルジャンドル関数 L は

$$L = \sum_{i=1}^m \text{info}_m(p_i) - \lambda \left(1 - \sum_{i=1}^m p_i \right) \quad (46)$$

となる。したがって、これを p_1 で微分すると

$$\frac{\partial L}{\partial p_1} = \frac{\partial \text{info}_m(p_1)}{\partial p_1} + \lambda = 0 \quad (47)$$

となる。これは他のどの確率 p_i についても成り立たなければならない。したがって、

$\frac{\partial \text{info}_m(p_1)}{\partial p_1}$ は定数にならなければならない。よって、 p_i はすべて等しい。それを p_0 とする。

一方、

$$\frac{\partial L}{\partial \lambda} = -\left(1 - \sum_{i=1}^m p_i\right) = 0 \quad (48)$$

より、

$$\sum_{i=1}^m p_i = 1 \quad (49)$$

となる。したがって、

$$\sum_{i=1}^m p_i = mp_0 = 1 \quad (50)$$

これから

$$p_0 = \frac{1}{m} \quad (51)$$

が導かれる。

3.10. 解析の終端

3.11. カテゴリーデータの場合の解析終端

解析をどのステップまですすめていくかを検討する必要がある。

上に述べたように $\text{info} = 0$ となれば、やることは明確になる。しかし、そこにいたるまでに多くのプロセスを経る必要がある場合がある。 $\text{info} = 0$ でなくてもある程度小さな値になれば、決定できるとみなす。その臨界値を info^* とし、 info がそれ以下になれば解析を打ち切る。臨界値は確率 p と連動させることができる。もし、確率 p_c で判断できるとする。 info^* は、提案モデルでは

$$\text{info}^* = \frac{1}{2} \sin(p_c \pi) + \frac{1}{2} \sin((1 - p_c) \pi) \quad (52)$$

となる。ここでは、 p_c を 1 に近い方の値とする。すなわち、 p が p_c より大きいのか、 $1 - p_c$ より

小さいならば、判断できるとし解析を打ち切る。これ以外であれば、次の項目を考える。

また、ステップ数がすすむにつれデータ数が少なくなっていく。データが少なくなってくると判断した確率の誤差が大きくなる。このことは以下のように考慮できる。

この場合の標準偏差は

$$\sqrt{\frac{p_c(1 - p_c)}{N}} \quad (53)$$

である。ただし N はある項目のある水準のデータ数である。したがって、これが $1 - p_c$ より小さければいいとする。

$$\xi = \frac{\sqrt{\frac{p_c(1 - p_c)}{N^*}}}{1 - p_c} \quad (54)$$

とする。ここで ξ はどの程度小さくするかを表現するパラメータである。ここでは **default** として **0.5** とする。すると

$$N^* = \frac{1}{\xi^2} \frac{p_c}{1-p_c} \quad (55)$$

となる。水準のデータ数がこれ以下になったら、解析は判断できない、で終端する。

3.12. 数値の場合の解析終端

数数値データの場合解析をどのステップまですすめていくかを検討する。

全ての項目において区分できなければ、そこで終わる。

また、ステップ数がすすむにつれデータ数が少なくなっていく。したがって、分割できるとした水準においても、分割領域の総データ数が基準値 N^* 以下になったら分割できない、とみなす。つまり、判別できるとして分割された領域の総データ数が

$$N^* = \frac{1}{\xi^2} \frac{p_c}{1-p_c} \quad (56)$$

以下になったら、判断できない、とする。つまり、分割はできない、とする。そして、同じように全ての項目において、分割できなければ、そこで終わる。

3.13. 新たなエントロピー関数による融資可非解析(two region model)

前節のエントロピー関数(式(39))で具体的にデータ分析をしていく。ここでは $\gamma=1$ とする。

例として銀行メンバーがお客に融資をするかどうかを考える。この場合、融資をするかどうかを考える項目としてリスク、金額、返済期間、利率を改定する。ここでリスクはお客の信用度を総合評価したものである。職業、年収、勤続年数、家族構成、持ち家の5項目をそれぞれ5点満点で信用度を評価し、その総合点をリスクとする。したがって、リスクは0から25の数値になる。

この場合は説明変数は数値であるから、その区切りをカテゴリー化法1で行う。

判断できる、できないの確率は0.1以下か0.9以上とする。

リスクは多いほど融資する確率は高くなるから、リスク値の下限に対応する判断確率は0.1、上限に対応する判断確率は0.9である。

金額は大きいほど融資する確率は低くなるから、金額値の下限に対応する判断確率は0.9、上限に対応する確率は0.1である。

期間は長いほど融資する確率は高くなるから、期間値の下限に対応する判断確率は0.1、上限に対応する判断確率は0.9である。

金利は高いほど融資する確率は高くなるから、金利値の下限に対応する判断確率は0.1、上限に対応する判断確率は0.9である。

以上をまとめたものを表 5 に示す。

表 5 各項目の数値範囲と判別確率

	リスク	判別確率	金額	判別確率	期間	判別確率	利率	判別確率
Start	0	0.1	10	0.9	1	0.1	3	0.1
↓	↓		↓		↓		↓	
Stop	25	0.9	500	0.1	10	0.9	3.5	0.9
Step	1		10		1		0.1	

まず、項目としてリスクを考える。この場合はリスクと審査結果をペアで考える。

リスクをリスク値に関して昇順にソートする。ソートして、審査結果が 1 である累積確率を評価する。リスク値の水準値終端位置で判別確率 0.1 を越えない水準値を探す。結果を表 6 に示す。リスク 13 では累積確率は 0.1 を超えていないが、14 では超えている。したがって、下限の区切りは 13 とする。

表 6 各項目の数値範囲と判別確率

リスク	審査	累積確率
13	1	0.091
13	1	0.092
13	1	0.092
13	1	0.093
13	1	0.094
13	1	0.094
14	0	0.094
14	0	0.094
14	0	0.094
14	0	0.094
14	0	0.094
14	0	0.149
14	1	0.154
14	1	0.146
14	1	0.140
14	1	0.133
14	1	0.128
14	1	0.125
15	0	0.122
15	0	0.120
15	0	0.118
15	0	0.115

この判断をプログラム上では以下のように判定している。

リスクの値を読み込み、次のリストのリスト値を同じであれば 0、違えば 1 を立てる。

最後のものには1を立てる。すると、リストの区切り終端位置に1が立つことになる。

このモニターを最初からみていく。1が立っている位置の累積確率を評価し、それが0.1を超えていなければその行数をモニターする。もし0.1を超えていれば判断ループから抜ける。したがって、モニターされた位置はリスクの区切り位置となる。また、その位置以下では融資可の確率は0.1以下であることが保障される。最初の水準で累積確率が0.1を超えていれば分離不可とする。

臨界確率が0.1でなく、0.9の場合は、累積確率が0.9以上であれば区切りとし、超えていれば区切りとしない、という判断に代えて同様に区切り位置を探す。

この区切りを評価後は、区切ったリスクデータに関して計算する（表7）。

表7 リスク下限の評価値

リスク下限				
項目	領域1(判別領域)		領域2	
範囲	0 - 13		14 - 25	
領域比率	0.538		0.462	
水準	1	0	1	0
水準データ数	132	1268	869	331
$p_1, 1-p_1$	0.094	0.906	0.724	0.276
infoTermLevel	0.292		0.762	
infoTerm	0.509			

先に述べたように、この場合の区切りは13である。領域1に対応する0-13はデータ数の比率が0.538、それ以上の14から25の値の範囲である領域2のデータ数は0.462である。つまり、約半分に分離されている。

第一領域の融資可のデータ数は132で、不可は1268で圧倒的に不可が多い。これに対応する融資可確率 p_1 は0.094と狙いどおり0.1以下となっている。

これに対応するエントロピーは

$$\begin{aligned} \text{info}[\text{リスク:領域1}] &= \frac{1}{2} \sin(0.094\pi) + \frac{1}{2} \sin((1-0.094)\pi) \\ &= 0.292 \end{aligned} \quad (57)$$

第二領域の融資可のデータ数は869で、不可は331で圧倒的にどちらが多いとはいえない。これに対応する融資可確率 p_1 は0.724となっている。

これに対応するエントロピーは

$$\begin{aligned} \text{info}[\text{リスク:領域2}] &= \frac{1}{2} \sin(0.724\pi) + \frac{1}{2} \sin((1-0.724)\pi) \\ &= 0.762 \end{aligned} \quad (58)$$

よって、リスク下限に対するトータルのエントロピーは

$$\begin{aligned}\text{info}[\text{リスク}] &= 0.538 \times \text{info}[\text{リスク:領域1}] + 0.462 \times \text{info}[\text{リスク:領域2}] \\ &= 0.509\end{aligned}\tag{59}$$

となる。

これを、区切りの上限に対しても行い、さらにその他の項目に対しても行う。

それをまとめたものを表 8 に示す。もっとも小さなエントロピー関数を示すリスク下限を選択する。したがって、リスク 0-13 のデータを削除し、同様なプロセスを繰り返していく。

表 8 リスク下限の評価値のまとめ

項目	リスク		金額		期間		金利	
	下限	上限	下限	上限	下限	上限	下限	上限
範囲	0-13	25-20	不可	500	不可	不可	不可	不可
infoTerm	0.509	0.575		0.929				

第 6 ステップまでの計算結果を表 9 に示す。

ステップがすすむにつれ対応するデータ数が減少していくことがわかる。

表 9 評価値のまとめ

【Step1】

全体		
全データ数	2600	
水準	1	0
水準データ数	1002	1598
p_1	0.385	
info	0.936	

【Step2】

全体		
全データ数	1200	
水準	1	0
水準データ数	870	330
p_1	0.725	
info	0.760	

【Step3】

全体		
全データ数	600	
水準	1	0
水準データ数	327	273
p_1	0.545	
info	0.990	

【Step4】

全体		
全データ数	443	
水準	1	0
水準データ数	312	131
p_1	0.704	
info	0.801	

【Step5】

全体		
全データ数	133	
水準	1	0
水準データ数	23	110
p_1	0.173	
info	0.517	

【Step6】

全体		
全データ数	44	
水準	1	0
水準データ数	15	29
p_1	0.341	
info	0.878	

リスク下限

項目	領域1(判別領域)		領域2	
範囲	0 - 13		14 - 25	
領域比率	0.538		0.462	
水準	1	0	1	0
水準データ数	132	1268	869	331
$p_1, 1-p_1$	0.094	0.906	0.724	0.276
infoTermLevel	0.292		0.762	
infoTerm	0.509			

リスク上限

項目	領域1(判別領域)		領域2	
範囲	25 - 20		19 - 14	
領域比率	0.500		0.500	
水準	1	0	1	0
水準データ数	543	57	326	274
$p_1, 1-p_1$	0.905	0.095	0.543	0.457
infoTermLevel	0.294		0.991	
infoTerm	0.642			

金額上限

項目	領域1(判別領域)		領域2	
範囲	500 - 370		360 - 10	
領域比率	0.262		0.738	
水準	1	0	1	0
水準データ数	15	142	311	132
$p_1, 1-p_1$	0.096	0.904	0.702	0.298
infoTermLevel	0.296		0.805	
infoTerm	0.672			

金利上限

項目	領域1(判別領域)		領域2	
範囲	3.5 - 3.2		3.1 - 3	
領域比率	0.700		0.300	
水準	1	0	1	0
水準データ数	289	21	22	111
$p_1, 1-p_1$	0.932	0.068	0.165	0.835
infoTermLevel	0.211		0.497	
infoTerm	0.297			

リスク下限

項目	領域1(判別領域)		領域2	
範囲	14 - 17		18 - 19	
領域比率	0.669		0.331	
水準	1	0	1	0
水準データ数	8	81	14	30
$p_1, 1-p_1$	0.090	0.910	0.318	0.682
infoTermLevel	0.279		0.841	
infoTerm	0.465			

金利下限

項目	領域1(判別領域)		領域2	
範囲	3 - 3		3.1 - 3.1	
領域比率	0.364		0.636	
水準	1	0	1	0
水準データ数	0	16	14	14
$p_1, 1-p_1$	0.000	1.000	0.500	0.500
infoTermLevel	0.000		1.000	
infoTerm	0.636			

図 12 に新モデルによる決定木を示す。




図 12 新モデルによる決定木(two regional model)

これにより、与えられた条件で、融資可か不可か判断できないか、のいずれになるのか
明白にできる。

一方、逆に融資不可、融資可の条件範囲を結果から読み取ることができる。表 10 にそ
れを示す。

表 10 融資可不可条件領域

融資不可

リスク	金額	金利
0-13	10-360	3
14-16	370-500	3.1
17-19		3.2-3.5
20-25		

融資可

リスク	金額	金利
0-13	10-360	3
14-16	370-500	3.1
17-19		3.2-3.5
20-25		

リスク	金額	金利
0-13	10-360	3
14-16	370-500	3.1
17-19		3.2-3.5
20-25		

リスク	金額	金利
0-13	10-360	3
14-16	370-500	3.1
17-19		3.2-3.5
20-25		

リスク	金額	金利
0-13	10-360	3
14-16	370-500	3.1
17-19		3.2-3.5
20-25		

リスク	金額	金利
0-13	10-360	3
14-16	370-500	3.1
17-19		3.2-3.5
20-25		

3.14. 新たなエントロピー関数による融資可非解析(Regional model)

前節と同じ問題を regional model で解析する。

もとのデータはいろいろな数値であるが、これらをすべて5つの水準に区分けする。(区分けの仕方は任意であるが、ここでは簡単化のため同一にしておく)

この場合の結果を示す。1st ステップとしては項目リスクが最小の info を提供するため、まずこれを検討する。レベル 1,2 では融資不可、レベル 5 では融資可となる。レベル 3,4 では判定できない。このため、レベル 3,4 についてのそれぞれ次の項目を考える。

リスクでレベル 3 のデータを考える。この場合は次に考える項目は利率になる。レベル 1 に対しては融資しない、ということになる。のこりの水準でのデータ数は 100 以下であるので、このデータでは水準分けした場合、各水準のデータ数が臨界値を下回るためここまでである。

リスクでレベル 4 のデータを考える。この場合は次に考える項目は金額になる。金額レベル 5 に対しては融資しない、ということになる。のこりの水準でのデータ数は 100 以下であるので、このデータでは水準分けした場合、各水準のデータ数が臨界値を下回るためこ

こまでである。

3.15. 新たなエントロピー関数による融資可非解析(Regional model)

前節と同じ問題を regional model で解析する。

もとのデータはいろいろな数値であるが、これらをすべて5つの水準に区分けする。(区分けの仕方は任意であるが、ここでは簡単化のため同一にしておく)

この場合の結果を示す。1st ステップとしては項目リスクが最小の info を提供するため、まずこれを検討する。レベル 1,2 では融資不可、レベル 5 では融資可となる。レベル 2,3 では判定できない。このため、レベル 2,3 についてのデータ全体に対して、次の項目を考える。

次の項目としては金額が最低の info を与える。金額のレベル 5 に関しては融資しない、と判別できる。その他のレベルは判別できない。この金額レベル 1 から 4 に関しては次の項目を考慮しても判別できない。したがって、解析は表 11 となる。

その結果を決定木で示したものが図 13 である。

表 11 評価値のまとめ

リスク					
Region	1	2	3	4	5
Region data number	600	500	500	500	500
Region ratio	0.23	0.19	0.19	0.19	0.19
Accept probability	0	0.092	0.342	0.644	0.924
Info	0.00	0.29	0.88	0.90	0.24
TermInfo	0.44				

金額					
Region	1	2	3	4	5
Region data number	200	200	200	200	200
Region ratio	0.2	0.2	0.2	0.2	0.2
Accept probability	0.69	0.69	0.64	0.4	0.045
Info	0.83	0.83	0.90	0.95	0.14
TermInfo	0.73				




図 13 新モデルによる決定木(regional model)

3.16. ランダムフォレスト

決定木では結論、つまり目的変数の選択される水準はデータによって大きく変更する、という問題がある。データの中に変なものが含まれているとそれに結果が日本津られ手しまうという問題がある。

この問題を解くために提案されたものがランダムフォレストである。これは基本的にやることは決定木と同じである。

ランダムフォレストでは決定木で利用したデータから復元抽出で多数のサンプルデータを作成する。そのサンプルデータを利用して決定木分析をする。例えば 5 種類のサンプルデータを作成した場合、それぞれから 5 種類の決定木を得ることになる。

ある説明変数のセットが与えられた場合、それを 5 種類の決定木にかけると、目的変数のどれかの水準がそれぞれ選択されることになる。その選ばれた水準に対して多数決でどの水準にするか決定する。これがランダムフォレストである。

3.17. プロセスがはっきりしている場合の決定木分析

プロセスの流れがはっきりしている場合の決定木分析の具体例を考えよう。

目の前に商談 A、B があり、そのどちらを選択するかを考える。

商談 A は確実に製品を 50 台納入できる。

商談 B は 30% の確率で受注でき、その場合は 100 台納入できる。受注できない場合は 30

台の納入となる。

以上を決定木で描くと図 14 になる。




図 14 商談の場合の決定木

Decision tree は左から右にかけて時間が経過するように描かれる。

何らかの選択が必要な場合は□で表現する。

ある確率に従って起こりうる複数のイベントがある場合は○で表現する。

結果を描いて終端する。

□は人間の意志が関わるイベントでこの中から選択する作業がある。

○は人間の意志とは無関係に起こるイベントでここでは選択作業はない。

まず左から右に向かっていくと最初に□に突き当たる。ここで商談 A か B か選択する。

もし商談 A を選択すれば 50 台納入となる。

もし商談 B を選択すると、次に○に突き当たる。この○は 2 つの起こりうるイベントにつながっている。70%の確率で受注できず、30%の確率で受注できる。

もし受注できなければ 30 台の納入となり、受注できれば 100 台の納入となる。

次に期待値を評価する。

期待値は□に対して評価する。

商談 A を選択した場合の期待値は 50 である。

商談 B を選択した場合の期待値は

$$30 \times \frac{70}{100} + 100 \times \frac{30}{100} = 51 \quad (60)$$

である。したがって、商談 A を選択すればいいことになる。Decision tree では選択した枝を

太くする。

この場合の決定の利用の仕方はあきらかである。目的変数を最大にするためには、どの行動をとればいいかが太線で示されている。□以下の線は自分で選択でき、○以下は自分では選択できず、確率的に起こる。

この場合は各プロセスにおける確率、得られる結果の数値データが必要となる。

3.18. エントロピーに対する他の簡単な関数形

info として

$$\text{info} = \alpha p(1-p) \quad (61)$$

を検討する。これは先に導入したエントロピーと同様に生起確率が 0,1 の場合は 0 になり、それ以外では 0 より大きくなる。さらに $p=1/2$ で最大値を持つという望ましいと思われる性質を持っている。 α は係数であり、何の値であっても上の性質を乱さない。あとは、全水準のエントロピーの総和の最大値が 1 である、という性質を係数で調整する。

目的変数の水準が 2 個の場合はトータルの info は

$$\text{info} = \alpha p_1(1-p_1) + \alpha p_2(1-p_2) \quad (62)$$

となる。ただし

$$p_1 + p_2 = 1 \quad (63)$$

である。この場合の info の最大値は

$$p_1 = p_2 = \frac{1}{2} \quad (64)$$

で得られる。この場合の info を 1 になるようにしたい。それは

$$\begin{aligned} \text{info}_{\max} &= \alpha \frac{1}{2} \left(1 - \frac{1}{2}\right) + \alpha \frac{1}{2} \left(1 - \frac{1}{2}\right) \\ &= 2 \times \frac{1}{2} \left(1 - \frac{1}{2}\right) \alpha \\ &= 1 \end{aligned} \quad (65)$$

より

$$\alpha = \frac{1}{2 \times \frac{1}{2} \left(1 - \frac{1}{2}\right)} \quad (66)$$

となる。したがって、info は

$$\text{info} = \frac{1}{2 \times \frac{1}{2} \left(1 - \frac{1}{2}\right)} p(1-p) \quad (67)$$

と定義されるであろう。

目的変数の水準数が m の場合は

$$\begin{aligned}
 \text{info} &= \frac{1}{m \times \frac{1}{m} \left(1 - \frac{1}{m}\right)} p(1-p) \\
 &= \frac{1}{1 - \frac{1}{m}} p(1-p) \\
 &= \frac{m}{m-1} p(1-p)
 \end{aligned} \tag{68}$$

と置けばいい。




図 15 様々な α におけるエントロピーの第 1 項。点線は既存モデル

既存モデルと提案モデルの比較を図 15 に示す。既存モデルは確率の低い方にバイアスがかかっているが、提案モデルは対称である。

目的変数の水準を m 個、ある項目の水準を s 個とした場合、対応するエントロピーは

$$\text{info}[\text{項目}] = \sum_{j=1}^s r_j \sum_{i=1}^m \frac{m}{m-1} p_{ij} (1-p_{ij}) \tag{69}$$

となる。ただし

$$\sum_{i=1}^m p_{ij} = 1 \quad (70)$$

である。

3.19. 熱物理のエントロピーとの対応

エントロピーはもともと熱物理学において定義され利用されてきたものである。ここでは、熱物理におけるエントロピーを紹介し、それとここでのエントロピーと比較する。

エントロピー S は熱物理においては以下のように定義される。

$$S = k_B \ln W \quad (71)$$

ここで k_B はボルツマン係数、 W は場合の数である。エントロピーは増大していく方向にあるとする。つまり、場合の数の大きい状態になっていく、ということを表している。

一方、ここで扱っている情報量と関連するエントロピーは以下のように定義されている。

全体と事象は二つのことが起こるとする。その二つの事象を E_1 、 E_2 とする。あること E_1 が起こったとことを知る前の場合の数 $W_T(E) = W_T(E_1 + E_2)$ と知ったあとの場合の数 $W(E_1)$ の比は、

$$p(E_1) = \frac{W(E_1)}{W_T(E)} \quad (72)$$

と表現される。確率は 1 より小さい値である。この場合、事象 E_1 が起こった場合の得た情

報量 $I(E_1)$ を

$$\begin{aligned} I(E_1) &= \log \frac{1}{P(E_1)} \\ &= -\log P(E_1) \\ &= -\log \frac{W(E_1)}{W_T(E)} \\ &= \log W_T(E) - \log W(E_1) \end{aligned} \quad (73)$$

とする。つまり、ボルツマン係数を無視して、熱力学と同じように場合の数の対数関数形式になるように定義している。事象 E が起こる確率は $P(E_1)$ であるから、この情報量を得る確率は

$$\begin{aligned} P(E_1)I(E_1) &= -P(E_1)\log P(E_1) \\ &= P(E_1)\log W_T(E) - P(E_1)\log W(E_1) \end{aligned} \quad (74)$$

となる。すべての場合に関しての情報量 info は平均情報量と呼ばれ

$$\begin{aligned}
\text{info} &= -P(E_1)\log P(E_1) - P(E_2)\log P(E_2) \\
&= P(E_1)\log W_T(E) - P(E_1)\log W(E_1) + P(E_2)\log W_T(E) - P(E_2)\log W(E_2) \\
&= [P(E_1) + P(E_2)]\log W_T(E) - [P(E_1)\log W(E_1) + P(E_2)\log W(E_2)] \\
&= \log W_T(E) - \langle \log W(E_i) \rangle
\end{aligned} \tag{75}$$

となる。ここで、

$$\langle \log W(E_i) \rangle = P(E_1)\log W(E_1) + P(E_2)\log W(E_2) \tag{76}$$

は、現在の状況の平均的な $\log W$ である。

イベント数が m の場合は

$$\begin{aligned}
\text{info} &= -\sum_{i=1}^m P(E_i)\log P(E_i) \\
&= \log W_T(E) - \langle \log W(E_i) \rangle
\end{aligned} \tag{77}$$

と同じような形式で表現される。

以上のように、この情報量のエントロピーは、熱力学で利用されているエントロピーと同様に場合の数の対数形式で表現されている。先の解析で示したように、決定できない場合は **info** は大きく、つまりエントロピーは大きい、決定できる場合は **info** は小さい、つまりエントロピーは小さい、と定性的にも一致するように定義されている。

3.20. まとめ

決定木の解析法をまとめた。

プロセスの流れがはっきりしていない場合は、エントロピーを定義し、**Gain** 比が大きい項目から順に決定木を構成していき、エントロピーが所望の値以下になるまで続ける。

説明変数が与えられたものであり、変更できない場合は、その説明変数の水準を決定木の上の階層から辿っていき、終端したところの目的変数の水準を得る。これにより、目的変数の何をすればいいのかわかる。

説明変数がコントロールできるものであり、目的変数の水準のあるものを得たいとする場合を考える。この場合は決定木の終端しているところの目的変数の所望の水準が決定されている最小の階層を選択する。それを上に辿っていけば、各項目でどの水準を選択すればいいのかわかる。

この場合は各項目の水準に対するカテゴリーデータを利用する。データが数値の場合はカテゴリー化する。

エントロピー関数と同様な役割を演ずるジニ係数の紹介もした。さらにその一般化したものも示した。

ここで導入したエントロピー関数は生起確率が 0.5 で最大値にならない。これを修正し

た関数を提案した。

プロセスの流れがはっきりしている場合は、判断が必要な部分と確率的に決まる部分を明記して、期待値にもとづいて決定木を構成する。期待値を最大にする行動は太線で示されているからそれに沿った行動をとればいい。この場合は各プロセスにおける生起確率、およびその場合の得られる結果の数値データが必要である。