

6. PLSA

概要: PLSA は Probabilistic latent semantic analysis の略である。これはテキストデータから何が必要なのか Hofman が 1999 年に発表した解析手法である。

キーワード: PLSA; カテゴリーデータ

6.1. 序

今日では SNS 等で大量のテキストデータが安価に容易に入手できるようになった。テキストのビックデータから有用な情報を引き出す手法として PLSA が提案されている。PLSA は Probabilistic latent semantic analysis の略である。これは Hofman が 1999 年に発表した解析手法である。これにより、目的を達成するためには何をすればいいのかが明らかになる。

6.2. テキストデータ解析一般論

SNS やコールセンターの応対等に関連する大量のテキストデータは、ある客の記録、または客および客に対応する人との応答記録からなる。それは、一つのセルに任意の複数の文章からなるテキストデータの集合である。

このテキストデータで、何を言っているのかが問題になる。

このテキストデータから単語を抜き出したものが基本データとなる。つまり、データの基本的な塊は、一つの応答記録とそれから抜き出した単語となる。このデータから必要な情報を引き出すためにはいくつかの課題がある。

単語に関しては、たとえば「良い」ということは、テキストデータ上ではさまざまな表現形態が存在する。「結果に満足している」「またお願いしたい」「良い」などが「良い」に対応するデータであるが、これらが同じものを表現していると機械が認識するのは容易ではない。そのため、これらの変換をするための辞書が作成されている。すなわち、テキストデータ解析を有効にするためには辞書作成が必須となる。

文章から単語を抽出し、その出現頻度をみれば、その文章がどの話題と関連しているかわかる場合がある。しかし、単語の出現頻度だけでその文章が何を話題にしているのか同定するのは困難である場合が一般的である。複数の話題で共通に利用される単語があるためである。そのため、話題と関連させるために単語だけではなく、他の単語との関連、つまり共起の状況をみるというのが一般的である。しかし、違う話題で共通の共起も存在する。また同じ話題でさまざまな共起の可能性もある。そのため、単語や共起の状況を詳しく把握し、話題と関連づける、ということが検討されている。

PLSA は後者のトピックと単語の関連づけに対して特徴のある解析手法である。PLSA では共起そのものを扱わない。あるトピックの場合、そのトピックに関連する単語の利用され

る分布の確率を同定する。ここでは、PLSA の解析手法を解説する。

6.3. 潜在意味の定性的説明

統計的潜在意味解析とは、データに潜む意味（トピック）を統計的に抽出する手法である。

一つの文章からなるテキストデータは単語の集合体と考えることができる。その文章がある内容（トピック）について書かれているとするならば、対応する単語の分布があるはずである。つまり文章のトピックと単語の生起は連動しているはずである。また、あるトピックが選択された場合、関連する単語が必ず生起するとは限らず、そのトピックと関連する単語群の中から確率的に選択される、と考える。単語同士の同時生起、つまり共起は確率の高い単語同士は共起しやすいと捉え共起そのものは扱わない。例えば、潜在的トピックとして音楽、演劇、スポーツがあるとする。文章がそれぞれについてのものであれば、対応する単語群が変わってくるはずである。トピック自体はテキストデータに直接あらわれることは一般にはないため、それは潜在的である、と言われる。つまりテキストデータ解析においては、データに直接的には表れないトピックをどう定量的に導き出すのかが大きなテーマとなる。

6.4. PLSA の発見法的説明

ここでは簡単な文書について PLSA では何をやっているのか見ていく。

PLSA においては文書のトピックを同定することが最大の目標であるが、ここではそのトピックがわかっているものとして PLSA を説明する。そのため PLSA でやっている解析そのものではないが、それを仮定することで PLSA の解析の流れを説明する。

表 1 に示すような文書から単語を抽出したデータがあったとする。

表 1 トピックつき元データ

元データ

	Topic	drive	automobile	car	play	music
文書1	Topic1	2	3	0	0	0
文書2	Topic1	2	0	2	0	0
文書3	Topic2	0	0	0	2	2
文書4	Topic2	0	0	0	3	1

文書 1,2 ともに drive が 2 個ずつある。また、文書 1 には automobile は生起しているが、car はなく、文書 2 には automobile はなく、car が生起している。したがって、文書 1,2 は車関連の文章だと想像できる。

文書 3,4 には car 、drive や automobile はなく、play、music が生起している。したがって、文書 3,4 は音楽関連の文書だと想像できる。

つまり、上の文書では車と音楽の 2 種類のトピックを扱ったデータとみなすことができる。

再び文書 1,2 を考える。文書 1 における”car”の出現頻度は 0 になっているため”car”で検索しても文書 1 は見つけることはできない。また、文書 2 における”automobile”の出現頻度が 0 であるため、同様に”automobile”で検索した場合、文書 2 は見つけることができない。文書 1 には”automobile”があるため、文書 1 は検索できる。つまり、共起という観点からすると文書 1 は drive と automobile、文書 2 は drive と car が共起として検索される。したがって、文書 1 と文書 2 は共起の観点からすると別の種類になる。

この例に関して発見法的に PLSA を半定量的に説明する。

最初の例で文書 1,2 はトピック 1、文書 3,4 はトピック 2 を扱っているものとする。つまり、元のデータは表 1 であるとする。

これを文書とトピック、トピックそのもの、トピックと単語に関してデータを集計して表 2 を得る。

表 2 トピックに注目した集計データ

	topic1	topic2
文書1	1	0
文書2	1	0
文書3	0	1
文書4	0	1
合計	2	2

	topic1	topic2
topic1	2	0
topic2	0	2
合計	2	2

	drive	automobile	car	play	music	合計
topic1	4	3	2	0	0	9
topic2	0	0	0	5	3	8

これを関連する集計値に関して規格化するとエラー! 参照元が見つかりません。に示す確率データになる。これが三つの確率行列となる。

表 3 トピックに注目した確率データ

	topic1	topic2
文書1	0.5	0
文書2	0.5	0
文書3	0	0.5
文書4	0	0.5

	topic1	topic2
topic1	0.5	0
topic2	0	0.5

	drive	automobile	car	play	music
topic1	0.44	0.33	0.22	0.00	0.00
topic2	0.00	0.00	0.00	0.63	0.38

これらを掛け合わせると表 4 に示す最終行列になる。この最終行列はある文書においてその単語が利用される確率を表している。

表 4 PLSA 最終行列

最終行列					
	drive	automobile	car	play	music
文書1	0.11	0.08	0.06	0.00	0.00
文書2	0.11	0.08	0.06	0.00	0.00
文書3	0.00	0.00	0.00	0.31	0.19
文書4	0.00	0.00	0.00	0.31	0.19

この最終行列と最初の元データを比較してみる。文書 1 には car はなく、文書 2 には automobile がないが、最終行列にはどちらも入っている。これは、文書 1,2 ともに topic 1 の

みを扱っており、topic1 に関しては全データで集計した単語の構成が利用されているためである。また、両者とも topic1 のみを扱っているため、データは同じものとなっている。文書 3,4 も topic2 のみを扱っているため、topic2 の単語の全集計の値が利用され、両者ともに同じ値となっている。

このもとのデータと最終行列は関連しているが、同じものではない。もとのデータの数が多いものに確率が高くなる関連性を持つ。このデータの関連はあとで詳しく扱う。

PLSA で重要なのは、最終行列ではなく、その前の表 3 に示す三つの確率データである。つまり、各トピックの重要性、単語の構成はどうなっているか、を知ることができる。また、最初の行列と元データを連動させることで各トピックと関連する生データを選択し、内容を見ることができる。

6.5. PLSA の基本行列

PLSA においては図 1 に示すようにデータ行列 X を同じ形式の行列に分解する。すなわち

$$\tilde{X} = \tilde{U} \tilde{S} \tilde{V}^T \quad (1)$$

とする。これらの行列 $\tilde{X}$ 、 $\tilde{U}$ 、 $\tilde{S}$ 、 $\tilde{V}$ の要素を与えられたデータ $n(d, w)$ を利用して数値的に同定する。




図 1 PLSA の行列分解

文書を d とし、文書の集まりを D とする。つまり

$$D = \{d_1, d_2, \dots, d_N\} \quad (2)$$

である。単語を w とし、単語の集まりを W とする。つまり

$$W = \{w_1, w_2, \dots, w_M\} \quad (3)$$

である。観測できない変数つまりトピックを z とし、トピックの集まりを Z とする。つまり

$$Z = \{z_1, z_2, \dots, z_K\} \quad (4)$$

である。

観測データ $n(d, w)$ が与えられているとする。それを結合確率モデルで示すと

$$P(d, w) = P(d)P(w|d) \quad (5)$$

となる。文書 d 中に単語 w がある確率は文書 d が選択される確率 $P(d)$ に文書 d が選択され

た状態で単語 w が選択される確率 $P(w|d)$ を掛けあわせたものであると解釈できる。

ここでこのデータに関連する K 個のトピック z があるとする。ここではトピックの種類
の数のみを指定して何のトピックであるかはわからない。すると、先に定義した条件付確率

$P(w|d)$ は

$$P(w|d) = \sum_{z \in Z} P(w|z)P(z|d) \quad (6)$$

と表現される。つまり文書 d に単語 w が現れるのは、文書 d がトピック z を扱っている確
率に、トピック z の中で単語 w が現れる確率をかけたものとして得られる。

ここでベイズの定理から

$$P(z|d) = \frac{P(z)P(d|z)}{P(d)} \quad (7)$$

である。したがって

$$\begin{aligned} P(d, w) &= P(d)P(w|d) \\ &= P(d) \sum_{z \in Z} P(w|z)P(z|d) \\ &= P(d) \sum_{z \in Z} P(w|z) \frac{P(z)P(d|z)}{P(d)} \\ &= \sum_{z \in Z} P(z)P(w|z)P(d|z) \end{aligned} \quad (8)$$

となる。ここで文書 d は N 個あるとし、 $d_i = 1, 2, \dots, N$ と表現する。単語 w は M 個あるとし、
 $w_j = 1, 2, \dots, M$ と表現する。トピック z は K 個あるとし、 $z_k = 1, 2, \dots, K$ と表現する。すると

$P(d, w)$ は N 行、 M 列の行列と考えることができる。その要素は

$$P(d_i, w_j) = \sum_{z_k} P(d_i | z_k) P(z_k) P(w_j | z_k) \quad (9)$$

と表現される。

ここで隠れ変数 z と関連する確率 $P(z), P(d|z), P(w|z)$ のそれぞれの要素は $P(z_k), P(d_i|z_k), P(w_j|z_k)$ としている。 $P(z), P(d|z), P(w|z)$ はそれぞれ K 行 K 列の対角行列、 N 行 K 列の行列、 M 行 K 列の行列となる。

この三つの行列要素をデータ $n(d, w)$ を反映させていかに求めるか、が PLSA の主題になる。

6.6. PLSA 解析の尤度関数

我々はデータ $n(d, w)$ を所有している。各データを得る確率を $P(d, w)$ とする。すると、データ $n(d, w)$ を得る確率 $f[n(d, w)]$ は多項分布

$$f[n(d, w)] = \frac{1}{\prod_{d \in D} \prod_{w \in W} n(d, w)!} \prod_{d \in D} \prod_{w \in W} P(d, w)^{n(d, w)} \quad (10)$$

に従う。ここで、 $n(d, w)$ は与えられているものとし、それを実現する確率 $P(d, w)$ のほうが変数であるとみなす。 $f[n(d, w)]$ で最大値を実現するもの求めるべき $P(d, w)$ とみなす。

$f[n(d, w)]$ の最大値と $\ln\{f[n(d, w)]\}$ の最大値は一致するから、対数を取り、

$$\begin{aligned} \ln\{f[n(d, w)]\} &= -\sum_{d \in D} \sum_{w \in W} \ln n(d, w)! + \ln \sum_{d \in D} \sum_{w \in W} P(d, w)^{n(d, w)} \\ &= -\sum_{d \in D} \sum_{w \in W} \ln n(d, w)! + \ln \sum_{d \in D} \sum_{w \in W} n(d, w) \ln P(d, w) \end{aligned} \quad (11)$$

となる。今、求めたいのは $P(d, w)$ であり、この中では $n(d, w)$ は定数項とみなされる。最大値には単独の定数項は影響を与えない。また $f[n(d, w)]$ そのものは $n(d, w)$ を変数として扱

うから、式の中の $P(d, w)$ と関連する項のみを残したものを尤度関数 L とする。その中で変数は $P(d, w)$ であると捉え

$$L = \sum_{d \in D} \sum_{w \in W} n(d, w) \ln P(d, w) \quad (12)$$

を最大化する $P(d, w)$ を要請する。よって

$$\begin{aligned} L &= \sum_{d \in D} \sum_{w \in W} n(d, w) \ln P(d, w) \\ &= \sum_{d \in D} \sum_{w \in W} n(d, w) \ln \left[\sum_{z \in Z} P(z) P(w|z) P(d|z) \right] \end{aligned} \quad (13)$$

を最大にする $P(d, w)$ 、つまり $P(z), P(d|z), P(w|z)$ を求める、と置き換えることができる。

6.7. $P(d, w)$ の最尤値

我々はデータ $n(d, w)$ を所有している。この場合の $P(d, w)$ の最尤値を求めることを考える。

データ $n(d, w)$ を得る確率 $f[n(d, w)]$ は多項分布で表現され

$$f[n(d, w)] = \frac{1}{\prod_{d \in D} \prod_{w \in W} n(d, w)!} \prod_{d \in D} \prod_{w \in W} P(d, w)^{n(d, w)} \quad (14)$$

に従う。ここで、 $n(d, w)$ は与えられているこの場合にすべての確率の和は 1 である必要がある。

この尤度関数を

$$L(\theta) = \prod_{i(d)} \prod_{j(w)} P_{ij}^{n_{ij}} \quad (15)$$

と置く。 θ は母数パラメータで、ここでは P_{ij} を一括して表現しているものとみなす。すなわ

ち

$$\theta = (P_{11}, P_{12}, \dots, P_{NM}) \quad (16)$$

である。ここで i は d を表し、 j は w を表すように簡単化してある。すべての確率の和は

$$\sum_{i,j} P_{ij} = 1 \quad (17)$$

この対数尤度関数は

$$\begin{aligned} \ln L(\theta) &= \sum_{i,j} \ln P_{ij}^{n_{ij}} \\ &= \sum_{i,j} n_{ij} \ln P_{ij} \end{aligned} \quad (18)$$

となる。これを最大にする P_{ij} を求める。

まず、対数尤度関数を P_{11} で偏微分して 0 と置く。偏微分は

$$\begin{aligned} \frac{\partial \ln L(\theta)}{\partial P_{11}} &= \frac{\partial}{\partial P_{11}} \sum_{i,j} n_{ij} \ln P_{ij} \\ &= \frac{\partial}{\partial P_{11}} (n_{11} \ln P_{11} + n_{NM} \ln P_{NM}) \\ &= \frac{n_{11}}{P_{11}} + n_{NM} \frac{\partial}{\partial P_{11}} \ln P_{NM} \end{aligned} \quad (19)$$

となる。ここで、すべての確率は独立ではないため、 P_{11} の他に一個の項 P_{NM} のみを残した。残す項は任意であるが、どれか一個である。すると

$$P_{NM} = 1 - (P_{11} + P_{12} + \dots + P_{N,M-1}) \quad (20)$$

であるから

$$\begin{aligned} \frac{\partial \ln L(\theta)}{\partial P_{11}} &= \frac{n_{11}}{P_{11}} + n_{NM} \frac{\partial}{\partial P_{11}} \ln P_{NM} \\ &= \frac{n_{11}}{P_{11}} + n_{NM} \frac{\partial}{\partial P_{11}} \ln [1 - (P_{11} + P_{12} + \dots + P_{N,M-1})] \\ &= \frac{n_{11}}{P_{11}} - \frac{n_{NM}}{1 - (P_{11} + P_{12} + \dots + P_{N,M-1})} \\ &= \frac{n_{11}}{P_{11}} - \frac{n_{NM}}{P_{NM}} \\ &= 0 \end{aligned} \quad (21)$$

となる。これから

$$\frac{n_{11}}{P_{11}} = \frac{n_{NM}}{P_{NM}} \quad (22)$$

他の確率でも同様な解析をすると

$$\frac{n_{11}}{P_{11}} = \frac{n_{12}}{P_{12}} = \dots = \frac{n_{NM}}{P_{NM}} = \frac{1}{c} \quad (23)$$

を得る。ここで、それぞれの項を一定値 $1/c$ と置いてある。すると各確率は

$$P_{ij} = cn_{ij} \quad (24)$$

これらの和を取ると

$$\sum_{ij} P_{ij} = c \sum_{ij} n_{ij} \quad (25)$$

これから

$$1 = cn \quad (26)$$

よって、

$$c = \frac{1}{n} \quad (27)$$

よって各確率の最尤値 $\hat{P}_{ij}$ は

$$\hat{P}_{ij} = \frac{n_{ij}}{n} \quad (28)$$

となる。

6.8. PLSA と AIC

PLSA においてはトピック数は、単に指定するものであり、その値はやってみなければわからない、と議論してきた。

しかし、モデルの良し悪しを判断する基準として、赤池の情報量基準(Akaike information criteria AIC)がある。ここでは、それを紹介する。

AIC は

$$AIC = -2(L - p) \quad (29)$$

ここで、 p は母数パラメータの自由度である。

PLSA では、三つの行列が基礎となっている。このため、この三つの行列の自由度を考える。

文書数を n_d 、単語数を n_w 、トピック数を K とする。

行列 $P(z|d)$ においては、トピック毎の確率の和が1に規格化されているから、その自由度は

$$(n_d - 1) \times K = Kn_d - K \quad (30)$$

である。

行列 $P(z)$ においては、全ての対角要素確率の和が 1 に規格化されているから、その自由度は

$$K - 1 \quad (31)$$

である。

行列 $P(w|z)$ においては、トピック毎の確率の和が 1 に規格化されているから、その自由度は

$$(n_w - 1) \times K = Kn_w - K \quad (32)$$

である。

よって、この場合の自由度は

$$\begin{aligned} p &= (Kn_d - K) + (K - 1) + (Kn_w - K) \\ &= K(n_d + n_w - 1) - 1 \end{aligned} \quad (33)$$

となる。この自由度を用いた AIC を評価する。




図 2 AIC のトピック数依存性

AIC の結果を図 2 に示す。PLSA の結果そのものがある程度ばらつくため、AIC の結果もばらつく。このバラツキは本質的なものと考えられている。

したがって、得られた AIC の値そのものを用いるのではなく、その平均値、すなわち

$$AIC_i \leftarrow \frac{1}{3}(AIC_{i-1} + AIC_i + AIC_{i+1}) \quad (34)$$

を用いる。AIC の端点には両側にデータがないから、

$$AIC_{start} \leftarrow \frac{1}{2}(AIC_{start} + AIC_{start+1}) \quad (35)$$

$$AIC_{finish} \leftarrow \frac{1}{2}(AIC_{finish-1} + AIC_{finish}) \quad (36)$$

とすればいい。

の値が最小になるトピック数が最適と考える。ここでは、目安として扱い、その前後で結果を検討する。

6.9. PLSA アルゴリズム

PLSA の計算サイクルの模式図を図 3 に示す。図ではトピック数は 3 にしているが、以下の計算では任意の数で評価している。




図 3 PLSA のサイクル

具体的に PLSA で基本的な三つの行列の要素を決定するアルゴリズムは以下のステップからなる。

我々が得ているのはデータ $n(d, w)$ である。求めたいのは三つの行列の要素 $P(z)$ 、 $P(d|z)$ 、 $P(w|z)$ である。以下ですることは、得られているデータ $n(d, w)$ をできるだけ反

映した三つの行列の要素 $P(z)$ 、 $P(d|z)$ 、 $P(w|z)$ を定める方法である

【ステップ 1】

求めたい三つの行列の要素 $P(z)$ 、 $P(d|z)$ 、 $P(w|z)$ の初期値を設定する。

$P(d|z)$ と $P(w|z)$ は乱数を用いて各 z ごとに違うデータを採用する。ここで、 z 依存性を持たせないと、いくらループを回しても z 依存性を表現できなくなる。他の行列要素は一定、すなわち

$$P(z) = \frac{1}{K} \quad (37)$$

とする。

【ステップ 2】

三つの行列の要素 $P(z)$ 、 $P(d|z)$ 、 $P(w|z)$ の値が決まれば、データ $n(d, w)$ を取った時の、各トピックになる確率を求めることができる。その確率は、三つの行列の要素を利用して

$$P(z_1 | d_i, w_j) = \frac{P(d_i | z_1) P(z_1) P(w_j | z_1)}{\sum_{z_{k'}=z_1}^{z_K} P(d_i | z_{k'}) P(z_{k'}) P(w_j | z_{k'})} \quad (38)$$

$$P(z_2 | d_i, w_j) = \frac{P(d_i | z_2) P(z_2) P(w_j | z_2)}{\sum_{z_{k'}=z_1}^{z_K} P(d_i | z_{k'}) P(z_{k'}) P(w_j | z_{k'})} \quad (39)$$

...

$$P(z_K | d_i, w_j) = \frac{P(d_i | z_K) P(z_K) P(w_j | z_K)}{\sum_{z_{k'}=z_1}^{z_K} P(d_i | z_{k'}) P(z_{k'}) P(w_j | z_{k'})} \quad (40)$$

これをすべての単語、文章について求めておく。つまり、これは $N \times M$ 行列が K 個できる。

【ステップ 3】

もとのデータ $n(d_i, w_j)$ の z 成分を $n(d_i, w_j)_{-z_k}$ と表記する。すると

$$n(d_i, w_j)_{-z_1} = P(z_1 | d_i, w_j) n(d_i, w_j) \quad (41)$$

$$n(d_i, w_j)_{-z_2} = P(z_2 | d_i, w_j) n(d_i, w_j) \quad (42)$$

...

$$n(d_i, w_j)_{-z_K} = P(z_K | d_i, w_j) n(d_i, w_j) \quad (43)$$

となる。

これにより $N \times M$ 行列が K 個できる。

【ステップ 4】

初期値を設定した三つの行列の要素を更新する。

まず文章について考える。つまり行列 $\tilde{U}$ の要素を評価する。

$$P(d_i | z_1) = \frac{\sum_{w_j'} n(d_i, w_j')_{-z_1}}{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j')_{-z_1}} \quad (44)$$

$$P(d_i | z_2) = \frac{\sum_{w_j'} n(d_i, w_j')_{-z_2}}{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j')_{-z_2}} \quad (45)$$

...

$$P(d_i | z_K) = \frac{\sum_{w_j'} n(d_i, w_j')_{-z_K}}{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j')_{-z_K}} \quad (46)$$

これを全ての文章について評価する。これは $N \times K$ 行列の要素となる。

次に $\mathbf{z}$ について考える。つまり行列 $\tilde{S}$ の要素を評価する。これは以下で評価される。

$$P(z_k) = \frac{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j')_{-z_k}}{\sum_{z_k'} \sum_{d_i'} \sum_{w_j'} n(d_i', w_j')_{-z_k'}} \quad (47)$$

最後に単語について考える。つまり行列 $\tilde{V}$ の要素を評価する。

$$P(w_j|z_1) = \frac{\sum_{d_i'} n(d_i', w_j)_{-z_1}}{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j')_{-z_1}} \quad (48)$$

$$P(w_j|z_2) = \frac{\sum_{d_i'} n(d_i', w_j)_{-z_2}}{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j')_{-z_2}} \quad (49)$$

...

$$P(w_j|z_K) = \frac{\sum_{d_i'} n(d_i', w_j)_{-z_K}}{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j')_{-z_K}} \quad (50)$$

これをすべての単語について評価する。これは $M \times K$ 行列の要素となる。

以上を更新値とする。

【ステップ 5】

この更新した行列要素を使い対数尤度

$$L = \sum_{d \in D} \sum_{w \in W} n(d, w) \ln P(d, w) \quad (51)$$

を評価する。

この対数尤度 L_{new} の更新前の対数尤度 L_{old} に対する増分比

$$\delta r_L = \frac{L_{new} - L_{old}}{L_{new}} \quad (52)$$

がある設定値 ε より小さければプロセスを終了し、大きければステップ 2 からプロセスを繰り返す。

ここで問題になるかもしれないのは $P(d, w)$ の非常に小さな値が多くあらわれることである。この値が 0 であると、この対数は発散してしまう。または、この値が小さな値の中で変動すると、その対数は大きな値で変動してしまう。そのような場合は尤度関数でなく $P(d, w)$ の変動値をループの終端の判断に利用する。更新の前後の $P(d, w)$ を $P(d, w)_{old}$ 、 $P(d, w)_{new}$ とし、その差分の二乗を

$$Q = \frac{1}{NM} \sum_{d \in D} \sum_{w \in W} [P(d, w)_{new} - P(d, w)_{old}]^2 \quad (53)$$

として評価する。このルートが臨界値 δ より小さくなるまで繰り返す。すなわち

$$\delta < \sqrt{Q} \quad (54)$$

をループの終了条件とする。臨界値 δ は

$$\delta = \varepsilon \frac{1}{NM} \quad (55)$$

と ε は 1 より十分小さな値とする。

【ステップ 5】

AIC を評価する。

以上の操作をトピック数を変化させて検討し、AIC の最小値のあたりを議論する。

6.10. 更新値の評価

前節で示したように、三つの行列の要素は更新されていく。その更新プロセスを詳細に検討する。

行列 $P(d, w)$ の要素 $P(d_i, w_j)$ はトピック z_k を使って

$$P(d_i, w_j) = \sum_{k'} P(d_i | z_{k'}) P(z_{k'}) P(w_j | z_{k'}) \quad (56)$$

となる。 (d_i, w_j) が選択された場合、 z_k である確率は

$$\begin{aligned} n(d_i, w_j)_{-z_k} &= n(d_i, w_j) P(z_k | d_i, w_j) \\ &= n(d_i, w_j) P(z_k | d_i, w_j) \\ &= n(d_i, w_j) \frac{P(d_i | z_k) P(z_k) P(w_j | z_k)}{P(d_i, w_j)} \end{aligned} \quad (57)$$

である。

よって更新される要素は

$$\begin{aligned}
P(d_i|z_k)_{-new} &= \frac{\sum_{w_j'} n(d_i, w_j')_{-z_k}}{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j')_{-z_k}} \\
&= \frac{\sum_{w_j'} n(d_i, w_j') \frac{P(d_i|z_k)P(z_k)P(w_j'|z_k)}{P(d_i, w_j')}}{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j') \frac{P(d_i'|z_k)P(z_k)P(w_j'|z_k)}{P(d_i', w_j')}} \\
&= P(d_i|z_k) \frac{\sum_{w_j'} n(d_i, w_j') \frac{P(w_j'|z_k)}{P(d_i, w_j')}}{\sum_{d_i'} P(d_i'|z_k) \sum_{w_j'} n(d_i', w_j') \frac{P(w_j'|z_k)}{P(d_i', w_j')}}
\end{aligned} \tag{58}$$

となる。

ここで

$$A_i(z_k) = \sum_{w_j'} n(d_i, w_j') \frac{P(w_j'|z_k)}{P(d_i', w_j')} \tag{59}$$

とおくと

$$\begin{aligned}
P(d_i|z_k)_{-new} &= P(d_i|z_k) \frac{A_i(z_k)}{\sum_{d_i'} P(d_i'|z_k) A_{i'}(z_k)} \\
&= P(d_i|z_k) \frac{A_i(z_k)}{\overline{A(z_k)}}
\end{aligned} \tag{60}$$

となる。ここで

$$\sum_{d_i'} P(d_i'|z_k) = 1 \tag{61}$$

であるから、

$$\overline{A(z_k)} = \sum_{d_i'} P(d_i'|z_k) A_{i'}(z_k) \tag{62}$$

としている。つまり、 $\overline{A(z_k)}$ は $A_i(z_k)$ の平均値である。

したがって $A_i(z_k)$ の平均値よりも $A_i(z_k)$ が大きければ更新される $P(d_i|z_k)$ は大きくなる。

り、 $A_i(z_k)$ の平均値よりも $A_i(z_k)$ が小さければ更新される $P(d_i|z_k)$ は小さくなる。

$A_i(z_k)$ の要素をより詳しく検討する。

$$\begin{aligned}
A_i(z_k) &= \sum_{w_j'} n(d_i, w_j') \frac{P(w_j' | z_k)}{P(d_i, w_j')} \\
&= \sum_{w_j'} n(d_i, w_j') \frac{P(w_j' | z_k)}{\sum_{k'} P(d_i | z_{k'}) P(z_{k'}) P(w_j' | z_{k'})} \\
&= \sum_{w_j'} n(d_i, w_j') \frac{P(w_j' | z_k)}{P(d_i | z_k) P(z_k) P(w_j' | z_k) + \sum_{k' \neq k} P(d_i | z_{k'}) P(z_{k'}) P(w_j' | z_{k'})} \\
&= \sum_{w_j'} n(d_i, w_j') \frac{1}{P(d_i | z_k) P(z_k) + \frac{\sum_{k' \neq k} P(d_i | z_{k'}) P(z_{k'}) P(w_j' | z_{k'})}{P(w_j' | z_k)}}
\end{aligned} \tag{63}$$

となる。厳密にはほかの要素の変動も考慮する必要があるが、更新される $P(d_i | z_k)$ にのみ注

目すると、 $P(d_i | z_k)$ は大きくなれば、係数は小さくなり、更新される $P(d_i | z_k)$ が小さくなれば、係数は大きくなる。よって、サイクルを重ねるに従い、

$$A_i(z_k) = \overline{A_i(z_k)} \tag{64}$$

に近づいていく。

一方、単語に対する確率は

$$\begin{aligned}
P(w_j | z_k)_{new} &= \frac{\sum_{d_i'} n(d_i', w_j)_{-z_k}}{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j')_{-z_k}} \\
&= \frac{\sum_{d_i'} n(d_i', w_j) \frac{P(d_i' | z_k) P(z_k) P(w_j | z_k)}{P(d_i', w_j)}}{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j') \frac{P(d_i' | z_k) P(z_k) P(w_j' | z_k)}{P(d_i', w_j')}} \\
&= P(w_j | z_k) \frac{\sum_{d_i'} n(d_i', w_j) \frac{P(d_i' | z_k)}{P(d_i', w_j)}}{\sum_{w_j'} P(w_i | z_k) \sum_{d_i'} n(d_i', w_j') \frac{P(d_i' | z_k)}{P(d_i', w_j')}}
\end{aligned} \tag{65}$$

となる。ここで

$$B_j(z_k) = \sum_{d_i'} n(d_i', w_j) \frac{P(d_i' | z_k)}{P(d_i', w_j)} \quad (66)$$

と置くと

$$\begin{aligned} P(w_j | z_k)_{-new} &= P(w_j | z_k) \frac{B_j(z_k)}{\sum_{w_j'} P(w_i' | z_k) B_{j'}(z_k)} \\ &= P(w_j | z_k) \frac{B_j(z_k)}{B(z_k)} \end{aligned} \quad (67)$$

ただし、

$$\overline{B(z_k)} = \sum_{w_j'} P(w_i' | z_k) B_{j'}(z_k) \quad (68)$$

である。

したがって $B_j(z_k)$ の平均値よりも $B_j(z_k)$ が大きければ更新される $P(w_j | z_k)$ は大きくなり、 $B_j(z_k)$ の平均値よりも $B_j(z_k)$ が小さければ更新される $P(w_j | z_k)$ は小さくなる。よって、サイクルを重ねるに従い、

$$B_j(z_k) = \overline{B(z_k)} \quad (69)$$

に近づいていく。

次に、トピックに関する確率は

$$\begin{aligned} P(z_k)_{-new} &= \frac{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j') - z_k}{\sum_{z_k'} \sum_{d_i'} \sum_{w_j'} n(d_i', w_j') - z_k'} \\ &= \frac{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j') \frac{P(d_i' | z_k) P(z_k) P(w_j | z_k)}{P(d_i', w_j')}}{\sum_{z_k'} \sum_{d_i'} \sum_{w_j'} n(d_i', w_j') \frac{P(d_i' | z_k) P(z_{k'}) P(w_j | z_{k'})}{P(d_i', w_j')}} \\ &= P(z_k) \frac{\sum_{d_i'} \sum_{w_j'} n(d_i', w_j') \frac{P(d_i' | z_k) P(w_j | z_k)}{P(d_i', w_j')}}{\sum_{z_k'} P(z_{k'}) \sum_{d_i'} \sum_{w_j'} n(d_i', w_j') \frac{P(d_i' | z_k) P(w_j | z_{k'})}{P(d_i', w_j')}} \end{aligned} \quad (70)$$

となる。

$$C_k = \sum_{d_i'} \sum_{w_j'} n(d_i', w_j') \frac{P(d_i' | z_k) P(w_j' | z_k)}{P(d_i', w_j')} \quad (71)$$

とおくと

$$\begin{aligned} P(z_k)_{new} &= P(z_k) \frac{C_k}{\sum_{z_k'} P(z_k') C_{k'}} \\ &= P(z_k) \frac{C_k}{\bar{C}} \end{aligned} \quad (72)$$

ただし、

$$\bar{C} = \sum_{z_k'} P(z_k') C_{k'} \quad (73)$$

である。したがって、サイクルを重ねるに従い

$$C_k = \bar{C} \quad (74)$$

となっていく。

以上から、サイクルを重ねるにつれ三つの行列要素はある一定値に近づいていく。一定値に近づいた三つの行列の積は確率の最尤値の要素を持つ行列に近づいていくと期待される。

6.11. 結果の解釈およびアウトプット

$P(z)$ はトピック z がどれぐらいの頻度で現れているかを表す。したがって、その大きいものが重要なトピックとみなすことができる。

重要なトピック z を選択し、対応する $P(w|z)$ をみる。それはトピック z における単語の生起確率である。このデータは共起よりもより一般的である。確率の大きい単語同士が共起しているとみなすことができる。この観察によりトピック z がどのようなものが判断する。

最後に、 $P(d|z)$ の大きい値の文書を選択する。そしてこの選択された文書 d に対応する生のデータを観察する。これにより、数多くあるデータをあるトピックに束ねて、その内容を把握することができる。

以上のように、PLSA ではトピック z と関連づけて単語の群、文章の群を設定できる。同じ単語、文は複数のトピックに帰属できる。そのため、結果はソフトクラスタリングのものと類似している。それも単語と文の両者に対してクラスタリングしている。

しかしながら、これは計算機上で膨大なデータをグルーピングしただけであることに留意する必要がある。トピックも単に数学的に定めただけであり、実際に利用できるグループになっているとは限らない。PLSA はとりあえずのトピックグループとそのトピックグループの利用されている単語利用頻度データを提供しているにすぎない。

このデータ群をもとに、その文書が実際に何のトピックをあつかっているのか検討会をする必要がある。

この検討会では以下のことを決定する必要がある。

PLSA では、データをトピック群に仕分けている。そのトピック群をもとに、それらは本当は何について語っているのかを議論する。そして、真に利用できるトピック名をそれぞれの文章に割り当てる。割り当てるトピックが明確でない場合はその他にしておく。

各、真のトピックに対応する施策を考える。

以上の検討会の後に得る基礎データは以下である。

1. 基本生データ

得られたデータに新のトピック名がタグ付けされたもの

2. 真のトピック行列

真の生データから得られるトピック確率対角行列

3. 真のトピック vs 単語生起確率

真の生データから得られる新のトピックに対応する単語生起確率

4. 真のトピックに対する施策

上の 2,3 は 1 に連動させておく。

6.12. データの活用

新たにお客が来た場合、このお客がどのトピック（グループ）に属するのかを考える。あらかじめ PLSA は解析し終わっておいたものとする。さらに検討会も終了し、新たなタグづけが終了し、その新たなタグに対しての施策も検討されているものとする。

つまり、対応する基礎データはあるものとする。

このお客に関する情報はワードリスト $W = \{w_1, w_2, \dots, w_M\}$ に対して、その単語の生起頻度

$\{n_1, n_2, \dots, n_M\}$ である。

このデータがトピック z_k を扱っている場合、この生起頻度を得る確率は

$$f(z_k) = \frac{1}{n_1!n_2!\cdots n_M!} P(w_1|z_k)^{n_1} P(w_2|z_k)^{n_2} \cdots P(w_M|z_k)^{n_M} P(z_k) \quad (75)$$

となる。この対数を取り

$$\ln[f(z_k)] = \sum_{i=1}^n \ln n_i! + \sum_{i=1}^n n_i \ln P(w_i|z_k) + \ln P(z_k) \quad (76)$$

となる。第1項はどのトピックにおいても同じであるから、この第2項のみを取り

$$g(z_k) = \sum_{i=1}^n n_i \ln P(w_i|z_k) + \ln P(z_k) \quad (77)$$

を評価する。これを最大にする z_k を新たなデータの帰属するものとみなす。

その新たなデータの帰属するトピックに対する施策を表示する。

6.13. データの更新

6.13.1. 日々の更新

日々のお客に対して、最終的にそのデータがどのトピックに対するものであったか同定し、タグ付けをし、それを基礎データベースに追加する。

そのデータをベースデータとして扱い、 $P(w|z_k), P(z_k)$ を更新する。

6.13.2. 定期的な更新

基礎データベースに利用しているデータに発生した年月日をタグづけておく。

古いものは削除する。

また、現在利用されなくなったトピックを選択し、そのトピックに対応するデータも削除する。

その他項目が多い場合は、それに対して PLSA を適用し、新たなトピック、新たなトピックに対応する施策を検討する。

そのデータを基礎データベースに追加する。

6.14. PLSA 解析全体の流れ

PLSA 解析の全体の流れを図 4 に示す。

最初は PLSA でデータ群を分類し、そのデータ群から真のトピックを洗い出し、それをデータにタグ付ける。これにより、真のトピックの生起確率、各トピックの利用単語分布の基礎データが得られる。また、各トピックに対してどのような施策をうつのかも決定されている。




図 4 PLSA の解析フロー

新たなお客が来た場合、それがどのトピックに属するかをランキング表示する。それがやりとりの中で確定したら、そのトピックに対する施策を講じる。

やりとりの中でその人のトピックが明確になったらそのトピックをデータにタグづけ、データベースに追加する。トピックが明確でなかったらその他としてデータに追加する。

追加されたデータで基礎データを更新していく。

定期的にデータのメンテナンスを行う。

データが作成された年月日が古いデータは削除する。

利用頻度のほとんどなくなったトピックを同定し、そのトピックと関連するデータを削除する。

その他とタグ付けられたデータの数进行评估する。

その他のデータ数が少ない場合は、単に上の定期更新を反映したデータの更新を行う。

その他のデータ数が多い場合は、そのデータで PLSA をし、新たなトピックを追加したデータを基礎データに追加する。

6.15. 簡単な例への適用

第 6.4 節で扱った簡単な例に対して PLSA を適用してみる。

下記のような初期値を採用し、これをこれまで述べてきたプロセスを 10 回ループさせる。その結果の表も示している。

表 5 設定した初期値

	z1	z2
d1	0.22	0.22
d2	0.16	0.09
d3	0.01	0.31
d4	0.61	0.38

	z1	z2
z1	0.50	0.00
z2	0.00	0.50

	w1	w2	w3	w4	w5
z1	0.20	0.20	0.20	0.20	0.20
z2	0.20	0.20	0.20	0.20	0.20

表 6 10 回ループ後の行列値

	z1	z2
d1	0.56	0.00
d2	0.44	0.00
d3	0.00	0.50
d4	0.00	0.50

	z1	z2
z1	0.53	0.00
z2	0.00	0.47

	w1	w2	w3	w4	w5
z1	0.44	0.33	0.22	0.00	0.00
z2	0.00	0.00	0.00	0.63	0.38

10 回ループ後の表で議論する。

まず、トピック 1 も 2 も同様な頻度で扱われていることがわかる。
また、トピック 1 は単語 $w1:drive$, $w2:automobile$, $w3:car$ が生起し、 $w4:play$, $w5: music$ はないことがわかる。これから、トピック 1 は自動車関連であることがわかる。

トピック 2 は単語 $drive$, $automobile$, car はなく、 $play$, $music$ が生起していることがわかる。これからトピック 2 は音楽関連を扱っていることがわかる。
また、文章でみると、トピック 1 を扱っているのは $d1, d2$ 、トピック 2 を扱っているのは $d3, d4$ であることがわかる。

以上は、ほぼ狙い通りの結果である。




図 5 L のサイクル依存性




図 6 δ のサイクル依存性

図 5 に L のサイクル依存性を示す。大体 6 回のサイクルで L の増加はほぼ飽和している。

図 6 に δ のサイクル依存性を示す。

初期の設定は現実を反映していないので最初の設定での変動量は大きい。それから大きく減少し、サイクルを回すたびにその変動量は大きくなり、真値に近づいていく。真値に近づいていくと、あるところから変動量は減少していく。今回の場合はほぼ 7 回のサイクルで行列要素の変動はほぼ無視できるところまで減少する。

L の飽和と δ の変動量はよく対応していることがわかる。 δ の変動はスケールとしては $1/(NM)$ のあたりである。したがって、 δ の変動量の臨界値としてはその値の $1/1000$ 、つまり $\varepsilon = 1/1000$ として

$$\delta = \varepsilon \frac{1}{NM} = \frac{1}{1000} \frac{1}{NM} \quad (78)$$

あたりを目安にすればいい。

同様に L の増加の飽和も

$$\delta r_L = \left| \frac{L_{new} - L_{old}}{L_{new}} \right| < \frac{1}{1000} \quad (79)$$

あたりを目安にすればいい。

6.16. PLSA のその他への適用

PLSA は、これ以外にもさまざまな場面に適用できる。

6.16.1. POS データ

POS データを考える。これは顧客とその顧客が買った商品群からなる。店に来た顧客 d が買った商品 w とみなすことができる。トピックは、その客がどのような購買グループに属するかに相当する。したがって、その客の属するグループの **topic** が同定できれば、その **topic** に応じた宣伝を選択して行えばいい、ということになる。

一方、どの **topic** (グループ) に属するか不明のお客がある商品を買った場合、何の商品を宣伝すればいいか、という問題がある。これは新たなお客の帰属するトピックでの解析を適用すればいい。このアルゴリズムで z を選択し、その z に対応する商品を宣伝すればいい。

6.16.2. 辞書作成

先に辞書を作成することが重要としていたが、PLSA は辞書作成そのものにも利用できるかもしれない。

もとデータを名詞 (行)、形容詞、動詞 (列) のデータに変換する。これに PLSA を適用することにより、名詞、形容詞、動詞のクラスタリングをおこなうことができるかもしれない。つまり、辞書が作成できるかもしれない。

6.16.3. 観光地

観光地は観光地 (行) と係り受け単語 (列) のデータ構造になる。係り受け単語とは文法構造を持つ単語のペアであり、”景色+良い”、”歴史+感じる”、”写真+撮る”のような単語とそれに対してどうだとか、何をする、を結びつけたものである。これはテキストデータの解析で事前にやっているものとする。このようなデータから、各観光地に対するテーマを同定する。各テーマに沿った宣伝をすとか、他の地域との連携で同一テーマの周遊を提案する、などに利用されている。

6.17. PLSA 解析における共起

先に我々は PLSA では単語の共起には注目せずに、単語の使用頻度確率分布を利用すると述べた。しかし、PLSA においても共起は以下のように評価できる。

まず、トピックを選択し、そのトピックと関連しているであろう文書を選択する。

その選択した文書の中で各ワードが利用されている文書数 $n(w_i)$ を評価する。

$n(w_i)$ の大きなものから順に選択する。

ワード w_i が 0 でない文書を選択し、その選択された文書の中で他のワード w_j が利用されている文書数 $n(w_j|w_i)$ を評価する。

$$P(w_j) = \frac{n(w_j)}{\sum_{w \in W} n(w)} \quad (80)$$

$$P(w_j|w_i) = \frac{n(w_j|w_i)}{n(w_i)} \quad (81)$$

とし、

$$\xi = \frac{P(w_j|w_i)}{P(w_j)} \quad (82)$$

で ξ の値が大きければ共起が起こっているとみなす。

6.18. 単語と係り受けからなるデータからスタートした PLSA 解析

実際の文章ではなく、その文章の単語と係り受けに注目した文章からなるデータをスタートにして PLSA をやる場合がある。

この場合、ある文章を S_h と置く。その文章には単語と係り受けがあり

$$S_{w_h} = \{w_1, w_2, \dots, w_i\} \quad (83)$$

$$S_{e_h} = \{e_1, e_2, \dots, e_j\} \quad (84)$$

これから、データを構成する。

これに対してトピックを設定する。

この場合、トピックを出した場合、最初の文章はどのトピックを扱っていたのかを評価する必要がある。

トピック T_k の場合の文章 S_{w_h} の出現確率は

$$P(S_{w_h}|T_k) = \sum_i P(S_{w_h}|w_i) P(w_i|T_k) \quad (85)$$

となる。

ここで $P(S_{w_h}|w_i)$ を考える。ここでの w_i は S_{w_h} に生起しているものに限定する。そうでなければ対応する $P(S_{w_h}|w_i)$ は 0 である。この場合単語 w_i を利用している文書数を $n(w_i)$ とすると、文書 S_{w_h} は文書数 1 であるから、

$$P(S_{w_h}|w_i) = \frac{1}{n(w_i)} \quad (86)$$

となる。

トピック T_k の場合の係り受け S_{e_h} の出現確率は

$$P(S_{e_h}|T_k) = \sum_j P(S_{e_h}|e_j)P(w_j|T_k) \quad (87)$$

となる。

ここで $P(S_{e_h}|e_j)$ を考える。ここでの e_j は S_{e_h} に生起しているものに限定する。そうでなければ対応する $P(S_{e_h}|e_j)$ は 0 である。この場合単語 e_j を利用している文書数を $n(e_j)$ とすると、文書 S_{e_h} は文書数 1 であるから、

$$P(S_{e_h}|e_j) = \frac{1}{n(e_j)} \quad (88)$$

となる。

これから、トピック T_k の場合、文章 S_h の出現確率をこれらの確率の平均と仮定して

$$P(S_h|T_k) = \frac{P(S_{w_h}|T_k) + P(S_{e_h}|T_k)}{2} \quad (89)$$

を得る。すると文章 S_h の出現確率は

$$P(S_h) = \sum_k P(S_h|T_k)P(T_k) \quad (90)$$

となる。

各トピックに対して文章のスコアを

$$\frac{P(S_h|T_k)}{P(S_h)} \quad (91)$$

とし、これが臨界値を超えた場合は 1、そうでなければ 0 とする。

6.19. ある項目に着目した PLSA 解析

共起から解析をスタートした場合、ある項目に着目した PLSA を考えることができる。

ある項目としては、最近のもの A と過去のもの B を考える。つまり、過去には重要であったが、今は重要でない。または最近重要になってきた、ということを解析したい。

そのためには、通常の PLSA ではなく、文章を編集して、共起と word のデータ形式にしておく。

その同じデータ形式で A, B のデータを作成する。A と B では一般にデータ数が違うから、総データ数でスケールしておく。さらにデータにおいて A-B を作成し、その絶対値をとる。このデータに PLSA を施す。

この結果得られたトピックは先のような過去重要で今は重要でない、今は重要で過去は重要ではない、というものである。このどちらかはデータの年代をみることによって同定できる。

この手法では、データの形式が共起と単語になっているため、これと元データの関連性を示す解析が必要になる。

6.20. まとめ

PLSA においてデータを潜在トピックに関連させる方法を示した。

潜在トピックの重要度を評価し、その重要なトピックに出現する確率、またその重要なトピックと関連する文章はどれか、を定量的に評価する。これらの情報から、文章に含まれるマクロな情報を引き出すことができる。

PLSA におけるトピック数は AIC であたりをつけることができることを示した。

PLSA 解析後の検討会ですべきことを示した。

PLSA の定期的なメンテナンスを示した。

PLSA の応用例も簡単に示した。

PLSA における共起の評価も示した。